Statistica

Tommaso Signorini

2026

Indice

1 Calcolo Combinatorio **5**
1.1 Il Principio Fondamentale 5
1.2 Permutazioni 5
1.3 Combinazioni 6
1.4 Coefficienti Multinomiali 6

2 Applicazioni **6**
2.1 Il Metodo "Stelle e Barrette" 7

3 Fondamenti di Probabilità **8**
3.1 Assiomi di Kolmogorov 8
3.2 Proprietà della Probabilità 8

4 Spazi Campionari ed Esiti Equiprobabili **9**

5 Successioni di Eventi e Disuguaglianze Notevoli **9**

6 Probabilità Condizionata e Teorema di Bayes **10**

7 Indipendenza e Prove di Bernoulli **12**

8 Variabili Aleatorie **13**

9 La Funzione di Distribuzione **13**

10 Valore Atteso e Varianza **14**
10.1 La Funzione Indicatrice 14
10.2 Trasformazioni e Linearità 14
10.3 La Varianza 14

11 Distribuzioni Discrete Notevoli **15**
11.1 La distribuzione di Bernoulli 15
11.2 La distribuzione Binomiale 15
11.3 La distribuzione di Poisson 15
11.4 La distribuzione Geometrica 15
11.5 La Distribuzione Binomiale Negativa 16
11.6 La Distribuzione Ipergeometrica 16

12 Distribuzioni Continue e Densità di Probabilità **17**
12.1 Proprietà Fondamentali 17
12.2 Funzione di Ripartizione e Derivazione 17

13 Momenti e Calcolo dell'Aspettativa **18**
13.1 Valore Atteso e Varianza 18
13.2 Calcolo dell'Aspettativa tramite la Funzione di Sopravvivenza 18

14 Modelli Continui Notevoli **19**
14.1 La Distribuzione Uniforme 19
14.2 La Distribuzione Normale (Gaussiana) 19

15 Approssimazione Normale e Teorema di De Moivre-Laplace **20**

16 Distribuzioni Continue Notevoli **22**
16.1 La Distribuzione Esponenziale 22
16.2 La Distribuzione Gamma 23
16.3 La Distribuzione Beta 24

17 Distribuzione di una Funzione di Variabile Aleatoria **24**

18 La Distribuzione Chi-Quadro e la MGF **25**
18.1 Distribuzione χ^2 25
18.2 Funzione Generatrice dei Momenti (MGF) 25

19 Covarianza **25**

20 Indipendenza e Scorrelazione **26**
20.1 Il legame tra Indipendenza e Covarianza 26

21 Leggi Congiunte, Marginali e Densità **27**
21.1 Caso Discreto 27
21.2 Caso Continuo 28

22 Somma di Variabili Aleatorie Indipendenti **29**

23 Disuguaglianze Fondamentali **30**

24 I Teoremi Asintotici della Probabilità **30**

25 Vettori Aleatori e Normale Multivariata **32**

26 Fondamenti di Statistica Inferenziale **33**

27 Approssimazione i.i.d. nel Campionamento **34**
27.1 Giustificazione Matematica 34

28 Definizione di Statistica e Distribuzioni Campionarie **35**

29 Proprietà Algebriche delle Statistiche Campionarie **36**

30 Analisi Probabilistica: Correttezza degli Stimatori **37**

31 Proprietà Fondamentali dei Campioni Normali **38**
31.1 Distribuzione della Media Campionaria (Punto ii) 38
31.2 Indipendenza tra Media e Varianza Campionaria (Punto i) 38
31.2.1 Espressione di S^2 in funzione degli scarti 39
31.2.2 Analisi della densità congiunta e cambio di variabili 39

32 Distribuzione Chi-Quadro della Varianza Campionaria (Punto iii) 40
32.1 Proprietà di Indipendenza dei Termini Ricorsivi 40
32.2 Dimostrazione per Induzione 41

33 La Distribuzione t di Student 42

34 Coefficiente di Correlazione Campionario 42

35 Statistiche d'Ordine, Mediana e Percentili 43
35.1 Percentili e Quartili 44

36 Distribuzione delle Statistiche d'Ordine 44
36.1 Distribuzione del Minimo $X_{(1)}$ 44
36.2 Distribuzione del Massimo $X_{(n)}$ 45

37 Esercizio: Distribuzione e Densità Congiunta del Minimo e del Massimo 45

38 Esercizio: Distribuzione Congiunta di Tutte le Statistiche d'Ordine 47

39 Esercizio: Densità Marginale dell'i-esima Statistica d'Ordine 49

40 Introduzione alla Riduzione dei Dati 50

41 Il Principio di Sufficienza 51

42 Formulazione Matematica della Probabilità Condizionata 51

43 Applicazione Pratica: Il Campione di Bernoulli 53

44 Esercizio: Media Campionaria per una Popolazione Normale 54

45 Il Teorema di Fattorizzazione di Halmos-Savage 55

46 Esercizi Svolti ed Applicazioni Pratiche 55
46.1 Esercizio: Distribuzione Uniforme Discreta 55
46.2 Esercizio: Distribuzione Potenza su $(0, 1)$ 56
46.3 Esercizio: Distribuzione di Tipo Beta e Trasformazioni Biettive 57
46.4 Esercizio: Sufficienza nel Modello Normale con Parametri Incogniti. 58

47 Statistiche Sufficienti Minimali 59
47.1 Esempio: Distribuzione Uniforme su $(\theta, \theta + 1)$ 59
47.2 Proprietà ed Osservazioni sulle Statistiche Minimali 60

48 Il Principio di Verosimiglianza 61

49 Introduzione agli Stimatori 62

50 Stimatori di Massima Verosimiglianza (MLE) 62
50.1 Procedura operativa e l'uso del Logaritmo 62

51 Esempi di Calcolo MLE 63

52 Proprietà degli Stimatori 64

53 Estensione a Modelli Multiparametrici 65

54 Un Caso con Dominio e Struttura Generica **65**

55 Esercizi su Minimalità e MLE **67**
55.1 Esercizi Statistiche Sufficienti e Minimali 67
55.1.1 Analisi della Sufficienza tramite il Teorema di Fattorizzazione 67
55.1.2 Verifica della Minimalità con il Criterio di Lehmann-Scheffé 67
55.2 Esercizio: Parametro Bidimensionale 68
55.3 Esercizi sul Principio di Massima Verosimiglianza 68
55.3.1 Stima di Massima Verosimiglianza e Proprietà di Correttezza 69

56 Altri Esercizi Stima di Massima Verosimiglianza (MLE) **70**

57 Gli Stimatori Bayesiani **73**
57.1 Derivazione dello Stimatore Bayesiano 73
57.2 Famiglie Coniugate 73

58 Esercizi sugli Stimatori Bayesiani **75**
58.1 Inferenza sulla Varianza di un Modello Gaussiano 76
58.2 Esercizio con Funzione di Costo 76

1 Calcolo Combinatorio

Il calcolo combinatorio ci fornisce gli strumenti per determinare in quanti modi possibili può verificarsi un certo evento senza doverli elencare tutti.

1.1 Il Principio Fondamentale

Immaginiamo di avere due esperimenti indipendenti. Supponiamo che il primo esperimento abbia n esiti possibili e il secondo ne abbia m; se sequenze distinte di eventi danno luogo a esiti distinti, allora il numero totale di esiti possibili per l'esperimento combinato è semplicemente il prodotto $n \cdot m$.

Possiamo visualizzare questo concetto immaginando di disporre gli esiti in una matrice:

$$\begin{matrix} (1,1) & (1,2) & \dots & (1,m) \\ \vdots & \vdots & & \vdots \\ (n,1) & (n,2) & \dots & (n,m) \end{matrix}$$

Avendo n righe e m colonne, il numero totale di coppie (i, j) è esattamente $n \times m$. Nel calcolo combinatorio e nella probabilità, affermare che *"sequenze distinte di eventi danno luogo ad esiti diversi"* significa semplicemente che **l'ordine** in cui si verificano gli eventi è rilevante.

Matematicamente, lo spazio campionario totale di un esperimento in più fasi è il **prodotto cartesiano** degli spazi delle singole fasi:

$$\Omega = \Omega_1 \times \Omega_2 \times \cdots \times \Omega_k$$

Ogni esito complessivo è rappresentato da una sequenza ordinata $\omega = (\omega_1, \omega_2, \dots, \omega_k)$. Pertanto, due sequenze composte dagli stessi elementi, ma disposti in posizioni diverse, costituiscono matematicamente due **esiti distinti**. Ad esempio, nel lancio di due monete, la sequenza $(\text{Testa}, \text{Croce})$ differisce dalla sequenza $(\text{Croce}, \text{Testa})$ proprio per l'ordine degli eventi.

1.2 Permutazioni

Le permutazioni indicano in quanti modi possiamo *ordinare* un determinato numero di elementi distinti. Supponiamo di avere tre lettere $\{A, B, C\}$, quindi di avere tre slot in cui posizionarle. Si hanno 3 lettere per la prima posizione, 2 per la seconda e 1 per l'ultima, per un totale di $3! = 6$ modi diversi di scriverle (ABC, ACB, BAC, BCA, CAB, CBA). In generale, per n elementi distinti, le permutazioni possibili sono $n!$.

Esempio: Gli anagrammi di "Pepper"

Quanti anagrammi diversi possiamo formare con le lettere della parola **pepper**?
Se tutte le 6 lettere fossero diverse (ad esempio etichettandole come $p_1, e_1, p_1, p_2, e_2, r_1$), avremmo semplicemente 6! permutazioni. Tuttavia, le lettere non sono tutte distinte. Abbiamo tre "p", due "e" e una "r".
Se scambiamo di posto la prima "e" (e_1) con la seconda "e" (e_2), otteniamo visivamente la stessa identica parola. Lo stesso vale per le tre "p". Per non contare più volte la stessa parola, dobbiamo dividere il totale delle permutazioni (6!) per le permutazioni delle lettere identiche:

$$\frac{6!}{3! \cdot 2!}$$

Dove 3! elimina i duplicati dovuti alle tre "p" e 2! elimina quelli dovuti alle due "e".

1.3 Combinazioni

Siano n e r due parametri tali che $r \leq n$. Con le combinazioni vogliamo contare il numero sottoinsiemi distinti di r elementi estratti da un insieme più grande di n elementi.

Esempio: L'Urna

Supponiamo di avere un'urna con 5 palline diverse e di volerne estrarre 3. Se tenessimo conto dell'ordine, avremmo $5 \times 4 \times 3$ modi. Tuttavia, estrarre le palline nell'ordine P_1, P_2, P_3 è equivalente a estrarle come P_3, P_2, P_1 se ci interessa solo quali palline abbiamo in mano.
Dobbiamo quindi dividere per i modi in cui possiamo ordinare queste 3 palline, ovvero 3!:

$$\frac{5 \times 4 \times 3}{3!} = \frac{5!}{3! \cdot 2!} = \binom{5}{3}$$

In generale, il numero di combinazioni è dato dal coefficiente binomiale:

$$\binom{n}{r} = \frac{n!}{(n-r)! \cdot r!}$$

Vale la convenzione che $0! = 1$ e $1! = 1$, da cui discende che $\binom{n}{0} = \binom{n}{n} = 1$.

1.4 Coefficienti Multinomiali

Se invece di suddividere gli elementi in due gruppi (scelti e non scelti), li vogliamo distribuire in r scatole distinte tali che la scatola i-esima contenga n_i elementi (con $\sum_{i=1}^{r} n_i = n$), espandiamo il concetto:

$$\binom{n}{n_1} \cdot \binom{n-n_1}{n_2} \cdots \binom{n-n_1-\cdots-n_{r-1}}{n_r} = \frac{n!}{n_1! n_2! \dots n_r!} = \binom{n}{n_1, \dots, n_r}$$

Infatti per la prima scatola si devono scegliere n_1 elementi dagli n totali, dopo aver riempito la prima scatola, dobbiamo mettere n_2 elementi nella seconda dagli $n - n_1$ disponibili e così via. Notiamo che se $r = 2$, ritroviamo esattamente il coefficiente binomiale.

2 Applicazioni

Teorema 2.1 (Teorema del Binomio)**.** *Per ogni $x, y \in \mathbb{R}$ e per ogni intero $n \geq 1$, vale:*

$$(x+y)^n = \sum_{j=0}^{n} \binom{n}{j} x^j y^{n-j}$$

(La dimostrazione procede per induzione).

Un'elegante applicazione di questo teorema riguarda la **cardinalità dell'insieme delle parti**. Dato un insieme di n elementi, il numero dei suoi sottoinsiemi di cardinalità k è $\binom{n}{k}$. Se li sommiamo tutti (per $k = 0, 1, \dots, n$), calcoliamo il numero totale di sottoinsiemi:

$$\sum_{k=0}^{n} \binom{n}{k} = (1+1)^n = 2^n$$

Il risultato è un insieme delle parti composto da 2^n elementi.

Teorema 2.2 (Teorema Multinomiale)**.** *La generalizzazione del binomio a r variabili è:*

$$(x_1 + x_2 + \cdots + x_r)^n = \sum_{\substack{n_1+n_2+\cdots+n_r=n \\ n_i \geq 0}} \binom{n}{n_1, \dots, n_r} x_1^{n_1} \dots x_r^{n_r}$$

2.1 Il Metodo "Stelle e Barrette"

Un classico problema combinatorio consiste nel chiedersi: *Quanti sono i vettori* $(y_1, \ldots, y_r)$ *nella somma del teorema multinomiale tali che* $y_i \geq 1$ *e* $\sum y_i = m$*?*

Possiamo visualizzare m oggetti identici ("stelle") allineati. Tra questi ci sono $m-1$ spazi vuoti. Vogliamo dividere questi oggetti in r gruppi inserendo $r-1$ separatori ("barrette") negli spazi disponibili. Il numero di modi per posizionare i separatori (senza avere gruppi vuoti) è:

$$\binom{m-1}{r-1}$$

Se ammettiamo soluzioni in cui $n_i \geq 0$ (è possibile avere gruppi vuoti), applicando il cambio di variabile $n_i = y_i - 1$, si ha $n = n_1 + \cdots + n_r = y_1 - 1 + \cdots + y_r - 1 = y_1 + \cdots + y_r - r$ da cui $m = y_1 + \cdots + y_r = n + r$. Pertanto, sostituendo nel binomio di prima, si deduce che il numero di soluzioni è:

$$\binom{n+r-1}{r-1}$$

Esempio Algebrico: Espansione di $(x+y+z)^3$
Vogliamo espandere il trinomio $(x+y+z)^n$ con $r=3$ variabili e potenza $n=3$. La formula del teorema multinomiale per $r=3$ è data da:

$$(x+y+z)^n = \sum_{\substack{n_1+n_2+n_3=n \\ n_1,n_2,n_3 \geq 0}} \binom{n}{n_1, n_2, n_3} x^{n_1} y^{n_2} z^{n_3}$$

dove il coefficiente multinomiale è definito come:

$$\binom{n}{n_1, n_2, n_3} = \frac{n!}{n_1!\, n_2!\, n_3!}$$

Per $n=3$, cerchiamo tutte le terne di interi non negativi tali che $n_1 + n_2 + n_3 = 3$:

1. **Un unico esponente pari a** 3 **(permutazioni di** $(3,0,0)$**):**
   - $(3,0,0) \implies \frac{3!}{3!\,0!\,0!} = 1 \implies x^3$
   - $(0,3,0) \implies \frac{3!}{0!\,3!\,0!} = 1 \implies y^3$
   - $(0,0,3) \implies \frac{3!}{0!\,0!\,3!} = 1 \implies z^3$
2. **Un esponente pari a** 2 **e uno pari a** 1 **(permutazioni di** $(2,1,0)$**):**
   - Il coefficiente per ciascuna di queste configurazioni è $\frac{3!}{2!\,1!\,0!} = 3$.
   - I termini generati sono: $3x^2y,\ 3x^2z,\ 3xy^2,\ 3xz^2,\ 3y^2z,\ 3yz^2$.
3. **Tutti gli esponenti pari a** 1 **(terna** $(1,1,1)$**):**
   - $(1,1,1) \implies \frac{3!}{1!\,1!\,1!} = 6 \implies 6xyz$

Sommando tutti i termini ottenuti:

$$(x+y+z)^3 = x^3 + y^3 + z^3 + 3x^2y + 3x^2z + 3xy^2 + 3xz^2 + 3y^2z + 3yz^2 + 6xyz$$

espandendo il cubo si verifica la correttezza del risultato.

3 Fondamenti di Probabilità

Dopo aver imparato a contare, passiamo al calcolo delle probabilità. Iniziamo definendo lo **Spazio Campionario** Ω, ovvero l'insieme di tutti gli esiti possibili di un esperimento. Ad esempio:

- Lancio di 1 moneta: $\Omega = \{T, C\}$
- Lancio di 2 monete: $\Omega = \{(T,T), (T,C), (C,T), (C,C)\}$

Un **Evento** è un qualsiasi sottoinsieme di Ω. Su questi eventi possiamo compiere le classiche operazioni insiemistiche:

- **Unione ($E \cup F$):** si verifica se accade E oppure F, o entrambi. Insiemisticamente si scrive $E \cup F = \{x \in \Omega : x \in E \text{ o } x \in F \text{ o in entrambi}\}$.
- **Intersezione ($E \cap F$, indicato anche come EF):** si verifica se accadono simultaneamente E e F. Insiemisticamente si scrive $E \cap F = \{x \in \Omega : x \in E \text{ e } x \in F\}$.
- **Complementare ($E^c = \Omega \setminus E$):** si verifica se non accade E.

Valgono proprietà fondamentali come le proprietà commutativa, associativa, distributiva dell'unione sull'intersezione ($(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$) e le Leggi di De Morgan:

$$\left(\bigcup_{i=1}^{n} A_i\right)^c = \bigcap_{i=1}^{n} A_i^c \qquad \text{e} \qquad \left(\bigcap_{i=1}^{n} A_i\right)^c = \bigcup_{i=1}^{n} A_i^c$$

3.1 Assiomi di Kolmogorov

La teoria della probabilità si fonda su tre pilastri. Supponiamo che per ogni evento $E \subseteq \Omega$ sia definito un numero $\mathbb{P}(E)$, tale che:

Assioma 1. La probabilità è sempre un numero compreso tra 0 e 1: $\quad 0 \leq \mathbb{P}(E) \leq 1$.

Assioma 2. L'evento certo (lo spazio campionario) ha probabilità 1: $\quad \mathbb{P}(\Omega) = 1$.

Assioma 3. Per ogni successione di eventi $\{E_i\}_i$ a due a due disgiunti (cioè mutuamente esclusivi), la probabilità dell'unione è la somma delle probabilità:

$$\mathbb{P}\left(\bigcup_i E_i\right) = \sum_i \mathbb{P}(E_i)$$

3.2 Proprietà della Probabilità

Da questi tre semplici assiomi derivano proprietà utilissime per la risoluzione dei problemi:

1. Poiché E ed E^c sono disgiunti per definizione e la loro unione è Ω, si ha $\mathbb{P}(E) + \mathbb{P}(E^c) = \mathbb{P}(\Omega) = 1$. Di conseguenza, $\mathbb{P}(E^c) = 1 - \mathbb{P}(E)$.
2. Se l'evento E implica l'evento F (ovvero $E \subseteq F$), allora $\mathbb{P}(E) \leq \mathbb{P}(F)$.
3. **Legge dell'addizione:** $\mathbb{P}(E \cup F) = \mathbb{P}(E) + \mathbb{P}(F) - \mathbb{P}(E \cap F)$. Sottraiamo l'intersezione per non contarla due volte.

Quest'ultimo punto si generalizza nel **Principio di Inclusione-Esclusione** per n eventi:

$$\mathbb{P}\left(\bigcup_{i=1}^{n} E_i\right) = \sum_{i=1}^{n} \mathbb{P}(E_i) - \sum_{i=1}^{n} \sum_{j<i} \mathbb{P}(E_i \cap E_j) + \sum_{i<j<k} \cdots + (-1)^{n+1} \mathbb{P}(E_1 \cap \cdots \cap E_n)$$

In sostanza, si sommano le probabilità singole, si sottraggono le intersezioni a due a due, si aggiungono le intersezioni a tre a tre, si sottraggono quelle a quattro a quattro, e così via.

4 Spazi Campionari ed Esiti Equiprobabili

Il punto di partenza per lo studio della probabilità classica è l'analisi di uno spazio campionario finito i cui esiti hanno tutti la stessa possibilità di verificarsi.

Consideriamo uno spazio campionario Ω che sia un insieme finito tale che $|\Omega| = N$ e $\Omega = \{1, 2, \dots, N\}$. Ipotizziamo che la probabilità di ogni singolo esito sia uniforme:

$$\mathbb{P}(\{1\}) = \mathbb{P}(\{2\}) = \cdots = \mathbb{P}(\{N\}) \implies \forall i \in \Omega,\ \mathbb{P}(\{i\}) = \frac{1}{N}$$

Per un generico evento $E \subseteq \Omega$, la sua probabilità è data dal rapporto tra il numero di casi favorevoli e il numero totale dei casi possibili (valido **solo** per esiti equiprobabili):

$$\mathbb{P}(E) = \frac{|E|}{|\Omega|}$$

Esempio: Commissione di 5 persone

Vogliamo formare una commissione di 5 persone scegliendo tra un gruppo composto da 6 uomini e 9 donne. Qual è la probabilità di avere esattamente 3 uomini e 2 donne? Definiamo lo spazio campionario come l'insieme di tutti i possibili gruppi da 5 persone scelti tra le 15 presenti. La cardinalità di Ω è:

$$|\Omega| = \binom{15}{5}$$

L'evento E corrisponde alla scelta di 3 uomini (su 6) e 2 donne (su 9). Pertanto:

$$|E| = \binom{6}{3} \cdot \binom{9}{2} \implies \mathbb{P}(E) = \frac{\binom{6}{3} \cdot \binom{9}{2}}{\binom{15}{5}}$$

5 Successioni di Eventi e Disuguaglianze Notevoli

Quando passiamo da insiemi finiti a collezioni numerabili di eventi, è utile introdurre il concetto di limite per successioni monotone.

Definizione 5.1. Una successione di eventi $\{E_i\}_i$ è detta **crescente** se $E_1 \subset E_2 \subset \dots$, mentre è detta **decrescente** se $E_1 \supset E_2 \supset E_3 \supset \dots$.

Se la successione è crescente, definiamo il limite come l'unione numerabile di tutti gli eventi (il più grande possibile):

$$\lim_{i\to\infty} E_i = \bigcup_{i=1}^{\infty} E_i$$

Se la successione è decrescente, il limite è dato dalla loro intersezione numerabile:

$$\lim_{i\to\infty} E_i = \bigcap_{i=1}^{\infty} E_i$$

Questo concetto ci porta a un risultato fondamentale sulla continuità della misura di probabilità.

Teorema 5.1 (Continuità della probabilità)**.** *Se $\{E_n\}_n$ è una successione monotona (crescente o decrescente) di eventi, allora la probabilità del limite coincide con il limite della probabilità:*

$$\mathbb{P}\left(\lim_{n\to\infty} E_n\right) = \lim_{n\to\infty} \mathbb{P}(E_n)$$

Per manipolare le probabilità di intersezioni e unioni complesse, ci vengono in aiuto due storiche disuguaglianze:

Proposizione 5.1 (Disuguaglianza di Bonferroni)**.** *La probabilità dell'intersezione di n eventi è limitata inferiormente:*

$$\mathbb{P}(E_1 \cap E_2 \cap \cdots \cap E_n) \geq \mathbb{P}(E_1) + \cdots + \mathbb{P}(E_n) - (n-1)$$

Proposizione 5.2 (Disuguaglianza di Boole)**.** *La probabilità dell'unione di n eventi è limitata superiormente dalla somma delle loro singole probabilità:*

$$\mathbb{P}\left(\bigcup_{i=1}^{n} E_i\right) \leq \sum_{i=1}^{n} \mathbb{P}(E_i)$$

Chiudiamo questa sezione ricordando un'importante formula di scomposizione, strettamente legata alla teoria degli insiemi. Per ogni coppia di eventi $A, B \subset \Omega$:

$$\mathbb{P}(A) = \mathbb{P}(A \cap B) + \mathbb{P}(A \cap B^c)$$

6 Probabilità Condizionata e Teorema di Bayes

Spesso ci troviamo a dover calcolare la probabilità di un evento sapendo che si è già verificato un altro evento che ha modificato il nostro livello di informazione sul sistema.

Definizione 6.1. Dati due eventi $E, F \subset \Omega$ con $\mathbb{P}(F) \neq 0$, definiamo la **probabilità condizionata** di E dato F come:

$$\mathbb{P}(E|F) = \frac{\mathbb{P}(E \cap F)}{\mathbb{P}(F)}$$

Esempio: Lancio di due monete

Una moneta viene lanciata due volte. Vogliamo calcolare la probabilità di ottenere due teste, ovvero l'evento $E = \{(T,T)\}$, sapendo che:

a) Al primo lancio è uscita testa ($F = \{(T,T),(T,C)\}$).

b) È uscita testa in almeno uno dei due lanci ($F = \{(T,T),(T,C),(C,T)\}$).

Nel caso (a), l'intersezione tra E e F è l'evento E stesso. Poiché $|F| = 2$ e Ω ha 4 esiti possibili equiprobabili:

$$\mathbb{P}(E|F) = \frac{|E|/|\Omega|}{|F|/|\Omega|} = \frac{|E|}{|F|} = \frac{1}{2}$$

Nel caso (b), il numero di casi favorevoli in cui esce *almeno* una testa è $|F| = 3$ ($F = \{(T,T),(T,C),(C,T)\}$), per cui la probabilità condizionata scende a:

$$\mathbb{P}(E|F) = \frac{1}{3}$$

Dalla definizione di probabilità condizionata deriva la **regola del prodotto** per l'intersezione di più eventi. Ad esempio, per 3 eventi:

$$\mathbb{P}(E_1 \cap E_2 \cap E_3) = \mathbb{P}(E_1|E_2 \cap E_3) \cdot \mathbb{P}(E_2 \cap E_3) = \mathbb{P}(E_1|E_2 \cap E_3) \cdot \mathbb{P}(E_2|E_3) \cdot \mathbb{P}(E_3)$$

Per un generico numero n di eventi $E_1, E_2, \ldots, E_n$, la regola del prodotto si generalizza nella seguente formula per l'intersezione:

$$\mathbb{P}(E_1 \cap E_2 \cap \cdots \cap E_n) = \mathbb{P}(E_1) \cdot \mathbb{P}(E_2|E_1) \cdot \mathbb{P}(E_3|E_1 \cap E_2) \cdots \mathbb{P}\left(E_n \,\middle|\, \bigcap_{j=1}^{n-1} E_j\right)$$

In forma compatta tramite il simbolo di produttoria:

$$\mathbb{P}\left(\bigcap_{i=1}^{n} E_i\right) = \prod_{i=1}^{n} \mathbb{P}\left(E_i \,\middle|\, \bigcap_{j=1}^{i-1} E_j\right)$$

(assumendo per $i = 1$ la probabilità non condizionata $\mathbb{P}(E_1)$).

Teorema 6.1 (Teorema di Bayes)**.** *Eguagliando $\mathbb{P}(E \cap F) = \mathbb{P}(E|F)\mathbb{P}(F)$ con $\mathbb{P}(F \cap E) = \mathbb{P}(F|E)\mathbb{P}(E)$, otteniamo la formula cardine dell'inferenza statistica:*

$$\mathbb{P}(F|E) = \frac{\mathbb{P}(E|F)\mathbb{P}(F)}{\mathbb{P}(E)}$$

Se consideriamo un evento B e una successione di eventi $\{A_i\}_i$ che formano una partizione di Ω ($\bigcup_{i=1}^{\infty} A_i = \Omega \quad con \quad A_i \cap A_j = \emptyset \; \forall i \neq j \quad e \quad \mathbb{P}(A_i) > 0 \; \forall i$), possiamo scrivere $\mathbb{P}(B)$ tramite la legge delle probabilità totali:

$$\mathbb{P}(B) = \sum_{i=1}^{\infty} \mathbb{P}(B \cap A_i) = \sum_{i=1}^{\infty} \mathbb{P}(B|A_i)\mathbb{P}(A_i)$$

Sostituendo nel Teorema di Bayes, otteniamo la sua formulazione estesa per partizioni:

$$\forall i, \; \mathbb{P}(A_i|B) = \frac{\mathbb{P}(A_i \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(B|A_i)\mathbb{P}(A_i)}{\sum_{n\geq 1} \mathbb{P}(B|A_n)\mathbb{P}(A_n)}$$

Esempio: Il paradosso del falso positivo

Un paziente presenta sintomi di una malattia nota. Sappiamo che l'incidenza della malattia nella popolazione è $\mathbb{P}(M) = \frac{1}{100.000}$. Sappiamo anche che la probabilità che una persona sana sviluppi gli stessi sintomi è $\mathbb{P}(S|M^c) = \frac{10}{99.999}$. Si assume inoltre che una persona malata presenti sempre i sintomi, quindi $\mathbb{P}(S|M) = 1$.
Qual è la probabilità che la persona sia effettivamente malata dato che ha i sintomi, ovvero $\mathbb{P}(M|S)$? Applicando Bayes e le probabilità totali:

$$\mathbb{P}(M|S) = \frac{\mathbb{P}(M \cap S)}{\mathbb{P}(S)} = \frac{\mathbb{P}(S|M)\mathbb{P}(M)}{\mathbb{P}(S \cap M) + \mathbb{P}(S \cap M^c)}$$

$$= \frac{\mathbb{P}(M)}{\mathbb{P}(M) + \mathbb{P}(S|M^c)\mathbb{P}(M^c)} = \frac{1}{11} \approx 9\%$$

Nonostante i sintomi, la probabilità di essere malati è solo di circa 1 su 11 a causa della bassissima incidenza di base.

Un'ultima osservazione fondamentale: la misura di probabilità condizionata $\mathbb{P}(\cdot|F)$ agisce come una misura di probabilità a tutti gli effetti. Essa soddisfa gli assiomi di Kolmogorov, infatti $\forall F \subseteq \Omega : \mathbb{P}(F) > 0$ si ha:

- $\mathbb{P}(\Omega|F) = \frac{\mathbb{P}(\Omega \cap F)}{\mathbb{P}(F)} = 1$
- $\forall E \subseteq \Omega$, $\mathbb{P}(E|F) \in [0, 1]$
- Se $\{E_i\}_i$ sono eventi a due a due disgiunti, $\mathbb{P}\left(\bigcup_{i=1}^{n} E_i|F\right) = \sum_{i=1}^{n} \mathbb{P}(E_i|F)$

7 Indipendenza e Prove di Bernoulli

Definizione 7.1. Siano $A, B \subset \Omega$. Gli eventi si dicono **indipendenti** se la probabilità della loro intersezione è il prodotto delle singole probabilità:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$$

Questa definizione si estende a un insieme di eventi $A_1, A_2, A_3 \subset \Omega$, i quali sono indipendenti se la regola del prodotto vale per *tutte* le possibili combinazioni e sotto-intersezioni (bisogna verificarle tutte, altrimenti è un errore concettuale):

- $\mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_1)\mathbb{P}(A_2)\mathbb{P}(A_3)$
- $\mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1)\mathbb{P}(A_2)$
- $\mathbb{P}(A_1 \cap A_3) = \mathbb{P}(A_1)\mathbb{P}(A_3)$
- $\mathbb{P}(A_2 \cap A_3) = \mathbb{P}(A_2)\mathbb{P}(A_3)$

Esempio: Successione di prove indipendenti (Bernoulli)

Consideriamo una successione infinita di prove indipendenti. Per ogni prova, definiamo la probabilità di successo come $p \in [0, 1]$ e la probabilità di insuccesso come $1 - p$.
a) Qual è la probabilità che ci sia almeno un successo nelle prime n prove?
Sia $E = \{$c'è almeno un successo$\}$. Passando al complementare, $E^c = \{$le prime n prove sono insuccessi$\}$. Se definiamo F_i come l'evento "la prova i-esima è un successo" e F_i^c il corrispondente insuccesso, sfruttando l'indipendenza calcoliamo:

$$\mathbb{P}(E^c) = \mathbb{P}\left(\bigcap_{i=1}^{n} F_i^c\right) = (1-p)^n$$

Pertanto, $\mathbb{P}(E) = 1 - (1-p)^n$. Se le prove non fossero state indipendenti, non avremmo potuto trattare l'intersezione in questo modo diretto.
b) Probabilità di avere esattamente k successi in n prove.
Consideriamo una stringa specifica di n caratteri composta da k successi (indicati con 1) e $n - k$ insuccessi (indicati con 0). La probabilità di *tale singola stringa* è:

$$\mathbb{P}(\text{stringa}) = p^k(1-p)^{n-k} = \mathbb{P}(F_1 \cap \cdots \cap F_k \cap F_{k+1}^c \cap \cdots \cap F_n^c) = \prod_{i=1}^{k} \mathbb{P}(F_i) \prod_{j=k+1}^{n} \mathbb{P}(F_j^c)$$

Moltiplicando questo valore per tutti i modi possibili di disporre i k successi tra gli n posti (il coefficiente binomiale), otteniamo la distribuzione binomiale:

$$\mathbb{P}(E_b) = \binom{n}{k} p^k (1-p)^{n-k}$$

c) Probabilità che tutte le infinite prove siano successi.
Vogliamo calcolare $\mathbb{P}(\bigcap_{i=1}^{\infty} F_i) = \mathbb{P}(\lim_{n\to\infty} \bigcap_{i=1}^{n} F_i)$. Poiché la successione nel limite è decrescente ($\bigcap_{i=1}^{n+1} F_i \subseteq \bigcap_{i=1}^{n} F_i$), applichiamo il teorema di continuità della probabilità visto in precedenza:

$$\mathbb{P}\left(\bigcap_{i=1}^{\infty} F_i\right) = \lim_{n\to\infty} \mathbb{P}\left(\bigcap_{i=1}^{n} F_i\right) = \lim_{n\to\infty} \prod_{i=1}^{n} \mathbb{P}(F_i) = \lim_{n\to\infty} p^n$$

Questo limite restituisce 1 se $p = 1$, oppure 0 altrimenti.

8 Variabili Aleatorie

Nel momento in cui vogliamo analizzare matematicamente un esperimento casuale, abbiamo bisogno di tradurre gli eventi (spesso descritti a parole o concetti astratti) in numeri. Questo è esattamente il ruolo della variabile aleatoria.

Definizione 8.1 (Variabile Aleatoria)**.** Una variabile aleatoria X è formalmente una funzione misurabile che associa ad ogni possibile esito di un esperimento (appartenente allo spazio campionario Ω) un numero reale. In simboli:

$$X : \Omega \to \mathbb{R}$$

Una variabile aleatoria si dice **discreta** se l'insieme dei valori che può assumere è al più numerabile. Quando lavoriamo con una variabile aleatoria discreta X, il modo più naturale per descriverne il comportamento è la sua *densità discreta* (o funzione di massa di probabilità), che associa ad ogni valore la probabilità che esso si verifichi:

$$\mathbb{P}(x) = \mathbb{P}(X = x) \quad \text{con } x \in \mathbb{R}$$

Chiamando x_i i valori possibili di X, questa densità deve rispettare due regole fondamentali per essere coerente con gli assiomi della probabilità:

- La probabilità non è mai negativa: $\mathbb{P}(x_i) \geq 0$
- La somma delle probabilità di tutti gli eventi possibili è l'evento certo: $\sum_i \mathbb{P}(x_i) = 1$

9 La Funzione di Distribuzione

Spesso non siamo interessati solo alla probabilità di un singolo valore, ma alla probabilità che la variabile assuma un valore *fino* ad una certa soglia.

Definizione 9.1 (Funzione di Distribuzione)**.** Si definisce funzione di distribuzione (o di ripartizione) cumulativa di una variabile aleatoria X la funzione:

$$F_X(x) = \mathbb{P}(X \leq x)$$

Se X è una variabile aleatoria discreta, il grafico di $F_X(x)$ assume la tipica forma a **gradini**, in corrispondenza dei valori in cui la probabilità è concentrata. La funzione di distribuzione gode di alcune proprietà matematiche molto importanti:

i) $F_X(x)$ è una funzione *non decrescente* rispetto a x.

ii) I suoi limiti all'infinito rappresentano l'impossibilità e la certezza:

$$\lim_{x \to -\infty} F_X(x) = 0 \quad e \quad \lim_{x \to \infty} F_X(x) = 1$$

iii) È una funzione *continua a destra*:

$$\lim_{y \searrow x} F_X(y) = F_X(x)$$

Se vogliamo ritrovare la probabilità di un singolo punto partendo dalla funzione di distribuzione, possiamo definire il limite da sinistra $F_X(x^-) = \lim_{x_m \nearrow x} F_X(x_m)$. Sottraendo questo valore al valore in x, otteniamo esattamente l'altezza del "salto" nel gradino, ovvero la probabilità puntuale:

$$\mathbb{P}(X = x) = \mathbb{P}(X \leq x) - \mathbb{P}(X < x) = F_X(x) - F_X(x^-)$$

Nel caso di variabili aleatorie continue questo valore sarà chiaramente zero, in quanto la misura di Lebesgue di un singolo punto è nulla.

10 Valore Atteso e Varianza

Per riassumere il comportamento di una variabile aleatoria, si utilizzano degli indici sintetici. Il più noto è il **Valore Atteso**, che rappresenta il "baricentro" della distribuzione, ovvero il valore medio che ci aspetteremmo se ripetessimo l'esperimento infinite volte.

Nel caso discreto, il valore atteso è calcolato come la media pesata di tutti i valori possibili, in cui i pesi sono le rispettive probabilità:

$$\mathbb{E}[X] = \sum_{x:\mathbb{P}(x)>0} x \cdot \mathbb{P}(X = x)$$

10.1 La Funzione Indicatrice

Uno strumento estremamente utile nel calcolo probabilistico è la funzione indicatrice. Per un qualsiasi evento $A \subseteq \Omega$, l'indicatrice "accende" o "spegne" il valore a seconda che l'evento si verifichi o meno:

$$\mathbb{1}_A = \begin{cases} 1 & \text{se } A \text{ si realizza} \\ 0 & \text{altrimenti} \end{cases}$$

Analogamente, definita sui singoli esiti ω:

$$\mathbb{1}_A(\omega) = \begin{cases} 1 & \text{se } \omega \in A \\ 0 & \text{se } \omega \notin A \end{cases}$$

Essendo a tutti gli effetti una variabile aleatoria, possiamo calcolarne il valore atteso. Eseguendo il calcolo, scopriamo un risultato molto elegante: il valore atteso dell'indicatrice di un evento coincide con la probabilità dell'evento stesso:

$$\mathbb{E}[\mathbb{1}_A] = 1 \cdot \mathbb{P}(A) + 0 \cdot \mathbb{P}(A^c) = \mathbb{P}(A)$$

10.2 Trasformazioni e Linearità

Se applichiamo una funzione $g : \mathbb{R} \to \mathbb{R}$ alla nostra variabile X, otteniamo una nuova variabile aleatoria $g(X)$, composta formalmente come $g \circ X : \Omega \to \mathbb{R} \to \mathbb{R}$. Il suo valore atteso è il seguente:

$$\mathbb{E}[g(X)] = \sum_{x:\mathbb{P}(x)>0} g(x) \cdot \mathbb{P}(x)$$

Una delle **proprietà** del valore atteso è la sua **linearità**. Per qualsiasi costante a e b:

$$\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$$

10.3 La Varianza

Mentre il valore atteso ci indica il centro della distribuzione, la **Varianza** misura il grado di dispersione, ovvero quanto i valori si allontanano mediamente dal centro.

Definizione 10.1 (Varianza)**.** La varianza di una variabile aleatoria X è definita come il valore atteso degli scarti quadratici dalla media:

$$Var(X) = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

A differenza del valore atteso, la varianza non è un operatore lineare. Infatti, date due costanti $a, b \in \mathbb{R}$, vale la relazione:

$$Var(aX + b) = a^2 Var(X)$$

Il termine b scompare (aggiungere una costante trasla la distribuzione ma non ne cambia la dispersione), mentre il termine a viene elevato al quadrato.

11 Distribuzioni Discrete Notevoli

Nella pratica statistica, molte situazioni reali ricadono in categorie predefinite. Di seguito analizziamo i modelli di distribuzioni discrete più celebri.

11.1 La distribuzione di Bernoulli

Modella un esperimento con soli due esiti possibili (es. successo/fallimento, testa/croce). È definita da un singolo parametro $p \in [0, 1]$. Se $X \sim \text{Bern}(p)$, si ha:

$$\mathbb{P}(X = 1) = p$$
$$\mathbb{P}(X = 0) = 1 - p$$

Di conseguenza $\mathbb{E}[X] = p$ e $Var(X) = p(1 - p)$.

11.2 La distribuzione Binomiale

Rappresenta il numero di successi ottenuti su n tentativi indipendenti, ciascuno con probabilità di successo p. È la somma di n variabili di Bernoulli indipendenti. Con $n \geq 1$ e $p \in [0, 1]$, se $X \sim \text{Bin}(n, p)$, allora:

$$\forall k \in \{0, \dots, n\}, \quad \mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

I suoi momenti principali sono:

- $\mathbb{E}[\text{Bin}(n, p)] = n \cdot p$
- $Var[\text{Bin}(n, p)] = n \cdot p(1 - p)$

11.3 La distribuzione di Poisson

Viene tipicamente usata per modellare il numero di eventi "rari" che si verificano in un fissato intervallo di tempo o spazio. Salta fuori matematicamente come il limite di una distribuzione Binomiale quando n tende all'infinito e p tende a zero.

Dipende da un parametro di tasso $\lambda > 0$. Se $X \sim \text{Poi}(\lambda)$:

$$\forall k \in \{0, 1, \dots\}, \quad \mathbb{P}(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

Una particolarità elegante della distribuzione di Poisson è che valore atteso e varianza coincidono:

$$\mathbb{E}[\text{Poi}(\lambda)] = \lambda \quad , \quad Var(\text{Poi}(\lambda)) = \lambda$$

11.4 La distribuzione Geometrica

Risponde alla domanda: *"Quanti tentativi ci vogliono prima di ottenere il primo successo?"* Se ogni tentativo ha probabilità di successo p, la probabilità che il primo successo avvenga esattamente al tentativo n-esimo è:

$$\mathbb{P}(X = n) = (1 - p)^{n-1} p$$

I suoi momenti sono:

$$\mathbb{E}(\text{Geom}(p)) = \frac{1}{p} \quad e \quad Var(\text{Geom}(p)) = \frac{1 - p}{p^2}$$

11.5 La Distribuzione Binomiale Negativa

La distribuzione Binomiale Negativa modella il numero di prove necessarie per ottenere un numero prefissato di successi in una sequenza di prove indipendenti.

Definizione 11.1 (Distribuzione Binomiale Negativa)**.** Sia data una successione di prove bernoulliane indipendenti, ciascuna con probabilità di successo $p \in (0,1)$. Definiamo la variabile aleatoria X come il numero totali di prove necessarie per ottenere il k-esimo successo:

$$X := \#\text{ prove necessarie per ottenere il } k\text{-esimo successo.}$$

Diremo che $X \sim \text{BinNegativa}(k,p)$.

La funzione di massa di probabilità (PMF) per ogni valore $m \geq k$ è data da:

$$\mathbb{P}(X=m) = \binom{m-1}{k-1} p^k (1-p)^{m-k}, \quad \forall m \geq k. \tag{1}$$

Interpretazione combinatoria: Affinché il k-esimo successo si verifichi esattamente alla prova m-esima, è necessario che nelle prime $m-1$ prove si siano verificati esattamente $k-1$ successi (in qualsiasi ordine, espresso dal coefficiente binomiale $\binom{m-1}{k-1}$), e che l'm-esima prova sia deterministica ed equivalga ad un successo (con probabilità p).

I primi due momenti della distribuzione sono forniti dalla seguente proposizione.

Proposizione 11.1. *Se $X \sim$ BinNegativa(k,p), il valore atteso e la varianza di X sono rispettivamente:*

$$\mathbb{E}[X] = \frac{k}{p}, \qquad \mathit{Var}[X] = k\frac{1-p}{p^2}.$$

Si noti come valore atteso e varianza siano esattamente pari a k volte quelli di una distribuzione Geometrica, riflesso del fatto che la Binomiale Negativa può essere vista come la somma di k variabili aleatorie geometriche indipendenti ed identicamente distribuite.

11.6 La Distribuzione Ipergeometrica

A differenza del modello binomiale, la distribuzione Ipergeometrica descrive processi di campionamento **senza reinserimento** da una popolazione finita.

Definizione 11.2 (Distribuzione Ipergeometrica)**.** Si consideri un'urna contenente N palline totali, di cui m bianche e $N-m$ nere. Estraendo n palline senza reinserimento dall'urna, definiamo la variabile aleatoria X come:

$$X := \#\text{ palline bianche tra le } n \text{ estratte.}$$

La probabilità di osservare esattamente i palline bianche (con $i \leq \min(n,m)$) è:

$$\mathbb{P}(X=i) = \frac{\binom{m}{i}\binom{N-m}{n-i}}{\binom{N}{n}}, \quad \forall i \in \{0,1,\ldots,n\}. \tag{2}$$

La formula si ricava mediante il classico rapporto tra casi favorevoli e casi possibili:

$$\mathbb{P}(X=i) = \frac{\overbrace{\binom{m}{i}}^{\text{scelta delle } i \text{ bianche}} \quad \overbrace{\binom{N-m}{n-i}}^{\text{scelta delle } n-i \text{ nere}}}{\underbrace{\binom{N}{n}}_{\text{tutti i casi possibili}}}.$$

12 Distribuzioni Continue e Densità di Probabilità

Passando al continuo, la trattazione probabilistica richiede strumenti dell'analisi reale e della teoria dell'integrazione secondo Lebesgue.

Definizione 12.1 (Variabile Aleatoria Continua)**.** Una variabile aleatoria X è detta **continua** se esiste una funzione $f_X : \mathbb{R} \to [0, +\infty)$ integrabile secondo Lebesgue tale che, per ogni sottoinsieme misurabile $B \subseteq \mathbb{R}$, si ha:

$$\mathbb{P}(X \in B) = \int_B f_X(x)\, dx.$$

Equivalentemente, considerando l'evento in termini di spazio campionario Ω:

$$\mathbb{P}(\{\omega \in \Omega : X(\omega) \in B\}) = \int_B f_X(x)\, dx.$$

La funzione f_X prende il nome di **densità di probabilità** di X.

12.1 Proprietà Fondamentali

Dalla definizione derivano immediatamente le seguenti proprietà chiave:

1. **Normalizzazione**: Ponendo $B = \mathbb{R}$, si ha l'assioma di certezza:

$$\mathbb{P}(X \in \mathbb{R}) = \int_{\mathbb{R}} f_X(x)\, dx = 1.$$

2. **Probabilità su intervalli**: Per qualsiasi intervallo $(a, b) \subset \mathbb{R}$:

$$\mathbb{P}(X \in (a, b)) = \int_a^b f_X(x)\, dx = \mathbb{P}(X \in [a, b]).$$

   infatti i singoli punti hanno misura nulla (Lebesgue).

3. **Misura singola di punto**: Se $a = b$, si ottiene:

$$\mathbb{P}(X \in \{a\}) = \int_a^a f_X(x)\, dx = 0, \quad \forall a \in \mathbb{R}.$$

Proposizione 12.1 (Proprietà fondamentale delle v.a. continue)**.** *Se X è una variabile aleatoria continua, la probabilità assumere un qualunque valore puntuale è nulla:*

$$\forall x \in \mathbb{R}, \quad \mathbb{P}(X = x) = 0.$$

Al contrario, se Y è una variabile aleatoria discreta, esiste un insieme al più numerabile di punti per cui $\mathbb{P}(Y = y) > 0$.

12.2 Funzione di Ripartizione e Derivazione

La funzione di ripartizione $F_X(x)$ (o CDF) di una v.a. continua rappresenta la probabilità cumulata fino al punto x:

$$F_X(x) := \mathbb{P}(X \leq x) = \mathbb{P}(X < x) = \int_{-\infty}^x f_X(t)\, dt.$$

Per il Teorema Fondamentale del Calcolo Integrale, nei punti in cui f_X è continua la densità si ottiene derivando la funzione di ripartizione:

$$f_X(x) = \frac{d}{dx} F_X(x).$$

Esempio: Trasformazione di una variabile aleatoria continua

Sia X una v.a. continua con funzione di ripartizione F_X e densità f_X. Si consideri la nuova variabile aleatoria trasformata $Y := 2X$. Vogliamo determinare la densità di probabilità $f_Y(y)$.
Svolgimento: Calcoliamo dapprima la funzione di ripartizione di Y:

$$\forall y \in \mathbb{R}, \quad F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(2X \leq y) = \mathbb{P}\left(X \leq \frac{y}{2}\right) = F_X\left(\frac{y}{2}\right).$$

Derivando rispetto a y mediante la regola di derivazione delle funzioni composte, otteniamo la densità $f_Y(y)$:

$$f_Y(y) = \frac{d}{dy} F_Y(y) = \frac{d}{dy}\left[F_X\left(\frac{y}{2}\right)\right] = \frac{1}{2} f_X\left(\frac{y}{2}\right).$$

13 Momenti e Calcolo dell'Aspettativa

13.1 Valore Atteso e Varianza

Per una variabile aleatoria continua X con densità f_X, il valore atteso (o media) e la varianza si definiscono nel modo seguente:

$$\mathbb{E}[X] := \int_{\mathbb{R}} x \cdot f_X(x)\, dx,$$

$$\mathrm{Var}[X] := \int_{\mathbb{R}} (x - \mathbb{E}[X])^2 f_X(x)\, dx.$$

Se $g : \mathbb{R} \to \mathbb{R}$ è una funzione $\mathcal{B}$-misurabile e integrabile, allora il valore atteso della v.a. trasformata $g(X)$ è:

$$\mathbb{E}[g(X)] = \int_{\mathbb{R}} g(x) \cdot f_X(x)\, dx.$$

13.2 Calcolo dell'Aspettativa tramite la Funzione di Sopravvivenza

Un risultato teorico di notevole eleganza e utilità pratica permette di esprimere il valore atteso di una variabile non negativa integrando direttamente la sua funzione di sopravvivenza $\mathbb{P}(Y > t)$.

Teorema 13.1 (Lemma del Valore Atteso per v.a. non negative)**.** *Se Y è una variabile aleatoria continua non negativa ($Y \geq 0$), allora:*

$$\mathbb{E}[Y] = \int_0^{+\infty} \mathbb{P}(Y > t)\, dt.$$

Dimostrazione. Sostituendo la definizione della probabilità dell'evento coda $\{Y > t\}$ tramite l'integrale della densità f_Y, abbiamo:

$$\int_0^{+\infty} \mathbb{P}(Y > t)\, dt = \int_0^{+\infty} \left(\int_t^{+\infty} f_Y(y)\, dy \right) dt.$$

Il dominio di integrazione nel piano (t, y) è descritto dal sistema di disequazioni $0 < t < y < +\infty$. Applicando il **Teorema di Fubini-Tonelli** per scambiare l'ordine di integrazione, si ottiene:

$$\int_0^{+\infty} \left(\int_t^{+\infty} f_Y(y)\, dy \right) dt = \int_0^{+\infty} f_Y(y) \left(\int_0^{y} dt \right) dy = \int_0^{+\infty} y \cdot f_Y(y)\, dy = \mathbb{E}[Y],$$

dove l'integrale esterno parte da 0 in virtù del fatto che $Y \geq 0$. Vediamo che la variabile aleatoria non fosse a valori positivi, la tesi verrebbe meno, perché quest'ultimo passaggio non darebbe lo stesso risultato. □

14 Modelli Continui Notevoli

14.1 La Distribuzione Uniforme

La distribuzione Uniforme descrive una variabile la cui probabilità è distribuita in modo omogeneo su un intervallo limitato.

Definizione 14.1 (Distribuzione Uniforme Standard e Generale)**.** Una v.a. X ha distribuzione Uniforme sull'intervallo $[0, 1]$, denotata $X \sim \text{Unif}([0, 1])$, se la sua densità è:

$$f_X(x) = \begin{cases} 1 & \text{se } x \in [0, 1] \text{ (o } (0, 1)) \\ 0 & \text{altrimenti.} \end{cases}$$

Più in generale, per un intervallo arbitrario $(a, b) \subset \mathbb{R}$ con $a < b$, si scrive $X \sim \text{Unif}(a, b)$ se la densità vale:

$$f_X(x) = \begin{cases} \frac{1}{b-a} & \text{se } x \in (a, b) \\ 0 & \text{altrimenti.} \end{cases}$$

Per ogni sottointervallo $(c, d) \subseteq (a, b)$, la probabilità associata dipende unicamente dalla sua lunghezza relativa:

$$\mathbb{P}(X \in (c, d)) = \frac{d - c}{b - a}.$$

La funzione di ripartizione $F_X(x)$ assume la forma lineare a tratti:

$$F_X(x) = \begin{cases} 0 & \text{se } x \leq a \\ \frac{x-a}{b-a} & \text{se } x \in (a, b) \\ 1 & \text{se } x \geq b. \end{cases}$$

14.2 La Distribuzione Normale (Gaussiana)

La distribuzione Normale è indubbiamente la più celebre e rilevante dell'intera teoria della probabilità.

Definizione 14.2 (Distribuzione Normale)**.** Una variabile aleatoria continua X ha distribuzione Normale (o Gaussiana) con parametri $\mu \in \mathbb{R}$ e $\sigma^2 > 0$, indicata con $X \sim \mathcal{N}(\mu, \sigma^2)$, se la sua densità di probabilità è data da:

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}}\, e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad \forall x \in \mathbb{R}. \tag{3}$$

In tal caso si dimostra che $\mathbb{E}[X] = \mu$ e $\text{Var}(X) = \sigma^2$.

Caso Standard: Quando $\mu = 0$ e $\sigma^2 = 1$, la variabile $Z \sim \mathcal{N}(0,1)$ è detta **Normale Standard**. La sua funzione di ripartizione viene storicamente indicata con la lettera greca maiuscola $\Phi(x)$:

$$\Phi(x) := \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}\, dt = \mathbb{P}(Z \leq x).$$

Sfruttando la simmetria della densità gaussiana rispetto all'origine, valgono le identità di simmetria:

$$\Phi(-z) = \mathbb{P}(Z \leq -z) = \mathbb{P}(Z > z) = 1 - \Phi(z).$$

Si nota inoltre che $\mathbb{P}(|Z| > z) = 2\Phi(-z) = 2(1 - \Phi(z))$.

15 Approssimazione Normale e Teorema di De Moivre-Laplace

Il Teorema di De Moivre-Laplace costituisce un caso speciale del Teorema del Limite Centrale, fornendo una giustificazione teorica all'impiego della distribuzione normale per approssimare somme di variabili bernoulliane.

Teorema 15.1 (De Moivre-Laplace)**.** *Sia $S_n \sim Bin(n,p)$ la somma di n variabili casuali bernoulliane indipendenti e identicamente distribuite, con probabilità di successo $p \in (0,1)$. Allora, per ogni $a, b \in \mathbb{R}$ con $a < b$:*

$$\lim_{n\to\infty} \mathbb{P}\left[\frac{S_n - np}{\sqrt{np(1-p)}} \in (a,b)\right] = \mathbb{P}(a < Z < b) = \Phi(b) - \Phi(a),$$

dove $Z \sim \mathcal{N}(0,1)$.

L'approssimazione risulta eccellente nella pratica già per $n > 30$, a condizione che p non sia troppo prossimo a 0 o 1.

Esempio: Applicazione e Correzione di Continuità

Supponiamo che per una prova d'ammissione universitaria il numero di posti disponibili sia tarato su un campione ideale di studenti $n = 450$ con probabilità di ammissione $p = 0.3$. Vogliamo stimare la probabilità che il test venga superato da più di 150 candidati.

Modellizzazione: La variabile $X \sim \text{Bin}(n = 450, p = 0.3)$ misura il numero di promossi. I momenti della distribuzione sono:

$$\mu = np = 450 \cdot 0.3 = 135, \qquad \sigma^2 = np(1-p) = 450 \cdot 0.3 \cdot 0.7 = 94.5.$$

Desideriamo calcolare $\mathbb{P}(X > 150)$. Questa si potrebbe calcolare usando direttamente la binomiale, tuttavia sarebbe una somma molto laboriosa.

La Correzione di Continuità: Essendo X una variabile discreta, per ogni intero k si ha $\mathbb{P}(k < X < k+1) = 0$, cosa non vera per le variabili continue. Nell'approssimare una variabile discreta tramite una variabile continua normale, si applica la *correzione di continuità* correlando il punto discreto 150 all'intervallo continuo $[150, 150.5]$. Pertanto, l'evento $X > 150$ (ossia $X \geq 151$) si converte in:

$$\mathbb{P}(X > 150) = \mathbb{P}(X \geq 150.5).$$

Standardizzando la variabile:

$$\mathbb{P}\left(\frac{X - 135}{\sqrt{94.5}} \geq \frac{150.5 - 135}{\sqrt{94.5}}\right) = \mathbb{P}\left(\frac{X - 135}{\sqrt{94.5}} \geq \frac{15.5}{9.72}\right) \approx \mathbb{P}(Z \geq 1.59).$$

In termini della funzione Φ:

$$\mathbb{P}(Z > 1.59) = 1 - \Phi(1.59) \approx 1 - 0.9441 = 0.0559 \quad (5.59\%).$$

Il calcolo viene poi rifinito consultando direttamente le tavole della Normale Standard.

Esempio: Il problema delle due monete

Supponiamo di avere due monete: una perfettamente **equa** e una **truccata**. Sappiamo che la moneta truccata ha una probabilità di far uscire "testa" pari a:

$$\mathbb{P}(\text{testa}) = 0.55$$

Scegliamo una moneta a caso e la lanciamo 1000 volte. La nostra regola di decisione (il nostro test) è la seguente: se il numero di teste ottenute è minore o uguale a 525, allora dichiariamo che la moneta selezionata è quella equa.
A questo punto sorge spontanea una domanda: *supponendo di aver effettivamente scelto la moneta equa, qual è la probabilità di giungere alla conclusione errata?*
Per rispondere, formalizziamo il problema. Sia N la variabile aleatoria che conta il numero di teste in 1000 lanci. Chiaramente, N segue una distribuzione Binomiale:

$$N \sim \text{Bin}(1000, p) \quad \text{con} \quad p = \begin{cases} 0.5 & \text{se la moneta è equa} \\ 0.55 & \text{se la moneta è truccata} \end{cases}$$

Vogliamo calcolare la probabilità di sbagliare sapendo che la moneta è equa, ovvero la probabilità che il nostro test ci dica che è truccata ($N > 525$) quando in realtà non lo è. Sfruttando l'approssimazione normale alla binomiale per n grande:

$$\begin{aligned} \mathbb{P}(\text{conclusione errata} \mid \text{moneta equa}) &= \mathbb{P}\left(N > 525 \;\middle|\; N \sim \text{Bin}\left(1000, \frac{1}{2}\right)\right) \\ &= \mathbb{P}\left(\frac{N - np}{\sqrt{np(1-p)}} \geq 1.61\right) \approx 0.053 \end{aligned}$$

Abbiamo quindi circa il 5.3% di probabilità di rifiutare scorrettamente l'ipotesi che la moneta sia equa.

16 Distribuzioni Continue Notevoli

Passiamo ora a rassegna alcune delle distribuzioni continue più importanti in teoria della probabilità, esplorandone le densità, le proprietà fondamentali e i collegamenti tra di esse.

16.1 La Distribuzione Esponenziale

La distribuzione esponenziale è ampiamente utilizzata per modellare i tempi di attesa o la durata di vita di un componente.

Definizione 16.1 (Distribuzione Esponenziale)**.** Sia $\lambda > 0$ un parametro detto *tasso*. Si dice che una variabile aleatoria X segue una distribuzione esponenziale, e si indica con $X \sim \text{Exp}(\lambda)$, se la sua funzione di densità di probabilità (PDF) è data da:

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x} & \text{se } x \geq 0 \\ 0 & \text{altrimenti} \end{cases}$$

Integrando la densità, si ottiene facilmente la Funzione di Ripartizione (CDF):

$$F_X(x) = \mathbb{P}(X \leq x) = \begin{cases} 0 & \text{se } x < 0 \\ 1 - e^{-\lambda x} & \text{se } x \geq 0 \end{cases}$$

I momenti principali della distribuzione sono il valore atteso $\mathbb{E}[X] = \frac{1}{\lambda}$ e la varianza $\mathrm{Var}(X) = \frac{1}{\lambda^2}$.

Nota sulla notazione: In molti testi di statistica si preferisce parametrizzare la distribuzione esponenziale utilizzando la media $\theta = \mathbb{E}[X]$. In tal caso, si scrive $X \sim \mathrm{Exp}(\theta)$ e la densità diventa $f_X(x) = \frac{1}{\theta} e^{-x/\theta}$ per $x \geq 0$.

La Proprietà di Assenza di Memoria

Una proprietà della distribuzione esponenziale è la cosiddetta **perdita di memoria**. Matematicamente, per ogni $s, t > 0$, vale:

$$\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t)$$

Questa proprietà si dimostra facilmente applicando la definizione di probabilità condizionata:

$$\frac{\mathbb{P}(\{X > s+t\} \cap \{X > s\})}{\mathbb{P}(X > s)} = \frac{\mathbb{P}(X > s+t)}{\mathbb{P}(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = \mathbb{P}(X > t)$$

Anche la distribuzione Geometrica (per $X \sim \mathrm{Geom}(p)$ con $p \in (0, 1)$) gode della proprietà di perdita di memoria nel caso discreto ($\forall s, t > 0$).

Esempio: L'ufficio postale

Il signor A entra in un ufficio postale. Ci sono due sportelli, ed entrambi sono attualmente occupati dai clienti B e C. A accederà al primo sportello che si libera. Supponiamo che il tempo di servizio per ogni cliente segua una distribuzione esponenziale $T \sim \mathrm{Exp}(\lambda)$.
Qual è la probabilità che A sia l'ultimo ad uscire dall'ufficio?
Senza perdita di generalità, supponiamo che B finisca prima e vada via, liberando il posto per A. Siano T_A il tempo di servizio per A e T_C il tempo di servizio per C. Per la perdita di memoria, il tempo che C deve ancora trascorrere allo sportello dal momento in cui A inizia il suo servizio è indipendente dal tempo già trascorso, e segue anch'esso una $\mathrm{Exp}(\lambda)$. Pertanto, vogliamo calcolare:

$$\mathbb{P}(T_C > s + t \mid T_C > s) = \mathbb{P}(T_C > t) = \mathbb{P}(T_A > t)$$

Più esplicitamente, impostando il calcolo con gli integrali, la probabilità che il tempo di A sia maggiore di quello di C è:

$$\mathbb{P}(T_A > T_C) = \int_0^{+\infty} da \int_0^a dc\, (\lambda e^{-\lambda c}) \cdot (\lambda e^{-\lambda a}) = \frac{1}{2}$$

Per simmetria, abbiamo ovviamente $\mathbb{P}(T_A > T_C) = \mathbb{P}(T_C > T_A) = \frac{1}{2}$. In generale, se $X \sim \mathrm{Exp}(\lambda_1)$ e $Y \sim \mathrm{Exp}(\lambda_2)$, si può dimostrare che la probabilità che X sia maggiore di Y dipende solo dai rispettivi tassi:

$$\mathbb{P}(X > Y) = \frac{\lambda_2}{\lambda_1 + \lambda_2}$$

16.2 La Distribuzione Gamma

La distribuzione Gamma è una generalizzazione dell'esponenziale (che si ottiene ponendo $\alpha = 1$).

Definizione 16.2 (Distribuzione Gamma)**.** Siano $\alpha, \lambda > 0$. Una variabile aleatoria $X \sim \Gamma(\alpha, \lambda)$ se la sua funzione di densità è:

$$f_X(x) = \begin{cases} \frac{\lambda e^{-\lambda x} \cdot (\lambda x)^{\alpha - 1}}{\Gamma(\alpha)} & \text{se } x \geq 0 \\ 0 & \text{altrimenti} \end{cases}$$

Il termine a denominatore è la **funzione Gamma di Eulero**, definita dall'integrale:

$$\Gamma(\alpha) := \int_0^{+\infty} e^{-y} y^{\alpha-1} dy$$

Una proprietà fondamentale della funzione Gamma, ricavabile integrando per parti se $\alpha > 1$, è la relazione ricorsiva $\Gamma(\alpha) = (\alpha-1)\Gamma(\alpha-1)$. Ne consegue che se il parametro di forma è intero ($\alpha \in \mathbb{N} \setminus \{0\}$), la funzione Gamma coincide con il fattoriale: $\Gamma(\alpha) = (\alpha-1)!$.

16.3 La Distribuzione Beta

Mentre l'esponenziale e la Gamma sono definite sul semiasse positivo, la distribuzione Beta è il modello naturale per variabili limitate nell'intervallo $[0,1]$, come proporzioni o probabilità.

Definizione 16.3 (Distribuzione Beta)**.** Siano $\alpha, \beta > 0$. Una variabile aleatoria continua X distribuita tra $[0,1]$ segue una distribuzione Beta, indicata con $X \sim \text{Beta}(\alpha, \beta)$, se la sua densità è:

$$f_X(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{\int_0^1 u^{\alpha-1}(1-u)^{\beta-1} du} \quad \text{per } x \in [0,1]$$

Se $x \notin [0,1]$, allora $f_X(x) = 0$. Il denominatore funge da costante di normalizzazione.

17 Distribuzione di una Funzione di Variabile Aleatoria

Spesso in statistica, conoscendo la distribuzione di una variabile aleatoria X, ci si trova a dover determinare la distribuzione di una sua trasformazione $Y = g(X)$.

Esempio: Trasformazione di una Uniforme

Sia $X \sim \text{Unif}(0,1)$ e sia $Y := X^n$ (con $n > 0$). Vogliamo trovare la densità di Y. Il metodo più sicuro è partire dalla Funzione di Ripartizione (CDF) di Y:

$$F_Y(y) = \mathbb{P}(Y \le y) = \mathbb{P}(X^n \le y) = \mathbb{P}(X \le \sqrt[n]{y}) = F_X(\sqrt[n]{y})$$

Poiché X è uniforme in $(0,1)$, la sua CDF è semplicemente l'argomento stesso all'interno dell'intervallo. Dunque:

$$F_Y(y) = \begin{cases} 0 & \text{se } y < 0 \\ y^{1/n} & \text{se } 0 \le y < 1 \\ 1 & \text{se } y \ge 1 \end{cases}$$

Per trovare la funzione di densità $f_Y(y)$, deriviamo la CDF:

$$f_Y(y) = \frac{dF_Y(y)}{dy} = \begin{cases} \frac{1}{n} \cdot y^{\frac{1-n}{n}} & \text{se } 0 < y < 1 \\ 0 & \text{se } y \le 0 \text{ oppure } y \ge 1 \end{cases}$$

Questo procedimento "manuale" basato sulla CDF è sempre valido. Tuttavia, se la funzione di trasformazione gode di buone proprietà di regolarità, possiamo usare un risultato diretto:

Teorema 17.1. *Sia X una variabile aleatoria con densità f_X e sia $g : \mathbb{R} \to \mathbb{R}$ una funzione strettamente crescente (o strettamente decrescente) e derivabile con continuità. Allora la variabile aleatoria $Y = g(X)$ è continua e possiede densità:*

$$f_Y(y) = \begin{cases} f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right| & \text{se } y = g(x) \text{ per qualche } x \\ 0 & \text{altrimenti.} \end{cases}$$

18 La Distribuzione Chi-Quadro e la MGF

18.1 Distribuzione χ^2

La distribuzione Chi-Quadro è un pilastro della statistica inferenziale, fondamentale per la stima delle varianze e nei test di bontà dell'adattamento.

Definizione 18.1 (Distribuzione Chi-Quadro)**.** Data una successione di variabili aleatorie $\{Z_i\}_i$ indipendenti e tutte con distribuzione normale standard $\mathcal{N}(0,1)$, definiamo per ogni $k \in \{1, 2, 3, \dots\}$:

$$Z_1^2 + Z_2^2 + \cdots + Z_k^2 \sim \chi_k^2$$

Il parametro k rappresenta il numero di **gradi di libertà** della distribuzione.

Esiste un legame diretto e profondo tra la distribuzione χ^2 e la famiglia delle distribuzioni Gamma introdotte in precedenza. Si può infatti dimostrare che la distribuzione Chi-Quadro con k gradi di libertà è esattamente una Gamma con specifici parametri:

$$\chi_k^2 \stackrel{d}{=} \Gamma\left(\alpha = \frac{k}{2}, \lambda = \frac{1}{2}\right)$$

18.2 Funzione Generatrice dei Momenti (MGF)

Infine, accenniamo a uno strumento analitico potentissimo nello studio delle variabili aleatorie.

Definizione 18.2 (Funzione Generatrice dei Momenti)**.** Per ogni $t \in \mathbb{R}$, la Funzione Generatrice dei Momenti (MGF) di una variabile aleatoria X è definita come il valore atteso dell'esponenziale:

$$M_X(t) := \mathbb{E}[e^{tX}]$$

Questa funzione deve essere definita regolarmente; in altre parole, il valore atteso deve esistere (essere finito) in almeno un intorno di $t = 0$.

Il nome "generatrice dei momenti" non è casuale. Derivando la MGF k volte rispetto a t e valutando il risultato in $t = 0$, si ottiene esattamente il momento di ordine k della variabile X:

$$\left(\frac{d^k M_X(t)}{dt^k}\right)\Big|_{t=0} = \mathbb{E}[X^k] \quad \forall k$$

Oltre a generare agilmente i momenti, la MGF gode di una proprietà teorica fondamentale: il teorema di unicità. Se la Funzione Generatrice dei Momenti esiste, essa **caratterizza univocamente** la distribuzione della variabile aleatoria. Ovvero, date due variabili aleatorie X, Y, se accade che:

$$M_X(t) = M_Y(t)$$

allora le due variabili hanno identica funzione di ripartizione:

$$\Rightarrow F_X(x) = F_Y(x) \quad \forall x \in \mathbb{R}.$$

19 Covarianza

Nello studio delle probabilità, spesso ci troviamo ad analizzare il comportamento congiunto di due o più variabili aleatorie. Un indicatore fondamentale per capire se due variabili tendono a variare insieme (e in che direzione) è la covarianza.

Definizione 19.1 (Covarianza)**.** Siano X e Y due variabili aleatorie (v.a.) per le quali esistono i valori attesi. Si definisce *covarianza* tra X e Y la seguente quantità:

$$\mathrm{Cov}(X, Y) = \mathbb{E}\big[(X - \mathbb{E}[X]) \cdot (Y - \mathbb{E}[Y])\big] \tag{4}$$

Sfruttando la linearità del valore atteso, possiamo ricavare una formula operativa molto più comoda per il calcolo della covarianza. Sviluppando il prodotto all'interno del valore atteso otteniamo:

$$\begin{aligned}\mathrm{Cov}(X,Y) &= \mathbb{E}\big[XY - X\mathbb{E}[Y] - Y\mathbb{E}[X] + \mathbb{E}[X]\mathbb{E}[Y]\big] \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] - \mathbb{E}[Y]\mathbb{E}[X] + \mathbb{E}[X]\mathbb{E}[Y] \qquad \text{(per linearità)} \\ &= \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]\end{aligned}$$

Questa quantità gode di diverse proprietà strutturali che derivano direttamente dalla sua definizione.

Proposizione 19.1 (Proprietà della Covarianza)**.** *Siano X, Y, X_i, Y_j variabili aleatorie e $a \in \mathbb{R}$ una costante. Valgono le seguenti proprietà:*

1. ***Simmetria:*** $\mathrm{Cov}(X,Y) = \mathrm{Cov}(Y,X)$
2. ***Legame con la Varianza:*** $\mathrm{Cov}(X,X) = \mathrm{Var}(X)$
3. ***Omogeneità:*** $\mathrm{Cov}(aX,Y) = a\,\mathrm{Cov}(X,Y)$
4. ***Bilinearità:*** $\mathrm{Cov}\left(\sum_{i=1}^n X_i, \sum_{j=1}^m Y_j\right) = \sum_{i=1}^n \sum_{j=1}^m \mathrm{Cov}(X_i, Y_j)$

20 Indipendenza e Scorrelazione

Un concetto ancora più forte della covarianza nulla è quello di indipendenza. Se la covarianza misura solo un legame lineare, l'indipendenza ci assicura che la realizzazione di una variabile non fornisce assolutamente alcuna informazione sull'altra.

Definizione 20.1 (Variabili Aleatorie Indipendenti)**.** Siano X e Y due variabili aleatorie. Esse si dicono *indipendenti* se per ogni coppia di insiemi misurabili $A, B \subseteq \mathbb{R}$ si ha che:

$$\mathbb{P}(\{X \in A\} \cap \{Y \in B\}) = \mathbb{P}(X \in A) \cdot \mathbb{P}(Y \in B)$$

Formalmente, in termini dello spazio campionario Ω, questo equivale a scrivere:

$$\mathbb{P}\big(\{\omega \in \Omega : X(\omega) \in A\} \cap \{\omega \in \Omega : Y(\omega) \in B\}\big)$$

Equivalentemente, operando con le funzioni di distribuzione cumulativa (CDF), due variabili sono indipendenti se e solo se la loro funzione di distribuzione congiunta fattorizza nel prodotto delle distribuzioni marginali:

$$\forall x, y \in \mathbb{R} \quad \mathbb{P}(X \le x, Y \le y) = \mathbb{P}(X \le x) \cdot \mathbb{P}(Y \le y)$$

Questo concetto si estende naturalmente a vettori di n variabili aleatorie. Diremo che $X_1, \ldots, X_n$ sono mutuamente indipendenti se per ogni $x_1, \ldots, x_n \in \mathbb{R}$:

$$\mathbb{P}\left(\bigcap_{i=1}^n \{X_i \le x_i\}\right) = \prod_{i=1}^n \mathbb{P}(X_i \le x_i)$$

20.1 Il legame tra Indipendenza e Covarianza

Se due variabili aleatorie sono indipendenti, allora vale la fattorizzazione del valore atteso: $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$. Di conseguenza, dalla formula operativa ricavata in precedenza, si deduce immediatamente che **la loro covarianza è nulla**.

Definizione 20.2 (Variabili scorrelate)**.** Due variabili aleatorie X e Y si dicono *scorrelate* se $\mathrm{Cov}(X, Y) = 0$.

È spontaneo chiedersi: vale anche il viceversa? Ovvero, se due variabili sono scorrelate, sono necessariamente indipendenti? La risposta è **no**, e il seguente controesempio lo dimostra in modo cristallino.

Esempio: Covarianza nulla non implica Indipendenza

Consideriamo una variabile aleatoria X distribuita uniformemente sui valori $\{-1, 0, 1\}$, tale che:

$$\mathbb{P}(X = -1) = \mathbb{P}(X = 0) = \mathbb{P}(X = 1) = \frac{1}{3}$$

Costruiamo ora una seconda variabile aleatoria Y, definita in funzione di X nel seguente modo:

$$Y = \begin{cases} 0 & \text{se } X \neq 0 \\ 1 & \text{se } X = 0 \end{cases}$$

Valutiamo la variabile prodotto $X \cdot Y$. Verificando caso per caso, ci accorgiamo che il prodotto è sempre nullo ($X \cdot Y = 0$), il che implica banalmente che $\mathbb{E}[XY] = 0$. Inoltre, calcoliamo il valore atteso di X:

$$\mathbb{E}[X] = (-1)\frac{1}{3} + (0)\frac{1}{3} + (1)\frac{1}{3} = 0 \implies \mathbb{E}[X]\mathbb{E}[Y] = 0$$

Abbiamo quindi dimostrato che $\mathrm{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0$. Le due variabili sono scorrelate.
Tuttavia, esse **non** sono indipendenti (infatti, Y dipende funzionalmente da X!). Per verificarlo con la definizione formale, prendiamo in esame gli eventi $\{X = -1\}$ e $\{Y = 0\}$:

$$\mathbb{P}(\{X = -1\} \cap \{Y = 0\}) = \mathbb{P}(X = -1) = \frac{1}{3}$$
$$\mathbb{P}(X = -1) \cdot \mathbb{P}(Y = 0) = \frac{1}{3} \cdot \frac{2}{3} = \frac{2}{9}$$

Poiché $\frac{1}{3} \neq \frac{2}{9}$, la condizione di indipendenza fallisce.

21 Leggi Congiunte, Marginali e Densità

Quando si studiano più variabili simultaneamente, si definisce la **funzione di distribuzione congiunta**:

$$\forall x, y \in \mathbb{R} \quad F_{X,Y}(x, y) = \mathbb{P}(X \leq x, Y \leq y)$$

Come possiamo recuperare le informazioni su una singola variabile ignorando l'altra? Dobbiamo ricavare la cosiddetta **distribuzione marginale**. È sufficiente mandare al limite l'altra variabile:

$$\lim_{y \to \infty} F_{X,Y}(x, y) = \mathbb{P}(\{X \leq x\} \cap \{Y \in \mathbb{R}\}) = \mathbb{P}(X \leq x) = F_X(x)$$

Le modalità operative cambiano a seconda che le variabili siano di natura discreta o continua.

21.1 Caso Discreto

Nel caso discreto, definiamo la densità di probabilità congiunta (o funzione di massa di probabilità) come la probabilità che le variabili assumano esattamente una certa coppia di valori:

$$\forall x, y \in \mathbb{R} \quad p_{X,Y}(x, y) := \mathbb{P}(X = x, Y = y)$$

Dalla densità congiunta, la densità marginale si ricava semplicemente *sommando* su tutti i valori possibili dell'altra variabile:

$$\mathbb{P}(X = x) = \sum_{y:\mathbb{P}(Y=y)>0} \mathbb{P}(X = x, Y = y)$$

21.2 Caso Continuo

(Ricordiamo che per variabili assolutamente continue, la probabilità che la v.a. assuma un punto esatto ha misura nulla, da qui la necessità di ricorrere agli integrali).

Se X e Y sono variabili continue, diciamo che sono *congiuntamente continue* se esiste una funzione $f(\cdot, \cdot)$ integrabile tale che per ogni insieme misurabile $B \subseteq \mathbb{R}^2$ si abbia:

$$\mathbb{P}\big((X, Y) \in B\big) = \iint_B f(x, y)\, dx\, dy$$

La funzione $f(x, y)$ è detta **densità congiunta**. In particolare, se il dominio è un rettangolo $B = A_1 \times A_2$, l'integrale diventa:

$$\mathbb{P}(X \in A_1, Y \in A_2) = \int_{A_1} \left(\int_{A_2} f(x, y)\, dy \right) dx$$

Analogamente al caso discreto, la funzione di distribuzione si esprime come integrale doppio da meno infinito:

$$F_{X,Y}(x, y) = \int_{-\infty}^{x} \left(\int_{-\infty}^{y} f(u, v)\, dv \right) du$$

E per il Teorema Fondamentale del Calcolo Integrale, se conosciamo la distribuzione $F_{X,Y}$, possiamo trovare la densità derivando rispetto a entrambe le variabili:

$$f(x, y) = \frac{\partial^2}{\partial x \partial y} F_{X,Y}(x, y)$$

Le densità marginali, che rappresentano il corrispettivo continuo delle sommatorie viste nel caso discreto, si ottengono integrando la variabile "di troppo":

$$f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x, y)\, dy \qquad \text{e} \qquad f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x, y)\, dx$$

Sfruttando le densità, possiamo anche riformulare l'indipendenza: due variabili congiuntamente continue sono indipendenti se e solo se la loro densità congiunta fattorizza nelle densità marginali: $f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$.

Esempio: Confronto tra due variabili Esponenziali

Siano date due variabili aleatorie $X \sim \text{Exp}(\lambda_1)$ e $Y \sim \text{Exp}(\lambda_2)$ con $\lambda_1, \lambda_2 > 0$. Supponiamo che X e Y siano indipendenti. Vogliamo calcolare la probabilità che $X > Y$. Grazie all'indipendenza, la densità congiunta è semplicemente il prodotto delle due marginali: $f_{X,Y}(x,y) = f_X(x)f_Y(y)$. L'evento $\{X > Y\}$ equivale a definire il dominio di integrazione $D = \{(x,y) \in \mathbb{R}^2 : x > y > 0\}$.
Procediamo con l'integrazione:

$$\begin{aligned}\mathbb{P}(X > Y) &= \iint_D f_{X,Y}(x,y)\,dx\,dy = \iint_D f_X(x) \cdot f_Y(y)\,dx\,dy \\ &= \iint_D \left(\lambda_1 e^{-\lambda_1 x}\right) \cdot \left(\lambda_2 e^{-\lambda_2 y}\right)\,dx\,dy\end{aligned}$$

Sistemando gli estremi di integrazione (fissiamo $x \in (0, +\infty)$ e di conseguenza y varierà tra 0 e x):

$$\begin{aligned}\mathbb{P}(X > Y) &= \int_0^{+\infty} \left(\int_0^x \lambda_2 e^{-\lambda_2 y}\,dy\right) \lambda_1 e^{-\lambda_1 x}\,dx \\ &= \int_0^{+\infty} \Big[-e^{-\lambda_2 y}\Big]_0^x \lambda_1 e^{-\lambda_1 x}\,dx \\ &= \int_0^{+\infty} (1 - e^{-\lambda_2 x})\lambda_1 e^{-\lambda_1 x}\,dx \\ &= \int_0^{+\infty} \lambda_1 e^{-\lambda_1 x}\,dx - \int_0^{+\infty} \lambda_1 e^{-(\lambda_1+\lambda_2)x}\,dx \\ &= \left[-e^{-\lambda_1 x} + \frac{\lambda_1}{\lambda_1+\lambda_2} e^{-(\lambda_1+\lambda_2)x}\right]_0^{+\infty} \\ &= (0 - (-1)) + \left(0 - \frac{\lambda_1}{\lambda_1+\lambda_2}\right) = 1 - \frac{\lambda_1}{\lambda_1+\lambda_2} = \frac{\lambda_2}{\lambda_1+\lambda_2}\end{aligned}$$

22 Somma di Variabili Aleatorie Indipendenti

Cosa succede quando sommiamo due variabili aleatorie indipendenti? Siano X e Y indipendenti e definiamo una nuova variabile $W := X + Y$. Vogliamo ricavare la legge di distribuzione di W.

Iniziamo calcolando la Funzione di Distribuzione Cumulativa (CDF) valutata in un punto $a \in \mathbb{R}$:

$$\begin{aligned}F_{X+Y}(a) &= \mathbb{P}(X + Y \le a) \\ &= \iint_{\{x+y \le a\}} f_X(x) f_Y(y)\,dx\,dy \\ &= \int_{\mathbb{R}} \left(\int_{-\infty}^{a-y} f_X(x)\,dx\right) f_Y(y)\,dy\end{aligned}$$

Notiamo che l'integrale più interno non è altro che la CDF di X valutata in $a - y$. Dunque possiamo riscrivere:

$$F_{X+Y}(a) = \int_{\mathbb{R}} F_X(a-y) f_Y(y)\,dy$$

Per trovare la densità di probabilità $f_W(a)$ della somma, ci basta derivare la funzione di distribuzione rispetto ad a. Sotto l'ipotesi di poter scambiare il segno di derivata con l'operatore

di integrale, otteniamo:

$$\begin{aligned} f_W(a) &= \frac{d}{da}\left[F_{X+Y}(a)\right] \\ &= \frac{d}{da}\left[\int_{\mathbb{R}} F_X(a-y) f_Y(y)\, dy\right] \\ &= \int_{\mathbb{R}} \left(\frac{d}{da} F_X(a-y)\right) f_Y(y)\, dy \\ &= \int_{\mathbb{R}} f_X(a-y) f_Y(y)\, dy \end{aligned}$$

Questo risultato è noto nell'analisi matematica come **prodotto di convoluzione** tra le due funzioni di densità.

23 Disuguaglianze Fondamentali

Nello studio della teoria della probabilità, spesso non si conosce la distribuzione esatta di una variabile aleatoria, ma se ne conoscono solo alcuni momenti (come la media o la varianza). Le disuguaglianze di Markov e Chebyshev ci permettono di limitare la probabilità che una variabile si discosti dai suoi valori attesi.

Teorema 23.1 (Disuguaglianza di Markov)**.** *Sia X una variabile aleatoria non negativa ($X \geq 0$). Allora per ogni $a > 0$ vale:*

$$\mathbb{P}(X > a) \leq \frac{\mathbb{E}[X]}{a}$$

Dimostrazione. L'utilità di questa disuguaglianza risiede nel fatto che è molto più semplice calcolare il valore atteso $\mathbb{E}[X]$ piuttosto che possedere informazioni complete sulla distribuzione. Dimostriamolo utilizzando la funzione indicatrice $\mathbb{1}_A$:

$$\mathbb{E}[X] = \mathbb{E}[X \cdot \mathbb{1}_{\{X \leq a\}}] + \mathbb{E}[X \cdot \mathbb{1}_{\{X > a\}}]$$

Poiché $X \geq 0$, il primo termine della somma è non negativo. Inoltre, nell'evento $\{X > a\}$, la variabile X è strettamente maggiore di a. Pertanto possiamo minorare il valore atteso:

$$\mathbb{E}[X] \geq a \cdot \mathbb{E}[\mathbb{1}_{\{X > a\}}] = a \cdot \mathbb{P}(X > a)$$

Dividendo per a si ottiene la tesi: $\mathbb{P}(X > a) \leq \frac{\mathbb{E}[X]}{a}$. □

Teorema 23.2 (Disuguaglianza di Chebyshev)**.** *Sia X una variabile aleatoria tale che $\mathbb{E}[X] = \mu$ e $Var(X) = \sigma^2 < \infty$. Allora per ogni $a > 0$:*

$$\mathbb{P}(|X - \mu| > a) \leq \frac{Var(X)}{a^2} = \frac{\sigma^2}{a^2}$$

Questa disuguaglianza (che si dimostra applicando Markov alla variabile non negativa $(X - \mu)^2$) fornisce una stima quantitativa di quanto la variabile X sia distante dalla sua media μ. Intuitivamente, se la varianza σ^2 è molto piccola, la probabilità che X si allontani dalla media decresce drasticamente: la variabile è *fortemente localizzata*.

24 I Teoremi Asintotici della Probabilità

I teoremi limite studiano il comportamento di successioni di variabili aleatorie al crescere del numero di osservazioni n.

Teorema 24.1 (Legge Debole dei Grandi Numeri)**.** *Sia $\{X_n\}_{n\geq 1}$ una successione di variabili aleatorie indipendenti e identicamente distribuite (i.i.d.) tali che $\mathbb{E}[X_1] = \mu$ e $Var(X_1) = \sigma^2 < \infty$ (quest'ultima ipotesi si può rilassare, però il teorema si dimostrerebbe diversamente). Allora, per ogni $\varepsilon > 0$ si ha:*

$$\mathbb{P}\left(\left|\frac{X_1 + \cdots + X_n}{n} - \mu\right| > \varepsilon\right) \xrightarrow{n\to\infty} 0$$

Dimostrazione. Definiamo $S_n = X_1 + \cdots + X_n$ e onsideriamo la media campionaria S_n/n. Il suo valore atteso è per linearità:

$$\mathbb{E}\left[\frac{S_n}{n}\right] = \frac{1}{n} \cdot n\mu = \mu$$

Assumendo (sebbene non strettamente necessario per la validità generale del teorema) che la varianza sia finita e pari a σ^2, calcoliamo la varianza della media campionaria sfruttando l'indipendenza (che annulla le covarianze):

$$\mathrm{Var}\left(\frac{S_n}{n}\right) = \frac{1}{n^2}\mathrm{Var}(X_1 + \cdots + X_n) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(X_i) = \frac{1}{n^2}(n\sigma^2) = \frac{\sigma^2}{n}$$

Applicando ora la disuguaglianza di Chebyshev alla variabile S_n/n:

$$\mathbb{P}\left(\left|\frac{S_n}{n} - \mu\right| > \varepsilon\right) \leq \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n\to\infty} 0$$

□

Per completezza, enunciamo anche la versione "forte", che garantisce la convergenza quasi certa:

Teorema 24.2 (Legge Forte dei Grandi Numeri)**.** *Sia $\{X_n\}_{n\geq 1}$ una successione di v.a. i.i.d. tali che $\mathbb{E}[X_1] = \mu$ e $\mathbb{E}[|X_1|] < +\infty$. Allora:*

$$\mathbb{P}\left(\lim_{n\to\infty}\frac{S_n}{n} = \mu\right) = 1$$

Teorema 24.3 (Teorema del Limite Centrale - TLC)**.** *Sia $\{X_n\}_{n\geq 1}$ una successione di v.a. i.i.d. con media μ e varianza σ^2. Allora per ogni $x \in \mathbb{R}$:*

$$\mathbb{P}\left(\frac{S_n - n\mu}{\sqrt{n}\cdot\sigma} \leq x\right) \xrightarrow{n\to\infty} \mathbb{P}(Z \leq x)$$

dove $Z \sim \mathcal{N}(0,1)$ è una variabile normale standardizzata.

Esempio: Approssimazione di una Poisson tramite TLC

Sia il numero di studenti iscritti a un corso modellizzato come una variabile Poissoniana: $X \sim \text{Poi}(100)$. Se il numero di tali studenti è ≥ 120, il corso viene sdoppiato. Qual è la probabilità di sdoppiamento?
Il calcolo esatto richiede una sommatoria onerosa:

$$\mathbb{P}(X \geq 120) = 1 - \mathbb{P}(X < 120) = 1 - \sum_{n=0}^{119} e^{-100} \cdot \frac{100^n}{n!}$$

Sfruttando la proprietà di riproducibilità della Poisson, possiamo immaginare X come somma di 100 variabili Poissoniane indipendenti di parametro 1:

$$X_i \sim \text{Poi}(1) \implies X = X_1 + \cdots + X_{100} \sim \text{Poi}(100)$$

Poiché $n = 100$ è grande, applichiamo il TLC (sapendo che per una Poi(1) media e varianza valgono 1, quindi per la somma media e varianza valgono 100, e la deviazione standard è $\sqrt{100} = 10$). Applicando anche la correzione per continuità (utilizzando 119.5 o procedendo con l'approssimazione diretta):

$$\mathbb{P}\left(\sum_{i=1}^{100} X_i \geq 120\right) = \mathbb{P}\left(\frac{\sum X_i - 100}{10} \geq \frac{19.5}{10}\right) \approx 1 - \Phi(1.95) = 0.0256$$

Quindi la probabilità è di circa il 2.56%.

25 Vettori Aleatori e Normale Multivariata

Estendiamo ora il concetto di distribuzione Normale a più dimensioni.

Definizione 25.1. Un vettore aleatorio colonna $\underline{X}$ di dimensione $k \times 1$ si dice distribuito come una **Normale Multivariata** di vettore delle medie $\underline{\mu}$ e matrice di covarianza Σ (simmetrica definita positiva $k \times k$), se la sua densità congiunta è data da:

$$f(\underline{x}) = \frac{1}{\sqrt{(2\pi)^k \det(\Sigma)}} \exp\left\{-\frac{1}{2}(\underline{x} - \underline{\mu})^T \Sigma^{-1} (\underline{x} - \underline{\mu})\right\}$$

dove:

- $\underline{\mu}_i = \mathbb{E}[X_i]$
- $\Sigma_{i,j} = \text{Cov}(X_i, X_j)$ per $i \neq j$, e $\Sigma_{i,i} = \sigma_i^2$

Se le componenti $\{X_i\}_{i=1}^k$ sono tra loro indipendenti, tutte le covarianze si annullano e la matrice Σ diventa diagonale.

Una proprietà fondamentale caratterizza questa distribuzione: **un vettore $\underline{X}$ è una normale multivariata se e solo se qualsiasi combinazione lineare delle sue componenti è distribuita come una normale univariata.** Ovvero, per ogni scelta di coefficienti scalari $a_1, \ldots, a_k \in \mathbb{R}$:

$$a_1 X_1 + a_2 X_2 + \cdots + a_k X_k \sim \mathcal{N}(\ldots, \ldots)$$

In particolare, visto che deve essere vera per tutti i coefficienti, dovrà essere vero che anche le singole componenti siano distribuzione come delle normali.

Esempio: Controesempio sulla normalità congiunta

Attenzione: avere componenti marginali normali **non** implica che il vettore congiunto sia una normale multivariata! Sia $X \sim \mathcal{N}(0,1)$. Definiamo una variabile W indipendente da X tale che:

$$W = \begin{cases} +1 & \text{con } p = 1/2 \\ -1 & \text{con } p = 1/2 \end{cases}$$

Definiamo ora $Y = W \cdot X$. Per simmetria, anche $Y \sim \mathcal{N}(0,1)$. Consideriamo il vettore $\underline{V} = (X, Y)^T$. Entrambe le marginali sono normali. Tuttavia, studiamo la combinazione lineare $X + Y$:

$$\begin{aligned} \mathbb{P}(X+Y=0) &= \mathbb{P}(\{X+Y=0\} \cap \{W=+1\}) + \mathbb{P}(\{X+Y=0\} \cap \{W=-1\}) \\ &= \mathbb{P}(\{2X=0\} \cap \{W=+1\}) + \mathbb{P}(\{0=0\} \cap \{W=-1\}) \\ &= \mathbb{P}(X=0)\mathbb{P}(W=1) + 1 \cdot \mathbb{P}(W=-1) \\ &= 0 + \frac{1}{2} = \frac{1}{2} \end{aligned}$$

La variabile $X+Y$ ha una probabilità concentrata in un singolo punto (massa di probabilità pari a $1/2$ in 0), pertanto non è continua. Non essendo continua, non può essere una Normale. Di conseguenza, essendoci una combinazione lineare non normale, il vettore $\underline{V}$ **non è** una normale multivariata.

26 Fondamenti di Statistica Inferenziale

Definizione 26.1. Le variabili aleatorie $X_1, \ldots, X_n$ costituiscono un **campione casuale** di taglia n tratto da una popolazione f se:

1. Sono reciprocamente indipendenti.
2. Hanno tutte la stessa distribuzione (o densità marginale) definita da f.

Sotto queste ipotesi, le X_i rappresentano le singole osservazioni indipendenti. La distribuzione congiunta (o funzione di verosimiglianza prima dell'osservazione) del campione si fattorizza semplicemente come il prodotto delle marginali:

$$f_n(x_1, \ldots, x_n) = \prod_{i=1}^{n} f(x_i)$$

In statistica, la funzione f che rappresenta la distribuzione o la densità di probabilità di una popolazione può dipendere da uno o più parametri, che comunemente indichiamo con il vettore θ. Di conseguenza, quando abbiamo a che fare con un campione formato da n osservazioni indipendenti, scriviamo la funzione di densità congiunta del campione in questo modo:

$$f_n(x_1, \ldots, x_n|\theta) = \prod_{i=1}^{n} f(x_i|\theta)$$

Tipicamente, il valore esatto di θ è sconosciuto: è proprio questo l'elemento che il nostro processo di inferenza andrà a stimare partendo dai dati empirici.

Esempio: Distribuzione Esponenziale

Un caso classico è la distribuzione esponenziale, denotata come $Exp(\lambda)$ o con il parametro $\beta > 0$. Tale parametro caratterizza interamente il comportamento della distribuzione. Se estraiamo un campione $X_1, \dots, X_n$ da una popolazione con questa distribuzione, la funzione di densità di una singola osservazione è $f(x|\beta) = \frac{1}{\beta} e^{-\frac{1}{\beta}x} \mathbb{1}_{\{x \geq 0\}}$. Per la congiunta, moltiplicando i vari termini, otteniamo la seguente forma:

$$f_n(x_1, \dots, x_n|\beta) = \frac{1}{\beta^n} e^{-\frac{1}{\beta}\sum_{i=1}^n x_i} \underbrace{\mathbb{1}_{\{x_1,\dots,x_n \geq 0\}}}_{\substack{\text{valori} \\ \text{fissati}}}$$

L'utilizzo della funzione indicatrice $\mathbb{1}$ è fondamentale a livello matematico per specificare formalmente il supporto in cui la variabile ha valori validi e non nulli.

27 Approssimazione i.i.d. nel Campionamento

Un aspetto essenziale prima di intraprendere le analisi è comprendere l'origine dei nostri dati. Se la popolazione di origine è **infinita**, le singole estrazioni saranno naturalmente indipendenti e identicamente distribuite (i.i.d.).

Spesso, però, nella pratica lavoriamo con una popolazione **finita** di cardinalità N, che possiamo immaginare come un'urna contenente N palline. Da quest'urna selezioniamo un campione di taglia n. Qui, le dinamiche di estrazione giocano un ruolo chiave:

- **Campionamento con rimpiazzo:** osserviamo l'esito e rimettiamo la pallina nell'urna. In questo scenario, le estrazioni restano perfettamente svincolate l'una dall'altra e il campionamento è effettivamente i.i.d.
- **Campionamento senza rimpiazzo:** non reinseriamo la pallina. Ciò che facciamo all'istante t ha evidenti conseguenze sulle probabilità al momento $t+1$. Tuttavia, si verifica un fenomeno rassicurante: se il numero di estrazioni n è piccolo rispetto alla totalità N, il fatto di non reinserire le palline diventa pressoché indifferente.

27.1 Giustificazione Matematica

Dimostriamo matematicamente questa indifferenza calcolando la probabilità che, pur estraendo con rimpiazzo, ci capiti di ripescare una pallina già estratta. Sia E l'evento "ripetere la stessa osservazione in n estrazioni su una popolazione di N elementi". Vogliamo calcolare $\mathbb{P}(E) = 1 - \mathbb{P}(E^c)$, dove E^c è l'evento "non estraggo mai la stessa pallina". Se faccio finta di poter sempre prendere tutte le palline, ho N^n casi totali, mentre i casi favorevoli a E^c sono gli allineamenti senza ripetizione:

$$\mathbb{P}(E^c) = \frac{N \cdot (N-1) \dots (N-n+1)}{N^n} = \frac{N}{N} \cdot \left(1 - \frac{1}{N}\right) \dots \left(1 - \frac{n-1}{N}\right) = \prod_{i=1}^{n-1} \left(1 - \frac{i}{N}\right)$$

Per valutarne l'ordine di grandezza, applichiamo il logaritmo:

$$\log\left(\prod_{i=1}^{n-1} \left(1 - \frac{i}{N}\right)\right) = \sum_{i=1}^{n-1} \log\left(1 - \frac{i}{N}\right)$$

Sfruttando lo sviluppo in serie di Taylor per il logaritmo centrato in zero, abbiamo che $\log(1-x) \approx -x$. Affinché questa approssimazione sia valida, necessitiamo che l'argomento tenda a zero:

questo è garantito se imponiamo che la taglia del campione sia $n = o(\sqrt{N})$. Segue che:

$$\sum_{i=1}^{n-1} \log\left(1 - \frac{i}{N}\right) \approx -\sum_{i=1}^{n-1} \frac{i}{N}$$

D'altra parte, essendo $\sum_{i=1}^{n-1} \frac{i}{N}$ ancora un $n = o(\sqrt{N})$, si ha che:

$$log\left(1 - \sum_{i=1}^{n-1} \frac{i}{N}\right) \approx -\sum_{i=1}^{n-1} \frac{i}{N}$$

Siccome le approssimazioni dei logaritmi sono uguali, affermiamo che:

$$\prod_{i=1}^{n-1}\left(1 - \frac{i}{N}\right) = 1 - \sum_{i=1}^{n-1} \frac{i}{N}$$

Da quest'ultima relazione deriva l'approssimazione diretta di partenza, dal momento che la somma $\sum_{i=1}^{n-1} i$ è nota:

$$\mathbb{P}(E) = 1 - \mathbb{P}(E^c) \approx \sum_{i=1}^{n-1} \frac{i}{N} = \frac{1}{N} \cdot \frac{1}{2} n(n-1) \approx \frac{n^2}{N} \ll 1$$

Abbiamo quindi dimostrato che, per $n = o(\sqrt{N})$, la probabilità $\mathbb{P}(E)$ è dell'ordine di $\frac{n^2}{N}$, che è un valore trascurabile in quanto estremamente più piccolo di qualsiasi costante ($\ll 1$). Grazie a questo risultato, persino in assenza di rimpiazzo, possiamo considerare le nostre osservazioni campionarie come i.i.d. Questo fondamento teorico è lo stesso che permette lo sviluppo e il successo del Machine Learning: garantendo l'indipendenza, si giustifica la robustezza e l'accuratezza dei modelli costruiti su tanti campioni.

28 Definizione di Statistica e Distribuzioni Campionarie

Avendo stabilito che i nostri dati possono essere trattati come un campione casuale di variabili i.i.d. $X_1, \ldots, X_n$, passiamo alle funzioni utili ad analizzarli.

Definizione 28.1 (Statistica)**.** Sia $X_1, \ldots, X_n$ un campione casuale di taglia n tratto da una qualche popolazione e sia $T : \Omega^n \to \mathbb{R}^k$, per un $k \geq 1$, una funzione che ha come dominio Ω^n (ovvero lo spazio campionario del vettore $X_1, \ldots, X_n$) e che nel suo codominio restituisce valori reali o vettoriali. La variabile aleatoria o il vettore aleatorio $T(X_1, \ldots, X_n)$ è detto **statistica**. La sua distribuzione di probabilità è definita **distribuzione campionaria** (o *sampling distribution*).

Nota cruciale: Una statistica, per definizione, *non può* dipendere da parametri incogniti. Se all'interno dell'espressione compare un parametro sconosciuto (es. θ, μ vera della popolazione), non siamo di fronte ad una statistica calcolabile dai dati empirici.

Esempio: Le Statistiche Fondamentali

Tra le statistiche più impiegate nello studio di un campione di taglia n troviamo:

- **Media Campionaria:** $\bar{X} := \frac{X_1+\cdots+X_n}{n}$
- **Varianza Campionaria:** $S^2 := \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$
- **Deviazione Standard Campionaria:** $S := \sqrt{S^2}$

Dal momento che esse stesse sono definite in termini di variabili aleatorie (le singole X_i), anch'esse ereditano la natura di variabili aleatorie a tutti gli effetti.

29 Proprietà Algebriche delle Statistiche Campionarie

Le formule delle statistiche campionarie celano all'interno interessanti proprietà algebriche.

Teorema 29.1. *Dati $x_1, \ldots, x_n$ valori fissati in $\mathbb{R}$, definiamo la loro media $\bar{x} := \frac{1}{n}\sum_{i=1}^{n} x_i$ e una quantità che richiama la varianza campionaria $s^2 := \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$. Allora valgono le seguenti proprietà:*

a) $\min_{a\in\mathbb{R}}\sum_{i=1}^{n}(x_i - a)^2 = \sum_{i=1}^{n}(x_i - \bar{x})^2$*, ovvero il valore che minimizza la somma degli scarti quadratici è esattamente $\bar{x}$.*

b) $(n-1)s^2 = \sum_{i=1}^{n}(x_i - \bar{x})^2 = \sum_{i=1}^{n} x_i^2 - n\bar{x}^2$*, che fornisce un pratico metodo alternativo di calcolo per la varianza campionaria.*

Dimostrazione. La dimostrazione si basa su semplici scomposizioni algebriche.
Per il punto a): Inseriamo nell'espressione il trucco strategico di sommare e sottrarre $\bar{x}$:

$$\begin{aligned}\sum_{i=1}^{n}(x_i - a)^2 &= \sum_{i=1}^{n}(x_i - \bar{x} + \bar{x} - a)^2 \\ &= \sum_{i=1}^{n}(x_i - \bar{x})^2 + \underbrace{2\sum_{i=1}^{n}(x_i - \bar{x})(\bar{x} - a)}_{=0} + n(\bar{x} - a)^2\end{aligned}$$

Il termine intermedio è nullo in quanto $\sum(x_i - \bar{x}) = 0$. Ci resta quindi la somma di due elementi. Poiché l'ultimo termine è un quadrato moltiplicato per n, risulta essere sempre non negativo (≥ 0). Pertanto, per minimizzare l'intera espressione, dobbiamo azzerare quest'ultimo termine, ovvero ottenere $(\bar{x} - a)^2 = 0 \Leftrightarrow \bar{x} = a$.

Per il punto b): Sviluppiamo direttamente il quadrato del binomio iniziale:

$$\begin{aligned}(n-1)s^2 &= \sum_{i=1}^{n}(x_i^2 + \bar{x}^2 - 2x_i\bar{x}) \\ &= \sum_{i=1}^{n}(x_i^2 + \bar{x}^2) - 2\bar{x}\underbrace{\sum_{i=1}^{n} x_i}_{=n\bar{x}} \\ &= \sum_{i=1}^{n}(x_i^2 + \bar{x}^2) - 2n\bar{x}^2 \\ &= \sum_{i=1}^{n}(x_i^2 - \bar{x}^2) = \sum_{i=1}^{n} x_i^2 - n\bar{x}^2\end{aligned}$$

□

30 Analisi Probabilistica: Correttezza degli Stimatori

In un contesto inferenziale, vogliamo che le nostre statistiche siano dei buoni stimatori dei parametri reali della popolazione. Una proprietà desiderabile è la "correttezza", la quale garantisce che, in media, lo stimatore centri il vero valore del parametro.

Teorema 30.1 (Statistiche non distorte)**.** *Siano $X_1, \dots, X_n$ variabili i.i.d. tali che $\mathbb{E}[X_1] = \mu$ e con varianza finita $Var(X_1) = \sigma^2 < +\infty$. Allora:*

(i) $\mathbb{E}[\bar{X}] = \mu$

(ii) $Var(\bar{X}) = \frac{\sigma^2}{n}$ *(questo in quanto somma di v.a. indipendenti)*

(iii) $\mathbb{E}[S^2] = \sigma^2$

Questi risultati sanciscono che la media campionaria $\bar{X}$ e la varianza campionaria S^2 sono ***statistiche corrette o non distorte*** *(unbiased statistics).*

Dimostrazione. Le dimostrazioni per (i) e (ii) sono banali corollari della linearità dell'operatore valore atteso e della regola per la varianza di variabili indipendenti. Più interessante è la prova del punto (iii), che giustifica in modo formale la presenza del denominatore $n - 1$.

Partiamo dalla definizione di S^2 e applichiamo l'identità algebrica dal teorema precedente (punto b), ricordando che tale scomposizione vale rigorosamente anche per l'operatore di aspettazione:

$$\mathbb{E}[S^2] = \mathbb{E}\left[\frac{1}{n-1}\left(\sum_{i=1}^{n} X_i^2 - n\bar{X}^2\right)\right]$$

Per la proprietà di linearità del valore atteso:

$$\mathbb{E}[S^2] = \frac{1}{n-1}\left[\sum_{i=1}^{n} \mathbb{E}[X_i^2] - n\mathbb{E}[\bar{X}^2]\right]$$

E poiché le variabili sono identicamente distribuite (i.i.d.):

$$\mathbb{E}[S^2] = \frac{1}{n-1}\left[n\mathbb{E}[X_1^2] - n\mathbb{E}[\bar{X}^2]\right]$$

Richiamando il fatto che, in generale, $\mathbb{E}[Y^2] = Var(Y) + \mathbb{E}[Y]^2$, espandiamo i momenti secondi:

$$\begin{aligned}
\mathbb{E}[S^2] &= \frac{1}{n-1}\left[n(\sigma^2 + \mu^2) - n\underbrace{\left(\frac{\sigma^2}{n} + \mu^2\right)}_{\text{da i e ii}}\right] \\
&= \frac{1}{n-1}\left[n\sigma^2 + n\mu^2 - \sigma^2 - n\mu^2\right] \\
&= \frac{1}{n-1}[(n-1)\sigma^2] = \sigma^2
\end{aligned}$$

Ecco, dunque, svelato il motivo per cui calcolando S^2 si divide matematicamente per $n - 1$: qualora dividessimo semplicemente per n, introdurremmo un *bias* sistematico (una sottostima della vera variabilità), dato che calcoliamo gli scarti rispetto a $\bar{X}$ (la quale, a sua volta, è stata minimizzata localmente sui dati) invece che rispetto alla vera media di popolazione μ. □

31 Proprietà Fondamentali dei Campioni Normali

In questo articolo approfondiamo uno dei risultati pilastro della statistica inferenziale classica: il comportamento congiunto della media campionaria e della varianza campionaria estratte da una popolazione distribuita secondo una legge Normale.

Sia $X_1, X_2, \ldots, X_n$ un campione casuale di dimensione n composto da variabili casuali indipendenti e identicamente distribuite (i.i.d.) secondo una distribuzione Normale con media μ e varianza σ^2, in simboli:

$$X_i \sim \mathcal{N}(\mu, \sigma^2), \quad i = 1, \ldots, n.$$

Ricordiamo le definizioni dei due stimatori fondamentali:

Definizione 31.1 (Media e Varianza Campionaria)**.** La **media campionaria** $\bar{X}$ e la **varianza campionaria** S^2 sono definite rispettivamente come:

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2.$$

Teorema 31.1 (Teorema Fondamentale della Campionatura Normale)**.** *Se $X_1, \ldots, X_n \sim \mathcal{N}(\mu, \sigma^2)$, allora valgono le seguenti proprietà:*

- ***i)*** *$\bar{X}$ e S^2 sono stocasticamente indipendenti tra loro;*
- ***ii)*** *La media campionaria ha distribuzione normale: $\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$;*
- ***iii)*** *La varianza campionaria opportunamente scalata segue una distribuzione Chi-quadro: $(n-1)\frac{S^2}{\sigma^2} \sim \chi^2_{n-1}$.*

Di seguito esaminiamo la dimostrazione dettagliata di ciascun punto del teorema.

31.1 Distribuzione della Media Campionaria (Punto ii)

La dimostrazione del punto (ii) discende direttamente dalle proprietà fondamentali delle combinazioni lineari di variabili casuali normali e indipendenti.

Poiché la somma di variabili casuali normali e indipendenti è ancora una variabile casuale normale, $\bar{X}$ ha distribuzione Normale. I relativi parametri (media e varianza) si calcolano agevolmente applicando la linearità del valore atteso e la proprietà della varianza per variabili indipendenti:

$$\mathbb{E}[\bar{X}] = \mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}[X_i] = \frac{1}{n}\cdot n\mu = \mu,$$

$$\mathrm{Var}(\bar{X}) = \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(X_i) = \frac{1}{n^2}\cdot n\sigma^2 = \frac{\sigma^2}{n}.$$

Pertanto, concludiamo che:

$$\bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

31.2 Indipendenza tra Media e Varianza Campionaria (Punto i)

Per dimostrare che $\bar{X}$ e S^2 sono stocasticamente indipendenti, adottiamo una strategia in due fasi: 1. Mostriamo che S^2 può essere espresso come funzione degli scarti $(X_2 - \bar{X}), (X_3 - \bar{X}), \ldots, (X_n - \bar{X})$. 2. Dimostriamo che il vettore degli scarti $((X_2 - \bar{X}), \ldots, (X_n - \bar{X}))$ è indipendente da $\bar{X}$ analizzando la densità di probabilità congiunta tramite un opportuno cambio di variabili.

31.2.1 Espressione di S^2 in funzione degli scarti

Esplicitiamo la somma dei quadrati degli scarti separando il primo termine $i = 1$:

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2 = \frac{1}{n-1}\left[(X_1 - \bar{X})^2 + \sum_{i=2}^{n}(X_i - \bar{X})^2\right].$$

Ricordando l'identità fondamentale secondo cui la somma di tutti gli scarti dalla media è sempre nulla, $\sum_{i=1}^{n}(X_i - \bar{X}) = 0$, possiamo esprimere il primo scarto $(X_1 - \bar{X})$ in funzione degli altri $n-1$ scarti:

$$(X_1 - \bar{X}) = -\sum_{i=2}^{n}(X_i - \bar{X}).$$

Sostituendo questa relazione nella formula di S^2, otteniamo:

$$\begin{aligned} S^2 &= \frac{1}{n-1}\left[\left(-\sum_{i=2}^{n}(X_i - \bar{X})\right)^2 + \sum_{i=2}^{n}(X_i - \bar{X})^2\right] \\ &= \frac{1}{n-1}\left[\left(\sum_{i=2}^{n}(X_i - \bar{X})\right)^2 + \sum_{i=2}^{n}(X_i - \bar{X})^2\right]. \end{aligned}$$

È quindi evidente che S^2 dipende soltanto dal vettore degli scarti $((X_2 - \bar{X}), \ldots, (X_n - \bar{X}))$.

31.2.2 Analisi della densità congiunta e cambio di variabili

Senza perdita di generalità, assumiamo per semplicità algebrica che $\mu = 0$ e $\sigma^2 = 1$ (è sempre possibile ricondursi a questo caso tramite una traslazione e una riscalatura). La densità congiunta del campione $(X_1, \ldots, X_n)$ è data da:

$$f_n(x_1, \ldots, x_n) = \frac{1}{(2\pi)^{n/2}} \exp\left\{-\frac{1}{2}\sum_{i=1}^{n} x_i^2\right\}.$$

Effettuiamo ora il seguente cambio di variabili da $(x_1, x_2, \ldots, x_n)$ a $(y_1, y_2, \ldots, y_n)$:

$$\begin{cases} y_1 = \bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i, \\ y_j = x_j - \bar{x}, \qquad\qquad j = 2, \ldots, n. \end{cases}$$

La matrice Jacobiana diretta di questa trasformazione ha la seguente struttura:

$$J_{diretta} = \begin{pmatrix} \frac{1}{n} & \frac{1}{n} & \cdots & \cdots & \frac{1}{n} \\ -\frac{1}{n} & 1 - \frac{1}{n} & \cdots & \cdots & -\frac{1}{n} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ -\frac{1}{n} & -\frac{1}{n} & \cdots & \cdots & 1 - \frac{1}{n} \end{pmatrix}.$$

Sommando la prima riga a tutte le righe successive, il determinante rimane invariato e si trasforma in una matrice triangolare superiore con $\frac{1}{n}$ sulla diagonale principale nella prima riga e 1 su tutte le altre:

$$\det(J_{diretta}) = \begin{vmatrix} \frac{1}{n} & \frac{1}{n} & \cdots & \cdots & \frac{1}{n} \\ 0 & 1 & \cdots & \cdots & 0 \\ \vdots & \vdots & \ddots & \cdots & \vdots \\ 0 & 0 & \cdots & \cdots & 1 \end{vmatrix} = \frac{1}{n}.$$

Siccome noi dobbiamo esprimere la densità in funzione di $(y_1, \ldots, y_n)$, la trasformazione inversa impiega lo Jacobiano inverso, il cui determinante è il reciproco del determinante diretto:

$$|J_{inversa}| = |\det(J_{diretta})|^{-1} = n.$$

Riscriviamo ora l'esponente della densità congiunta $\sum_{i=1}^{n} x_i^2$. Poiché $x_i = y_i + y_1$ per $i = 2, \ldots, n$ e $x_1 = y_1 - \sum_{i=2}^{n} y_i$, espandendo i quadrati otteniamo che la densità congiunta nelle nuove coordinate si fattorizza esattamente nel prodotto di due densità distinte:

$$\begin{aligned} f_n(y_1, y_2, \ldots, y_n) &= \frac{n}{(2\pi)^{n/2}} \exp\left\{ -\frac{1}{2}\left(y_1 - \sum_{i=2}^{n} y_i \right)^2 - \frac{1}{2}\sum_{i=2}^{n}(y_i + y_1)^2 \right\} \\ &= \left[\left(\frac{n}{2\pi}\right)^{1/2} \exp\left\{ -\frac{n}{2} y_1^2 \right\} \right] \cdot \left[\frac{n^{1/2}}{(2\pi)^{(n-1)/2}} \exp\left\{ -\frac{1}{2}\left[\sum_{i=2}^{n} y_i^2 + \left(\sum_{i=2}^{n} y_i \right)^2 \right] \right\} \right]. \end{aligned}$$

Poiché la densità di probabilità congiunta $f_n(y_1, y_2, \ldots, y_n)$ si scompone nel prodotto di una funzione che dipende unicamente da $y_1 = \bar{X}$ e una che dipende unicamente da $(y_2, \ldots, y_n) = ((X_2 - \bar{X}), \ldots, (X_n - \bar{X}))$, ne consegue che $^{**}\bar{X}$ è stocasticamente indipendente da tutti gli scarti**.

E poiché S^2 è funzione esclusiva degli scarti, concludiamo che $^{**}\bar{X}$ e S^2 sono indipendenti**.

32 Distribuzione Chi-Quadro della Varianza Campionaria (Punto iii)

Dimostriamo infine che $(n-1)\frac{S^2}{\sigma^2} \sim \chi^2_{n-1}$ mediante un procedimento per induzione sulla dimensione campionaria n. Anche in questo caso poniamo $\mu = 0$ e $\sigma^2 = 1$.

Per chiarezza espositiva, indichiamo con S_m^2 la varianza campionaria calcolata su un campione di dimensione m:

$$S_m^2 = \frac{1}{m-1}\sum_{i=1}^{m}(X_i - \bar{X}_m)^2, \qquad \bar{X}_m = \frac{1}{m}\sum_{i=1}^{m} X_i.$$

Utilizziamo la relazione ricorsiva fondamentale per la somma degli scarti quadratici:

$$(n-1)S_n^2 = (n-2)S_{n-1}^2 + \frac{n-1}{n}(X_n - \bar{X}_{n-1})^2. \tag{5}$$

32.1 Proprietà di Indipendenza dei Termini Ricorsivi

Prima di procedere con l'induzione matematica, è cruciale stabilire l'indipendenza stocastica tra i due addendi che compaiono al lato destro della relazione (5) valutata a $n = k + 1$:

$$kS_{k+1}^2 = (k-1)S_k^2 + \frac{k}{k+1}(X_{k+1} - \bar{X}_k)^2.$$

Analizziamo i due termini separatamente: 1. Il primo termine, $(k-1)S_k^2$, è costruito unicamente a partire dalle prime k osservazioni $(X_1, \ldots, X_k)$. 2. Il secondo termine, $\frac{k}{k+1}(X_{k+1} - \bar{X}_k)^2$, coinvolge solo la nuova osservazione X_{k+1} e la media delle prime k osservazioni $\bar{X}_k$.

L'indipendenza tra questi due addendi deriva dai seguenti motivi:

- Per il punto (i) dimostrato precedentemente, la varianza campionaria S_k^2 è indipendente dalla media campionaria $\bar{X}_k$.
- La variabile X_{k+1} è indipendente da S_k^2, poiché S_k^2 dipende soltanto da $X_1, \ldots, X_k$ e le variabili del campione sono i.i.d.

Di conseguenza, il termine $(k-1)S_k^2$ risulta completamente indipendente dal termine $\frac{k}{k+1}(X_{k+1}-\bar{X}_k)^2$.

Inoltre, calcoliamo la distribuzione della variabile $(X_{k+1}-\bar{X}_k)$: Poiché $X_{k+1}\sim\mathcal{N}(0,1)$ e $\bar{X}_k\sim\mathcal{N}\left(0,\frac{1}{k}\right)$ (per via dei teoremi visti prima) sono indipendenti, la loro differenza è ancora normale:

$$(X_{k+1}-\bar{X}_k)\sim\mathcal{N}\left(0,1+\frac{1}{k}\right)=\mathcal{N}\left(0,\frac{k+1}{k}\right).$$

Moltiplicando per la radice del coefficiente $\sqrt{\frac{k}{k+1}}$, otteniamo una variabile normale standardizzata:

$$\sqrt{\frac{k}{k+1}}(X_{k+1}-\bar{X}_k)\sim\mathcal{N}(0,1).$$

Il quadrato di una variabile normale standard ha per definizione una distribuzione Chi-quadro con 1 grado di libertà:

$$\frac{k}{k+1}(X_{k+1}-\bar{X}_k)^2\sim\chi_1^2.$$

32.2 Dimostrazione per Induzione

Possiamo ora completare la dimostrazione per induzione.

Passo Base ($n=2$): Per $n=2$, grazie alla formula((5)) si ha:

$$S_2^2=\frac{1}{2-1}\sum_{i=1}^{2}(X_i-\bar{X}_2)^2=\frac{1}{2}(X_2-X_1)^2=\left(\frac{X_2-X_1}{\sqrt{2}}\right)^2.$$

Poiché $X_1,X_2\sim\mathcal{N}(0,1)$, la differenza $(X_2-X_1)\sim\mathcal{N}(0,2)$, e dunque $\frac{X_2-X_1}{\sqrt{2}}\sim\mathcal{N}(0,1)$. Ne consegue che:

$$(2-1)S_2^2=S_2^2\sim\chi_1^2.$$

Il passo base è verificato.

Passo Induttivo: Assumiamo vera l'ipotesi induttiva per $n=k$, ovvero che:

$$(k-1)S_k^2\sim\chi_{k-1}^2.$$

Verifichiamo la proprietà per $n=k+1$. Utilizzando la relazione ricorsiva:

$$kS_{k+1}^2=(k-1)S_k^2+\frac{k}{k+1}(X_{k+1}-\bar{X}_k)^2.$$

Per l'ipotesi induttiva e per quanto dimostrato nella sezione precedente:

- $(k-1)S_k^2\sim\chi_{k-1}^2$;
- $\frac{k}{k+1}(X_{k+1}-\bar{X}_k)^2\sim\chi_1^2$;
- I due addendi sono indipendenti.

Poiché la somma di due variabili casuali indipendenti distribuite come Chi-quadro con $k-1$ e 1 gradi di libertà è una variabile Chi-quadro con gradi di libertà pari alla somma dei singoli gradi di libertà ($(k-1)+1=k$), concludiamo che:

$$kS_{k+1}^2\sim\chi_k^2.$$

La proprietà è quindi verificata per ogni $n\geq 2$. Ripristinando i parametri generici μ e σ^2, si ottiene il risultato finale:

$$(n-1)\frac{S^2}{\sigma^2}\sim\chi_{n-1}^2.$$

33 La Distribuzione t di Student

Nelle applicazioni pratiche, la varianza della popolazione σ^2 è quasi sempre ignota e viene approssimata tramite la varianza campionaria S^2.

Se la varianza fosse nota, la variabile standardizzata $Z = \frac{\bar{X}-\mu}{\sigma/\sqrt{n}}$ seguirebbe una normale standard $\mathcal{N}(0,1)$. Sostituendo al posto del parametro incognito σ la deviazione standard campionaria $S = \sqrt{S^2}$, si definisce la quantità pivotale:

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}.$$

Riscriviamo algebricamente la statistica T moltiplicando e dividendo per σ:

$$T = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \cdot \frac{\sigma}{S} = \frac{\frac{\bar{X}-\mu}{\sigma/\sqrt{n}}}{\sqrt{\frac{S^2}{\sigma^2}}} = \frac{\frac{\bar{X}-\mu}{\sigma/\sqrt{n}}}{\sqrt{\frac{(n-1)S^2/\sigma^2}{n-1}}}.$$

La statistica T si presenta come il rapporto tra:

1. Una variabile normale standard al numeratore: $Z = \frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1)$;
2. La radice di una variabile Chi-quadro divisa per i propri gradi di libertà al denominatore: $\sqrt{\frac{V}{n-1}}$, dove $V = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$.

Grazie all'indipendenza provata tra $\bar{X}$ e S^2, numeratore e denominatore sono stocasticamente indipendenti.

Definizione 33.1 (Distribuzione t di Student)**.** Sia $\{X_n\}_n$ un campione casuale i.i.d. da una popolazione $\mathcal{N}(\mu, \sigma^2)$ con media e varianza incognite. La quantità pivotale $T = \frac{\bar{X}-\mu}{S/\sqrt{n}}$ segue una distribuzione t di Student con $p = n - 1$ gradi di libertà.

In generale, una variabile casuale T ha distribuzione t di Student con p gradi di libertà se la sua funzione di densità di probabilità è espressa da:

$$f_T(t) = \frac{\Gamma\left(\frac{p+1}{2}\right)}{\Gamma\left(\frac{p}{2}\right)\sqrt{p\pi}} \cdot \frac{1}{\left(1 + \frac{t^2}{p}\right)^{\frac{p+1}{2}}}, \quad t \in \mathbb{R},$$

dove $\Gamma(\cdot)$ indica la funzione Gamma di Eulero.

Confronto tra Normale e t di Student: La densità della t di Student è bell-shaped e simmetrica attorno allo zero, proprio come la Gaussiana standard. Tuttavia, causa dell'incertezza introdotta dalla stima della varianza tramite S, la t presenta una variabilità maggiore che si traduce in **code più pesanti** (fat tails), ovvero una maggiore probabilità di osservare valori estremi lontani dal centro rispetto ad una normale standard.

34 Coefficiente di Correlazione Campionario

Passiamo allo studio della relazione lineare tra due variabili quantitative osservate su un campione di coppie di dati $((x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n))$.

Definiamo anzitutto le deviazioni standard campionarie di x e y:

$$s_x = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}, \qquad s_y = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2}.$$

Per capire se esiste un'associazione concordante o discordante, analizziamo il segno dei prodotti degli scarti congiunti $(x_i - \bar{x})(y_i - \bar{y})$:

- **Caso I (Concordanza):** Se a valori di $x_i > \bar{x}$ corrispondono tendenzialmente valori di $y_i > \bar{y}$ (e viceversa), gli scarti sono concordi in segno e la loro somma risulterà **positiva e grande**.
- **Caso II (Discordanza):** Se a valori grandi di $x_i > \bar{x}$ corrispondono valori piccoli di $y_i < \bar{y}$, gli scarti avranno segno opposto e la loro somma risulterà **negativa e grande**.

Definizione 34.1 (Coefficiente di Correlazione Campionario)**.** Il coefficiente di correlazione campionario di Pearson r adimensiona la concordanza dividendola per il prodotto delle deviazioni standard:

$$r := \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{(n-1)s_x s_y}.$$

Proprietà di r:

1. Il coefficiente è delimitato nell'intervallo $[-1, 1]$.
2. **Correlazione Perfetta Positiva ($r = +1$):** Si verifica quando i punti giacciono esattamente su una retta con pendenza positiva ($y_i = a + bx_i$ con $b > 0$).
3. **Correlazione Perfetta Negativa ($r = -1$):** Si verifica quando i punti giacciono esattamente su una retta con pendenza negativa ($y_i = a + bx_i$ con $b < 0$).
4. **Assenza di Correlazione Lineare ($r = 0$):** Indica la mancanza di un legame *lineare*. Non implica necessariamente l'indipendenza stocastica tra le variabili, in quanto potrebbe sussistere una relazione funzionale non lineare (ad esempio quadratica).

Esempio: Correlazione vs Causalità

Un principio cardine della statistica è che **la correlazione non implica la causalità** (*Cum hoc ergo propter hoc*). Un valore elevato del coefficiente r evidenzia soltanto una co-variazione empirica tra le variabili, la quale potrebbe essere causata da una terza variabile latente (variabile di confondimento).

35 Statistiche d'Ordine, Mediana e Percentili

Definizione 35.1 (Statistiche d'Ordine)**.** Sia $X_1, X_2, \ldots, X_n$ un campione di variabili casuali i.i.d. Le **statistiche d'ordine** si ottengono ordinando i valori osservati del campione in senso non decrescente:

$$X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)},$$

dove $X_{(1)} = \min_{1 \leq i \leq n} X_i$ è il minimo campionario e $X_{(n)} = \max_{1 \leq i \leq n} X_i$ è il massimo campionario.

Dalle statistiche d'ordine si derivano importanti indici sintetici di dispersione e posizione:

- **Campo di Variazione (Range):** $R = X_{(n)} - X_{(1)}$, misura l'ampiezza dell'intervallo occupato dai dati.
- **Mediana Campionaria (M):** L'elemento che divide a metà il campione ordinato:

$$M := \begin{cases} X_{\left(\frac{n+1}{2}\right)} & \text{se } n \text{ è dispari,} \\ \frac{X_{\left(\frac{n}{2}\right)} + X_{\left(\frac{n}{2}+1\right)}}{2} & \text{se } n \text{ è pari.} \end{cases}$$

Esempio: Controversia Salariale: Media vs Mediana

In una trattativa sindacale per le pensioni di un club sportivo:

- **Dirigenza del Club:** "Il salario medio dei giocatori è di 433 659 $ annui, quindi il contributo pensionistico attuale è adeguato."
- **Sindacato Giocatori:** "Oltre la metà dei giocatori guadagna meno di 250 000 $ annui, pertanto il contributo non è sufficiente."

Questo esempio illustra come la **media campionaria** sia fortemente influenzata da pochi valori estremi molto elevati (outliers), mentre la **mediana** fornisca una misura robusta del valore tipico della distribuzione.

35.1 Percentili e Quartili

Fissiamo un valore di probabilità $p \in [0,1]$. Il percentile $100 \cdot p$-esimo è definito come quel valore v per cui almeno il $100p\%$ dei dati è inferiore o uguale a v e almeno il $100(1-p)\%$ è superiore o uguale a v.

Data una dimensione campionaria n, il calcolo pratico del percentile v avviene secondo la seguente regola:

$$v := \begin{cases} X_{(\lceil np \rceil)} & \text{se } np \notin \mathbb{N}, \\ \frac{X_{(np)} + X_{(np+1)}}{2} & \text{se } np \in \mathbb{N}, \end{cases}$$

dove $\lceil \cdot \rceil$ indica la funzione parte intera superiore (ceiling).

Particolari percentili assumono nomi specifici:

- 25° percentile = Primo Quartile (Q_1);
- 50° percentile = Mediana (M);
- 75° percentile = Terzo Quartile (Q_3).

36 Distribuzione delle Statistiche d'Ordine

Analizziamo il problema probabilistico di determinare la funzione di ripartizione e la densità delle statistiche d'ordine estreme (minimo e massimo) per variabili casuali continue.

Siano $X_1, \dots, X_n \sim$ i.i.d. con funzione di ripartizione $F_X(x)$ e densità $f_X(x)$.

36.1 Distribuzione del Minimo $X_{(1)}$

La funzione di ripartizione del minimo si ricava considerando la probabilità dell'evento complementare:

$$\begin{aligned} F_{X_{(1)}}(x) &= \mathbb{P}(X_{(1)} \le x) = 1 - \mathbb{P}(X_{(1)} > x) \\ &= 1 - \mathbb{P}(X_1 > x, X_2 > x, \dots, X_n > x) \\ &= 1 - \prod_{i=1}^{n} \mathbb{P}(X_i > x) = 1 - (1 - F_X(x))^n. \end{aligned}$$

Derivando rispetto a x, si ottiene la funzione di densità del minimo:

$$f_{X_{(1)}}(x) = \frac{d}{dx} F_{X_{(1)}}(x) = n(1 - F_X(x))^{n-1} f_X(x).$$

36.2 Distribuzione del Massimo $X_{(n)}$

Per il massimo campionario, la condizione che $X_{(n)} \leq x$ equivale a richiedere che tutte le singole osservazioni siano minori o uguali a x:

$$F_{X_{(n)}}(x) = \mathbb{P}(X_{(n)} \leq x) = \mathbb{P}(X_1 \leq x, X_2 \leq x, \ldots, X_n \leq x) = \prod_{i=1}^{n} F_X(x) = F_X^n(x).$$

La relativa densità di probabilità si ricava per derivazione:

$$f_{X_{(n)}}(x) = \frac{d}{dx} F_{X_{(n)}}(x) = n F_X^{n-1}(x) f_X(x).$$

Esempio: Esempio Discreto: Estrazione da Urna con Rimpiazzo

Consideriamo un'urna contenente N palline numerate $\{1, 2, \ldots, N\}$. Effettuiamo n estrazioni indipendenti con rimpiazzo. La variabile casuale discreta X_i indica il numero estratto all' i-esima prova, con $\mathbb{P}(X_i = k) = \frac{1}{N}$ per ogni $k \in \{1, \ldots, N\}$.
Calcoliamo la probabilità che il minimo sia pari a N:

$$\mathbb{P}(X_{(1)} = N) = \mathbb{P}(X_1 = N, X_2 = N, \ldots, X_n = N) = \left(\frac{1}{N}\right)^n = \frac{1}{N^n}.$$

Questo risultato esprime il fatto che l'unico modo in cui il valore minimo estratto in n prove possa essere pari al valore massimo teorico N è che tutte le n estrazioni abbiano dato esattamente la pallina N.

37 Esercizio: Distribuzione e Densità Congiunta del Minimo e del Massimo

Esempio: Esercizio

Siano $X_1, X_2, \ldots, X_n$ variabili aleatorie indipendenti e identicamente distribuite (i.i.d.) con funzione di ripartizione $F_X(x)$ e funzione di densità di probabilità $f_X(x)$.
Determina la funzione di ripartizione congiunta $F_{X_{(1)},X_{(n)}}(x, y)$ e la funzione di densità congiunta $f_{X_{(1)},X_{(n)}}(x, y)$ per il minimo $X_{(1)} = \min(X_1, \ldots, X_n)$ e il massimo $X_{(n)} = \max(X_1, \ldots, X_n)$.

Svolgimento e Spiegazione dei Passaggi

Passo 1: Calcolo della Funzione di Ripartizione Congiunta $F_{X_{(1)},X_{(n)}}(x, y)$

Per definizione, la funzione di ripartizione congiunta è data da:

$$F_{X_{(1)},X_{(n)}}(x, y) = \mathbb{P}(X_{(1)} \leq x,\, X_{(n)} \leq y)$$

Spiegazione del passaggio logico: Per calcolare questa probabilità congiunta, applichiamo la legge delle probabilità totali nella forma $\mathbb{P}(A) = \mathbb{P}(A \cap B) + \mathbb{P}(A \cap B^c)$. Scegliamo come evento principale $A = \{X_{(n)} \leq y\}$ e come evento di partizione $B = \{X_{(1)} \leq x\}$. Riorganizzando i termini otteniamo:

$$\mathbb{P}(X_{(1)} \leq x,\, X_{(n)} \leq y) = \mathbb{P}(X_{(n)} \leq y) - \mathbb{P}(X_{(n)} \leq y,\, X_{(1)} > x)$$

Analizziamo separatamente i due termini risultanti:

1. **Primo termine** $\mathbb{P}(X_{(n)} \leq y)$**:**

L'evento che il massimo sia minore o uguale a y equivale a richiedere che *tutti* i singoli elementi del campione siano minori o uguali a y. Poiché le X_i sono i.i.d., si ha:

$$\mathbb{P}(X_{(n)} \leq y) = \mathbb{P}(X_1 \leq y,\, X_2 \leq y,\, \ldots,\, X_n \leq y) = \prod_{i=1}^{n} \mathbb{P}(X_i \leq y) = F_X^n(y)$$

2. **Secondo termine** $\mathbb{P}(X_{(n)} \leq y,\, X_{(1)} > x)$**:**

Dobbiamo distinguere due casi in base alla relazione d'ordine tra x e y:

1. **Caso** $x \geq y$**:** Poiché per definizione $X_{(1)} \leq X_{(n)}$, l'evento $\{X_{(1)} > x \geq y \geq X_{(n)}\}$ è impossibile. Pertanto:
$$\mathbb{P}(X_{(n)} \leq y,\, X_{(1)} > x) = 0$$

2. **Caso** $x < y$**:** L'evento equivale a chiedere che tutti gli X_i cadano contemporaneamente nell'intervallo $(x, y]$. Sfruttando l'indipendenza:
$$\mathbb{P}(X_{(n)} \leq y,\, X_{(1)} > x) = \mathbb{P}\left(\bigcap_{i=1}^{n} \{x < X_i \leq y\}\right) = (F_X(y) - F_X(x))^n$$

Risultato per la CDF congiunta: Unendo i due casi tramite la funzione indicatrice $\mathbb{1}_{\{x<y\}}$, si ottiene l'espressione finale:

$$F_{X_{(1)},X_{(n)}}(x, y) = F_X^n(y) - \left[(F_X(y) - F_X(x))^n\right] \mathbb{1}_{\{x<y\}} \tag{6}$$

Nota sulle Proprietà Insiemistiche e di Probabilità

A supporto dei passaggi algebrici eseguiti, richiamiamo le proprietà della probabilità applicate alla singola variabile X_1:

$$\mathbb{P}\big(\{X_1 \leq y\} \cap \{X_1 > x\}\big) = \mathbb{P}\big(\{X_1 \leq y\} \cap \{X_1 \leq x\}^c\big) = \mathbb{P}(X_1 \leq y) - \mathbb{P}(X_1 \leq x)$$

Inoltre, quando $x < y$, l'unione degli eventi $\{X_1 \leq y\} \cup \{X_1 > x\}$ copre l'intero spazio campionario (evento certo, probabilità pari a 1):

$$\underbrace{\mathbb{P}(\{X_1 \leq y\} \cup \{X_1 > x\})}_{\substack{=1 \\ \text{perché } x<y}} = \mathbb{P}(X_1 \leq y) + \underbrace{\mathbb{P}(X_1 > x)}_{1-\mathbb{P}(X_1 \leq x)} - \mathbb{P}(x < X_1 \leq y) = 1$$

Da questo segue:

$$\mathbb{P}(x < X_1 \leq y) = \mathbb{P}(X_1 \leq y) - \mathbb{P}(X_1 \leq x) = F_X(y) - F_X(x)$$

Passo 2: Derivazione della Densità Congiunta $f_{X_{(1)},X_{(n)}}(x, y)$

Per ottenere la funzione di densità congiunta $f_{X_{(1)},X_{(n)}}(x, y)$, calcoliamo la derivata parziale seconda incrociata della funzione di ripartizione $F_{X_{(1)},X_{(n)}}(x, y)$ rispetto a x e y:

$$f_{X_{(1)},X_{(n)}}(x, y) = \frac{\partial^2 F_{X_{(1)},X_{(n)}}(x, y)}{\partial x\, \partial y}$$

Spiegazione dei passaggi di derivazione: 1. Calcoliamo dapprima la derivata parziale rispetto a x (sotto la condizione $x < y$):

$$\frac{\partial}{\partial x}\left[F_X^n(y) - (F_X(y) - F_X(x))^n\right] = -n(F_X(y) - F_X(x))^{n-1} \cdot (-f_X(x)) = n(F_X(y) - F_X(x))^{n-1} f_X(x)$$

2. Deriviamo successivamente il risultato ottenuto rispetto a y:

$$\frac{\partial}{\partial y}\left[n(F_X(y) - F_X(x))^{n-1} f_X(x)\right] = n(n-1)(F_X(y) - F_X(x))^{n-2} f_X(y) f_X(x)$$

Risultato per la PDF congiunta:

$$f_{X_{(1)},X_{(n)}}(x,y) = n(n-1)\left(F_X(y) - F_X(x)\right)^{n-2} f_X(x) f_X(y)\, \mathbb{1}_{\{x<y\}} \tag{7}$$

38 Esercizio: Distribuzione Congiunta di Tutte le Statistiche d'Ordine

Esempio: Esercizio

Siano $X_1, X_2, \ldots, X_n$ variabili aleatorie indipendenti e identicamente distribuite (i.i.d.) con funzione di ripartizione $F_X(x)$ e funzione di densità di probabilità $f_X(x)$.
Trova la funzione di ripartizione $F_{X_{(1)},\ldots,X_{(n)}}(x_1, \ldots, x_n)$ e la funzione di densità di probabilità congiunta $f_{X_{(1)},\ldots,X_{(n)}}(x_1, \ldots, x_n)$ per l'intero vettore delle statistiche d'ordine nel caso $x_1 < x_2 < \cdots < x_n$ (ovvero nell'unico dominio in cui la densità è non nulla).

Svolgimento e Spiegazione dei Passaggi

L'obiettivo è determinare la probabilità congiunta che le statistiche d'ordine si trovino simultaneamente in un vettore di punti ordinati:

$$F_{X_{(1)},\ldots,X_{(n)}}(x_1, \ldots, x_n) = \mathbb{P}(X_{(1)} \le x_1,\, X_{(2)} \le x_2,\, \ldots,\, X_{(n)} \le x_n)$$

Passo 1: Step Intermedio con Intervalli Disgiunti

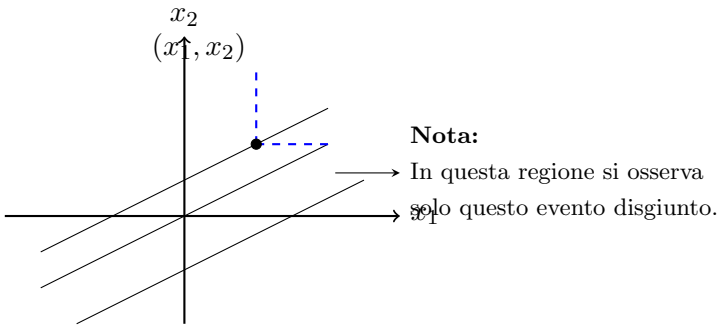
Per evitare sovrapposizioni tra le variabili ordinate, introduciamo dei punti intermedi $y_1, y_2, \ldots, y_n$ tali che valga la seguente catena di disuguaglianze ordinate:

$$y_1 < x_1 \le y_2 < x_2 \le y_3 \cdots \le y_n \le x_n$$

Valutiamo la probabilità dell'evento congiunto che ogni statistica d'ordine $X_{(i)}$ cada nel rispettivo intervallo disgiunto $(y_i, x_i]$:

$$\mathbb{P}\left[y_1 < X_{(1)} \le x_1,\, y_2 < X_{(2)} \le x_2,\, \ldots,\, y_n < X_{(n)} \le x_n\right] = \circledast\circledast$$

Interpretazione Geometrica (Caso $n = 2$): Nel caso $n = 2$, stiamo considerando la probabilità che il minimo $X_{(1)}$ sia in $(y_1, x_1]$ e il massimo $X_{(2)}$ sia in $(y_2, x_2]$.



Passo 2: Conteggio delle Permutazioni ed Eventi Disgiunti

I vari modi in cui le variabili originali $X_1, \ldots, X_n$ possono distribuirsi tra gli n intervalli disgiunti costituiscono **eventi mutuamente disgiunti**.

Poiché le X_i sono i.i.d., la probabilità che una specifica permutazione di variabili ricada negli intervalli è identica per tutte le $n!$ permutazioni degli indici. Ad esempio:

$$\mathbb{P}(y_1 < X_1 \leq x_1,\, y_2 < X_2 \leq x_2,\, \ldots) = \mathbb{P}(y_1 < X_2 \leq x_1,\, y_2 < X_1 \leq x_2,\, \ldots)$$

Sommando i contributi delle $n!$ permutazioni uguali, la probabilità dell'evento $\circledast\circledast$ diventa:

$$\begin{aligned}
\circledast\circledast &= n!\,\mathbb{P}(y_1 < X_1 \leq x_1,\, y_2 < X_2 \leq x_2,\, \ldots,\, y_n < X_n \leq x_n) \\
&= n!\,(F_X(x_1) - F_X(y_1)) \cdot (F_X(x_2) - F_X(y_2)) \cdots (F_X(x_n) - F_X(y_n)) \\
&= n! \prod_{i=1}^{n} [F_X(x_i) - F_X(y_i)]
\end{aligned}$$

Passo 3: Calcolo della Densità Congiunta

Per ottenere la funzione di densità congiunta $f_{X_{(1)},\ldots,X_{(n)}}(x_1, \ldots, x_n)$, deriviamo l'espressione trovata rispetto a ciascuna delle variabili $x_1, x_2, \ldots, x_n$.

Spiegazione del passaggio: Poiché i punti y_i rappresentano soltanto costanti degli estremi inferiori degli intervalli disgiunti, essi scompaiono durante la derivazione rispetto a x_i:

$$\begin{aligned}
f_{X_{(1)},\ldots,X_{(n)}}(x_1, \ldots, x_n) &= \frac{\partial^n}{\partial x_1 \partial x_2 \ldots \partial x_n} \mathbb{P}\left[y_1 < X_{(1)} \leq x_1,\, \ldots,\, y_n < X_{(n)} \leq x_n\right] \\
&= n! \prod_{i=1}^{n} \frac{\partial}{\partial x_i} [F_X(x_i) - F_X(y_i)] \\
&= n! \prod_{i=1}^{n} f_X(x_i)
\end{aligned}$$

Risultato per la densità congiunta del vettore ordinato:

$$f_{X_{(1)},\ldots,X_{(n)}}(x_1, \ldots, x_n) = n! \prod_{i=1}^{n} f_X(x_i) \cdot \mathbb{1}_{\{x_1 < x_2 < \cdots < x_n\}}$$

Nota Concettuale sui Limiti a $-\infty$ e sulla CDF Integrale

Nella formula $\circledast\circledast$ **non è corretto** mandare semplicemente i punti $y_1 \to -\infty$ e $y_k \to x_{k-1}$ per ricavare direttamente la F. Infatti, l'evento $X_{(1)} \leq x_1$ non garantisce automaticamente che $X_{(2)} > x_1$. Essendo stati imposti intervalli disgiunti nella costruzione dello step intermedio, i limiti a $-\infty$ violerebbero l'ipotesi di disgiunzione degli intervalli.

Di conseguenza, la funzione di ripartizione congiunta $F_{X_{(1)},\dots,X_{(n)}}(x_1,\dots,x_n)$ si calcola correttamente integrando la densità congiunta sopra il dominio ordinato:

$$\begin{aligned} F_{X_{(1)},\dots,X_{(n)}}(x_1,\dots,x_n) &= \int_{-\infty}^{x_1}\int_{-\infty}^{x_2}\cdots\int_{-\infty}^{x_n} n!\, f_X(z_1)f_X(z_2)\dots f_X(z_n)\,dz_1\,dz_2\dots dz_n \\ &= n!\, F_X(x_1)\,F_X(x_2)\dots F_X(x_n) \end{aligned}$$

39 Esercizio: Densità Marginale dell'i-esima Statistica d'Ordine

Esempio: Esercizio

Siano $X_1, X_2, \dots, X_n$ i.i.d. con funzione di ripartizione $F_X(x)$ e densità $f_X(x)$.
Determina la funzione di densità di probabilità marginale $f_{X_{(i)}}(x)$ per la generica i-esima statistica d'ordine $X_{(i)}$, con $i \in \{1, 2, \dots, n\}$.

Svolgimento e Spiegazione dei Passaggi

Partendo dalla densità congiunta di tutte le n statistiche d'ordine ottenuta nell'esercizio precedente:

$$f_{X_{(1)},\dots,X_{(n)}}(x_1,\dots,x_n) = n!\prod_{k=1}^{n} f_X(x_k) \quad \text{per } x_1 < x_2 < \dots < x_n$$

Per ottenere la densità marginale dell'i-esima variabile $X_{(i)}$, dobbiamo integrare via tutte le altre variabili x_k con $k \neq i$. L'integrazione avviene in due fasi distinte: prima saturiamo le variabili inferiori $x_1, \dots, x_{i-1}$ e successivamente le variabili superiori $x_{i+1}, \dots, x_n$.

Fase 1: Integrazione delle Variabili Inferiori ($x_1, \dots, x_{i-1}$)

Integrando rispetto a x_1 nell'intervallo $(-\infty, x_2]$:

$$f_{X_{(2)},\dots,X_{(n)}}(x_2,\dots,x_n) = \int_{-\infty}^{x_2} n!\cdot f_X(x_1)f_X(x_2)\dots f_X(x_n)\,dx_1 = n!\cdot F_X(x_2)f_X(x_2)\dots f_X(x_n)$$

Integrando il risultato rispetto a x_2 nell'intervallo $(-\infty, x_3]$:

$$\int_{-\infty}^{x_3} F_X(x_2)f_X(x_2)\,dx_2 = \frac{1}{2}F_X^2(x_3)$$

Iterando questo procedimento fino alla variabile x_{i-1}, l'integrazione delle $i-1$ variabili inferiori genera il fattore moltiplicativo $\frac{1}{(i-1)!}$. Si ottiene così la densità congiunta ridotta per le variabili da $X_{(i)}$ a $X_{(n)}$:

$$f_{X_{(i)},\dots,X_{(n)}}(x_i,\dots,x_n) = \frac{n!}{(i-1)!}F_X^{i-1}(x_i)\cdot f_X(x_i)f_X(x_{i+1})\dots f_X(x_n) \tag{8}$$

Fase 2: Integrazione delle Variabili Superiore ($x_n, \dots, x_{i+1}$)

Procediamo ora a saturare le variabili maggiori integrando da destra verso sinistra.

1. **Integrazione rispetto a x_n nell'intervallo $[x_{n-1}, +\infty)$:**

$$\int_{x_{n-1}}^{+\infty} f_X(x_n)\,dx_n = 1 - F_X(x_{n-1})$$

2. **Integrazione rispetto a x_{n-1} nell'intervallo $[x_{n-2}, +\infty)$:**

$$\int_{x_{n-2}}^{+\infty} f_X(x_{n-1}) \cdot (1 - F_X(x_{n-1}))\, dx_{n-1} = \frac{1}{2}(1 - F_X(x_{n-2}))^2$$

Iterando la saturazione delle $n - i$ variabili superiori $(x_n, x_{n-1}, \ldots, x_{i+1})$, si accumula al denominatore un fattore $(n - i)!$ e la potenza $(1 - F_X(x_i))^{n-i}$.

Fase 3: Risultato Finale per la Densità Marginale

Mettendo insieme i contributi delle due fasi di integrazione, otteniamo la densità marginale dell'i-esima statistica d'ordine:

$$f_{X_{(i)}}(x) = \frac{n!}{(i-1)!(n-i)!} F_X^{i-1}(x)\,(1 - F_X(x))^{n-i}\, f_X(x) \tag{9}$$

Interpretazione Combinatoria del Risultato: Il coefficiente $\frac{n!}{(i-1)!(n-i)!} = n\binom{n-1}{i-1}$ e la struttura della formula riflettono la logica combinatoria dell'evento $X_{(i)} \in (x, x + dx)$:

- Esattamente 1 osservazione cade nell'intorno $[x, x + dx]$, con densità $f_X(x)$;
- Esattamente $i - 1$ osservazioni cadono a sinistra di x (ognuna con probabilità $F_X(x)$);
- Le rimanenti $n - i$ osservazioni cadono a destra di x (ognuna con probabilità $1 - F_X(x)$).

Caso Particolare: Campione da Distribuzione Uniforme $U(0, 1)$

Esempio: Caso Particolare: Distribuzione Uniforme

Se le variabili $X_1, \ldots, X_n \sim U(0, 1)$, si ha $F_X(x) = x$ e $f_X(x) = 1$ per $x \in (0, 1)$. Sostituendo nella formula generale:

$$f_{X_{(i)}}(x) = \frac{n!}{(i-1)!(n-i)!}\, x^{i-1}(1 - x)^{n-i}\, \mathbb{1}_{\{x \in (0,1)\}}$$

Riconosciamo la funzione di densità della **distribuzione Beta**:

$$X_{(i)} \sim \text{Beta}(\alpha = i,\, \beta = n - i + 1)$$

40 Introduzione alla Riduzione dei Dati

Nel campo dell'inferenza statistica (in riferimento al classico testo *Statistical Inference* di Casella e Berger, Capitolo 6), uno dei problemi centrali riguarda la sintesi e la gestione dell'informazione campionaria.

Quando raccogliamo un campione osservato $\underline{X} = (X_1, X_2, \ldots, X_n)$, la dimensione e la complessità dei dati possono risultare elevate. L'obiettivo della **riduzione dei dati** è quello di comprimere l'insieme delle osservazioni mediante un numero ristretto di statistiche, garantendo al contempo che **nessuna informazione essenziale** riguardante il parametro ignoto $\theta \in \Theta$ vada perduta.

Formalmente, consideriamo una famiglia di densità parametriche parametrizzata da θ:

$$f(\underline{x} \mid \theta) \quad \text{con } \theta \in \Theta$$

dove Θ rappresenta lo spazio parametrico, ovvero l'insieme dei possibili valori che il parametro θ può assumere.

In letteratura si individuano **tre metodi principali** per approcciare la riduzione dei dati:

i) **Il Principio di Sufficienza:** focalizzato sulla conservazione integrale dell'informazione campionaria (oggetto principale della nostra analisi);

ii) **Il Principio di Verosimiglianza:** basato sul comportamento della funzione di verosimiglianza per il confronto tra ipotesi;

iii) **Il Principio di Equivalenza (o Invarianza):** fondato sulle simmetrie e sulle trasformazioni dello spazio dei campioni.

41 Il Principio di Sufficienza

L'idea intuitiva alla base della sufficienza è la seguente: vogliamo sintetizzare le informazioni ottenute dai dati osservati in modo tale che la statistica scelta catturi tutto ciò che c'è da sapere sul parametro θ.

Definizione 41.1 (Statistica Sufficiente)**.** Una statistica $T(X_1, \dots, X_n)$ è detta **sufficiente** per il parametro θ se la distribuzione condizionata del campione $(X_1, \dots, X_n)$, dato il valore assunto dalla statistica $T(X_1, \dots, X_n)$, non dipende più da θ.

In termini concettuali, ciò significa che una volta noto il valore di T, l'osservazione dei singoli valori del campione non aggiunge alcuna ulteriore informazione circa la stima o la struttura di θ. L'intera carica informativa è interamente contenuta in T.

Proposizione 41.1 (Enunciato del Principio di Sufficienza)**.** *Se $T(X_1, \dots, X_n)$ è una statistica sufficiente per θ, allora qualsiasi informazione o inferenza su θ ricavabile dal campione dipende dai dati unicamente tramite $T(X_1, \dots, X_n)$.*

In altri termini, se due realizzazioni campionarie $(x_1, \dots, x_n)$ e $(y_1, \dots, y_n)$ producono lo stesso valore della statistica, ossia:

$$T(x_1, \dots, x_n) = T(y_1, \dots, y_n)$$

allora le informazioni ricavate su θ sono esattamente le medesime, sia che sia stato osservato $(X_1, \dots, X_n) = (x_1, \dots, x_n)$, sia che sia stato osservato $(X_1, \dots, X_n) = (y_1, \dots, y_n)$.

42 Formulazione Matematica della Probabilità Condizionata

Per formalizzare la definizione, consideriamo il caso in cui la statistica $T(X_1, \dots, X_n)$ sia una variabile aleatoria **discreta**. Per evitare divisioni per zero, assumiamo per comodità di calcolo che:

$$\mathbb{P}(T(X_1, \dots, X_n) = t) > 0$$

(Si considera il caso discreto per semplicità, il caso continuo è analogo al livello di ragionamento, ma richiede passaggi diversi).
Utilizziamo la notazione $\mathbb{P}_{(\theta)}$ per indicare espressamente che la probabilità è calcolata assumendo θ come valore fissato del parametro. La probabilità condizionata da esaminare è:

$$\mathbb{P}_{(\theta)}\Big[(X_1, \dots, X_n) = (x_1, \dots, x_n) \;\Big|\; T(X_1, \dots, X_n) = t\Big]$$

Posto $t = T(x_1, \dots, x_n)$, calcoliamo esplicitamente:

$$\mathbb{P}_{(\theta)}\Big[(X_1, \dots, X_n) = (x_1, \dots, x_n) \;\Big|\; T(X_1, \dots, X_n) = T(x_1, \dots, x_n)\Big]$$

Sfruttando la definizione di probabilità condizionata $\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$, otteniamo:

$$= \frac{\mathbb{P}_{(\theta)}\big((X_1, \dots, X_n) = (x_1, \dots, x_n) \;\cap\; T(X_1, \dots, X_n) = T(x_1, \dots, x_n)\big)}{\mathbb{P}_{(\theta)}\big(T(X_1, \dots, X_n) = T(x_1, \dots, x_n)\big)}$$

Osserviamo che l'evento $\{(X_1, \ldots, X_n) = (x_1, \ldots, x_n)\}$ è contenuto nell'evento $\{T(X_1, \ldots, X_n) = T(x_1, \ldots, x_n)\}$. Infatti, conoscere la sequenza puntuale del campione determina in modo univoco il valore assunto dalla statistica T. Di conseguenza, l'intersezione coincide semplicemente con l'evento più restrittivo al numeratore:

$$= \frac{\mathbb{P}_{(\theta)}\big((X_1, \ldots, X_n) = (x_1, \ldots, x_n)\big)}{\mathbb{P}_{(\theta)}\big(T(X_1, \ldots, X_n) = T(x_1, \ldots, x_n)\big)} \quad (*)$$

Nota metodologica: L'inclusione logica vale in un solo senso: l'osservazione puntuale del campione implica il valore $T(\underline{x})$, ma non è vero il viceversa, poiché più campioni distinti possono originare la medesima sintesi T.

Esprimendo l'espressione $(*)$ in termini di densità discreta congiunta p_n del campione e densità discreta q della statistica T, arriviamo al rapporto:

$$\frac{p_n(x_1, \ldots, x_n \mid \theta)}{q(T(x_1, \ldots, x_n) \mid \theta)}$$

dove:

- $p_n(\underline{x} \mid \theta)$ è la densità discreta congiunta della variabile aleatoria n-dimensionale $(X_1, \ldots, X_n)$;
- $q(t \mid \theta)$ è la densità discreta della variabile aleatoria scalare $T(\underline{X})$.

Analogamente, per variabili aleatorie **continue**, la condizione si formula tramite il rapporto tra le corrispondenti funzioni di densità di probabilità:

$$\frac{f_n(x_1, \ldots, x_n \mid \theta)}{q(T(x_1, \ldots, x_n) \mid \theta)}$$

Teorema 42.1 (Criterio di Caratterizzazione per la Sufficienza)**.** *Dalla definizione discende che $T(\underline{X})$ è una statistica sufficiente per θ se e solo se il rapporto tra la densità congiunta del campione e la densità della statistica:*

$$\frac{f_n(x_1, \ldots, x_n \mid \theta)}{q(T(x_1, \ldots, x_n) \mid \theta)} \quad \textit{è indipendente da } \theta, \quad \forall (x_1, \ldots, x_n).$$

43 Applicazione Pratica: Il Campione di Bernoulli

Esempio: Campione Bernoulli i.i.d. e Statistica Sufficiente

Siano $X_1, \dots, X_n$ variabili aleatorie indipendenti e identicamente distribuite (i.i.d.) secondo una legge di Bernoulli di parametro $\theta \in (0,1)$:

$$X_i \sim \text{Bern}(\theta), \quad i = 1, \dots, n$$

Vogliamo dimostrare che la somma delle osservazioni:

$$T(X_1, \dots, X_n) := \sum_{i=1}^{n} X_i$$

è una statistica sufficiente per il parametro θ.
Passo 1: Identificazione delle distribuzioni. Dalla teoria sappiamo che la somma di n variabili aleatorie Bernoulli i.i.d. segue una distribuzione Binomiale di parametri n e θ:

$$T(X_1, \dots, X_n) \sim \text{Bin}(n, \theta)$$

Per ogni singolo elemento del supporto $x_i \in \{0,1\}$, la probabilità marginale è espressa come:

$$\mathbb{P}(X_i = x_i) = \theta^{x_i}(1-\theta)^{1-x_i}$$

Passo 2: Calcolo della densità congiunta. Sfruttando l'**indipendenza stocastica** delle variabili $X_1, \dots, X_n$, la densità congiunta del campione $p_n(\underline{x} \mid \theta)$ è data dal prodotto delle singole densità marginali:

$$p_n(x_1, \dots, x_n \mid \theta) = \prod_{i=1}^{n} \theta^{x_i}(1-\theta)^{1-x_i} = \theta^{\sum_{i=1}^n x_i}(1-\theta)^{n-\sum_{i=1}^n x_i}$$

Definendo $t := \sum_{i=1}^n x_i$ (che rappresenta il numero totale di successi ottenuti nel campione), possiamo riscrivere:

$$p_n(x_1, \dots, x_n \mid \theta) = \theta^t(1-\theta)^{n-t}$$

Passo 3: Densità dello statistico T. La funzione di massa di probabilità della variabile $T \sim \text{Bin}(n, \theta)$ per il valore t è:

$$q(t \mid \theta) = \binom{n}{t}\theta^t(1-\theta)^{n-t}$$

Passo 4: Verifico il rapporto di sufficienza. Calcoliamo ora il rapporto tra la densità congiunta e la densità dello statistico:

$$\frac{p_n(x_1, \dots, x_n \mid \theta)}{q(T(x_1, \dots, x_n) \mid \theta)} = \frac{\theta^t(1-\theta)^{n-t}}{\binom{n}{t}\theta^t(1-\theta)^{n-t}} = \frac{1}{\binom{n}{t}} = \frac{1}{\binom{n}{\sum_{i=1}^n x_i}}$$

Conclusione: Il valore del rapporto $1 \Big/ \binom{n}{\sum x_i}$ risulta totalmente privo del parametro θ. Di conseguenza, per la definizione data, la somma campionaria $T(X_1, \dots, X_n) = \sum_{i=1}^n X_i$ è a tutti gli effetti una **statistica sufficiente** per θ.

44 Esercizio: Media Campionaria per una Popolazione Normale

Esempio: Esercizio

Siano $X_1, \ldots, X_n$ variabili casuali indipendenti ed identicamente distribuite (i.i.d.) secondo una distribuzione Normale $\mathcal{N}(\mu, \sigma^2)$, dove la varianza σ^2 è nota ed il parametro di interesse è la media incognita μ.
Vogliamo mostrare che la media campionaria

$$T(\underline{X}) = \bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

è una statistica sufficiente per μ.

Svolgimento: Calcoliamo innanzitutto la densità congiunta del campione $\underline{x} = (x_1, \ldots, x_n)$:

$$f_n(\underline{x}|\mu) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2\right).$$

Scomponiamo la somma dei quadrati a livello dell'esponente aggiungendo e sottraendo la media campionaria $\bar{x}$:

$$(x_i-\mu)^2 = ((x_i-\bar{x})+(\bar{x}-\mu))^2 = (x_i-\bar{x})^2 + 2(x_i-\bar{x})(\bar{x}-\mu) + (\bar{x}-\mu)^2.$$

Sommando su tutti gli n elementi ed osservando che $\sum_{i=1}^{n}(x_i-\bar{x}) = 0$, il termine con il doppio prodotto si annulla:

$$\sum_{i=1}^{n}(x_i-\mu)^2 = \sum_{i=1}^{n}(x_i-\bar{x})^2 + 2(\bar{x}-\mu)\underbrace{\sum_{i=1}^{n}(x_i-\bar{x})}_{=0} + \sum_{i=1}^{n}(\bar{x}-\mu)^2 = \sum_{i=1}^{n}(x_i-\bar{x})^2 + n(\bar{x}-\mu)^2.$$

Possiamo dunque riscrivere la densità congiunta come:

$$f_n(\underline{x}|\mu) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\bar{x})^2\right)\exp\left(-\frac{n}{2\sigma^2}(\bar{x}-\mu)^2\right).$$

Dai teoremi visti nei precedenti capitoli, sappiamo che la media campionaria si distribuisce come:

$$T(\underline{X}) = \bar{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Pertanto, la densità marginale della statistica $T(\underline{X})$ è data da:

$$q(T(\underline{x})|\mu) = q(\bar{x}|\mu) = \frac{1}{\sqrt{2\pi\frac{\sigma^2}{n}}}\exp\left(-\frac{n}{2\sigma^2}(\bar{x}-\mu)^2\right).$$

Consideriamo ora il rapporto tra la densità congiunta e la densità della statistica:

$$\frac{f_n(\underline{x}|\mu)}{q(T(\underline{x})|\mu)} = \frac{\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\bar{x})^2\right)\exp\left(-\frac{n}{2\sigma^2}(\bar{x}-\mu)^2\right)}{\frac{\sqrt{n}}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{n}{2\sigma^2}(\bar{x}-\mu)^2\right)}.$$

Semplificando i termini esponenziali contenenti il parametro μ, si ottiene:

$$\frac{f_n(\underline{x}|\mu)}{q(T(\underline{x})|\mu)} = \sqrt{n}\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^{n-1}\exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\bar{x})^2\right).$$

Poiché tale rapporto dipende unicamente dai dati osservati $\underline{x}$ e non dal parametro μ, concludiamo che $\bar{X}$ è una **statistica sufficiente** per la media μ.

45 Il Teorema di Fattorizzazione di Halmos-Savage

Il calcolo diretto del rapporto tra densità richiede la conoscenza a priori della distribuzione marginale della statistica $T(\underline{X})$, la quale non è sempre di facile determinazione. Il **Teorema di Fattorizzazione** fornisce un criterio operativo estremamente potente e pratico.

Teorema 45.1 (Fattorizzazione di Halmos-Savage)**.** *Sia $f_n(\underline{x}|\theta)$ la densità congiunta di un campione casuale $\underline{X} = (X_1, \dots, X_n)$. La statistica $T(\underline{X})$ è sufficiente per il parametro θ se e solo se esistono due funzioni non negative $g(t|\theta)$ e $h(\underline{x})$ tali che per ogni valore del campione $\underline{x}$ e per ogni $\theta \in \Theta$:*

$$f_n(\underline{x}|\theta) = g(T(\underline{x})|\theta) \cdot h(\underline{x}),$$

dove:

- *$h(\underline{x})$ è una funzione che dipende unicamente dai dati osservati $\underline{x}$ e **non contiene** il parametro θ;*
- *$g(t|\theta)$ è una funzione che dipende dal parametro θ e interagisce con i dati campionari $\underline{x}$ **esclusivamente tramite** la statistica $T(\underline{x})$.*

Riconsiderando l'esempio della popolazione normale $\mathcal{N}(\mu, \sigma^2)$, la densità congiunta fattorizzata era:

$$f_n(\underline{x}|\mu) = \underbrace{\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i - \bar{x})^2\right)}_{=h(\underline{x})} \cdot \underbrace{\exp\left(-\frac{n}{2\sigma^2}(\bar{x} - \mu)^2\right)}_{=g(T(\underline{x})|\mu)}.$$

L'applicazione del teorema conferma immediatamente la sufficienza di $T(\underline{X}) = \bar{X}$.

46 Esercizi Svolti ed Applicazioni Pratiche

46.1 Esercizio: Distribuzione Uniforme Discreta

Esempio: Esercizio

Siano $X_1, \dots, X_n$ i.i.d. distribuiti secondo una Uniforme Discreta nell'insieme $\{1, 2, \dots, \theta\}$, dove $\theta \in \mathbb{N}^+$ è il parametro incognito. La funzione di massa di probabilità del singolo elemento è:

$$f(x|\theta) = \begin{cases} \frac{1}{\theta} & \text{se } x \in \{1, 2, \dots, \theta\} \\ 0 & \text{altrimenti.} \end{cases}$$

Determinare una statistica sufficiente per θ.

Svolgimento: La funzione di massa di probabilità congiunta del campione è:

$$f_n(\underline{x}|\theta) = \begin{cases} \frac{1}{\theta^n} & \text{se } x_i \in \{1, 2, \dots, \theta\} \quad \forall i \in \{1, \dots, n\} \\ 0 & \text{altrimenti.} \end{cases}$$

Osserviamo che la condizione $x_i \in \{1, 2, \dots, \theta\}$ per ogni $i = 1, \dots, n$ equivale a richiedere simultaneamente che:

1. $x_i \in \{1, 2, \dots\}$ per ogni i;

2. Il massimo del campione non superi θ, ossia $\max_{1\leq i\leq n} x_i \leq \theta$.

Definiamo quindi la statistica $T(\underline{X}) = \max_{1\leq i\leq n} X_i$. Sfruttando le funzioni indicatrici, possiamo scrivere la congiunta come:

$$f_n(\underline{x}|\theta) = \underbrace{\mathbb{1}_{\{x_i\in\mathbb{N}^+\,\forall i\}}(\underline{x})}_{=h(\underline{x})} \cdot \underbrace{\frac{1}{\theta^n}\mathbb{1}_{\{T(\underline{x})\leq\theta\}}(T(\underline{x}))}_{=g(T(\underline{x})|\theta)}.$$

Per il Teorema di Fattorizzazione, la statistica $T(\underline{X}) = \max_{1\leq i\leq n} X_i$ è una **statistica sufficiente** per θ.

46.2 Esercizio: Distribuzione Potenza su $(0, 1)$

Esempio: Esercizio

Sia $X_1, \ldots, X_n$ un campione i.i.d. con densità:

$$f(x|\theta) = \begin{cases} \theta x^{\theta-1} & \text{se } x \in (0,1) \\ 0 & \text{altrimenti} \end{cases} \quad (\theta > 0).$$

Trovare una statistica sufficiente per θ.

Svolgimento: La densità congiunta è data dal prodotto delle singole densità:

$$f_n(\underline{x}|\theta) = \prod_{i=1}^{n} \left(\theta x_i^{\theta-1}\mathbb{1}_{(0,1)}(x_i)\right) = \theta^n \left(\prod_{i=1}^{n} x_i\right)^{\theta-1} \prod_{i=1}^{n} \mathbb{1}_{(0,1)}(x_i).$$

Scegliamo come statistica il prodotto delle osservazioni campionarie:

$$T(\underline{X}) = \prod_{i=1}^{n} X_i.$$

Possiamo fattorizzare la densità congiunta ponendo:

$$h(\underline{x}) = \prod_{i=1}^{n} \mathbb{I}_{(0,1)}(x_i) = \begin{cases} 1 & \text{se } x_i \in (0,1) \quad \forall i = 1, \ldots, n \\ 0 & \text{altrimenti} \end{cases}$$

e

$$g(T(\underline{x})|\theta) = \theta^n \left(T(\underline{x})\right)^{\theta-1}.$$

Poiché $f_n(\underline{x}|\theta) = g(T(\underline{x})|\theta) \cdot h(\underline{x})$, la statistica $T(\underline{X}) = \prod_{i=1}^{n} X_i$ è sufficiente per θ.

Nota sulla Non-Unicità: Le funzioni $g(t|\theta)$ e $h(\underline{x})$ della fattorizzazione non sono uniche. È ad esempio sempre possibile moltiplicare $h(\underline{x})$ per una costante arbitraria $c > 0$ e dividere $g(t|\theta)$ per la medesima costante.

46.3 Esercizio: Distribuzione di Tipo Beta e Trasformazioni Biettive

Esempio: Esercizio

Siano $X_1, \dots, X_n$ i.i.d. con densità:

$$f(x|\theta) = \frac{\Gamma(\alpha+\theta)}{\Gamma(\alpha)\Gamma(\theta)} x^{\alpha-1}(1-x)^{\theta-1}, \quad \alpha, \theta > 0,\ x \in [0,1],$$

dove α è un parametro noto e θ è il parametro incognito da stimare.
Si chiede di mostrare che la statistica:

$$T(\underline{X}) = \frac{1}{n}\left[\sum_{i=1}^{n} \log\left(\frac{1}{1-X_i}\right)\right]^3$$

è sufficiente per θ.

Svolgimento: Scriviamo innanzitutto la densità congiunta del campione:

$$f_n(\underline{x}|\theta) = \left(\frac{1}{\Gamma(\alpha)}\right)^n \left(\prod_{i=1}^{n} x_i^{\alpha-1}\right) \left(\frac{\Gamma(\alpha+\theta)}{\Gamma(\theta)}\right)^n \left(\prod_{i=1}^{n}(1-x_i)\right)^{\theta-1} \prod_{i=1}^{n} \mathbb{1}_{[0,1]}(x_i).$$

Dalla fattorizzazione naturale emerge la statistica sufficente fondamentale:

$$T'(\underline{X}) = \prod_{i=1}^{n}(1-X_i).$$

Infatti, ponendo:

$$h(\underline{x}) = \left(\frac{1}{\Gamma(\alpha)}\right)^n \left(\prod_{i=1}^{n} x_i^{\alpha-1}\right) \prod_{i=1}^{n} \mathbb{1}_{[0,1]}(x_i),$$

$$g(t'|\theta) = \left(\frac{\Gamma(\alpha+\theta)}{\Gamma(\theta)}\right)^n (t')^{\theta-1},$$

il teorema di fattorizzazione assicura che $T'(\underline{X})$ è sufficiente per θ.

Mostriamo ora che $T(\underline{X})$ è una trasformazione biettiva (invertibile) di $T'(\underline{X})$. Sfruttando le proprietà dei logaritmi:

$$\sum_{i=1}^{n} \log\left(\frac{1}{1-x_i}\right) = -\sum_{i=1}^{n} \log(1-x_i) = -\log\left(\prod_{i=1}^{n}(1-x_i)\right) = -\log(T'(\underline{x})).$$

Sostituendo nell'espressione di $T(\underline{X})$:

$$T(\underline{X}) = \frac{1}{n}\left[-\log(T'(\underline{X}))\right]^3 = \varphi(T'(\underline{X})),$$

dove definiamo la funzione $\varphi : (0,1] \to [0,\infty)$ (ricordando che $x_i \in [0,1) \implies (1-x_i) \in (0,1]$, da cui $t' = \prod_{i=1}^{n}(1-x_i) \in (0,1]$, da questo il dominio di φ) come:

$$\varphi(t') = \frac{1}{n}\left(-\log(t')\right)^3.$$

La funzione φ è strettamente decrescente e continua, dunque è **biettiva ed invertibile**. La sua funzione inversa è data da:

$$t' = \varphi^{-1}(t) = \exp\left(-(nt)^{1/3}\right).$$

Possiamo quindi esprimere la funzione della fattorizzazione direttamente in termini di $T(\underline{x})$:

$$\tilde{g}(t|\theta) = g(\varphi^{-1}(t)|\theta) = \left(\frac{\Gamma(\alpha+\theta)}{\Gamma(\theta)}\right)^n \left(\varphi^{-1}(t)\right)^{\theta-1}.$$

Ne consegue che $f_n(\underline{x}|\theta) = \tilde{g}(T(\underline{x})|\theta) \cdot h(\underline{x})$, dimostrando che anche $T(\underline{X})$ è una **statistica sufficiente** per θ.

Principio Generale: Ogni applicazione invertibile (biettiva) di una statistica sufficiente conserva integralmente la proprietà di sufficienza.

46.4 Esercizio: Sufficienza nel Modello Normale con Parametri Incogniti.

Esempio: Sufficienza nel Modello Normale

Consideriamo un campione di variabili casuali indipendenti e identicamente distribuite (i.i.d.) provenienti da una popolazione normale con media e varianza entrambe incognite:

$$X_1, \ldots, X_n \overset{\text{i.i.d.}}{\sim} \mathcal{N}(\mu, \sigma^2)$$

Il vettore dei parametri incogniti è descritto da $\underline{\theta} = (\mu, \sigma^2)^T \in \mathbb{R} \times \mathbb{R}^+$. La densità di probabilità congiunta per la realizzazione campionaria $\underline{x} = (x_1, \ldots, x_n)$ si esprime come:

$$f_n(\underline{x}|\underline{\theta}) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left(-\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{2\sigma^2}\right) \exp\left(-\frac{n(\bar{x}-\mu)^2}{2\sigma^2}\right)$$

(come già visto negli esercizi precedenti). Vogliamo dimostrare che la coppia formata dalla media campionaria e dalla varianza campionaria $\underline{T}(\underline{X}) = (\bar{X}, S^2)$ costituisce una statistica sufficiente per il vettore parametrico $\underline{\theta}$.

Svolgimento Osserviamo innanzitutto che il termine $\exp\left(-\frac{n(\bar{x}-\mu)^2}{2\sigma^2}\right)$ dipende dai dati $\underline{x}$ unicamente attraverso la media campionaria $\bar{x}$.

Per quanto riguarda il termine contenente la somma degli scarti quadratici $\sum_{i=1}^n (x_i - \bar{x})^2$, ricordiamo la definizione di varianza campionaria:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^n (x_i - \bar{x})^2 \implies \sum_{i=1}^n (x_i - \bar{x})^2 = (n-1)s^2$$

Sostituendo tale relazione nella funzione di densità congiunta, possiamo riscrivere $f_n(\underline{x}|\underline{\theta})$ nella forma fattorizzata:

$$f_n(\underline{x}|\underline{\theta}) = \underbrace{\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left(-\frac{(n-1)}{2\sigma^2}\cdot s^2\right) \exp\left(-\frac{n(\bar{x}-\mu)^2}{2\sigma^2}\right)}_{g((\bar{x},s^2)\,|\,\underline{\theta})} \cdot \underbrace{1}_{h(\underline{x})}$$

Poiché la funzione $h(\underline{x}) = 1$ non dipende dal parametro $\underline{\theta}$ e la funzione $g((\bar{x}, s^2)|\underline{\theta})$ dipende dal campione solo tramite le statistiche $\bar{x}$ e s^2, in virtù del Teorema di Fattorizzazione concludiamo che:

$$\underline{T}(\underline{X}) = (\bar{X}, S^2)$$

è una **statistica sufficiente** per il vettore di parametri $\underline{\theta} = (\mu, \sigma^2)$.

47 Statistiche Sufficienti Minimali

Sebbene molte statistiche possano essere sufficienti, l'obiettivo prioritario dell'analisi dei dati è la **massima compressione dell'informazione senza perdita di contenuto inferenziale**. Questo concetto porta alla definizione di statistica sufficiente minimale.

Definizione 47.1 (Statistica Sufficiente Minimale)**.** Una statistica sufficiente $T(\underline{X})$ è detta **minimale** se, per ogni altra statistica sufficiente $T'(\underline{X})$, la statistica $T(\underline{X})$ è una funzione di $T'(\underline{X})$.

Se due realizzazioni campionarie $\underline{x}$ e $\underline{y}$ producono lo stesso valore per la statistica T', allora producono necessariamente lo stesso valore per T:

$$T'(\underline{x}) = T'(\underline{y}) \implies T(\underline{x}) = T(\underline{y})$$

Intuizione: Consideriamo due possibili statistiche per un campione:

1. $T_A(\underline{X}) = (X_1, \dots, X_n)$: l'intero vettore dei dati. È banalmente una statistica perché non dipende dai parametri.
2. $T_B(\underline{X}) = \sum_{i=1}^{n} X_i$: la somma campionaria.

In questo caso T_B è l'unico candidato plausibile ad essere una statistica minimale.

Dimostrare direttamente dalla definizione che una statistica è minimale può risultare complesso a causa del quantificatore universale ($\forall T'$ sufficiente). Per superare questo ostacolo si utilizza il seguente teorema fondamentale:

Teorema 47.1 (Teorema di Lehmann-Scheffé per la Minimalità)**.** *Sia $f_n(\underline{x}|\underline{\theta})$ la densità di probabilità congiunta della n-upla $\underline{x} = (x_1, \dots, x_n)$. Supponiamo che esista una statistica $T(\underline{X})$ tale che, per ogni coppia di osservazioni $\underline{x}, \underline{y}$, la condizione:*

$$\frac{f_n(\underline{x}|\underline{\theta})}{f_n(\underline{y}|\underline{\theta})} \text{ è costante rispetto a } \underline{\theta} \iff T(\underline{x}) = T(\underline{y})$$

*sia soddisfatta. Allora $T(\underline{X})$ è una **statistica sufficiente e minimale** per $\underline{\theta}$.*

47.1 Esempio: Distribuzione Uniforme su $(\theta, \theta + 1)$

Esempio: Distribuzione Uniforme

Sia $X_1, \dots, X_n \overset{\text{i.i.d.}}{\sim} \text{Unif}(\theta, \theta + 1)$ con $\theta \in \mathbb{R}$. Vogliamo mostrare che la coppia delle statistiche d'ordine estreme:

$$T(\underline{X}) = (X_{(1)}, X_{(n)}) = \left(\min_i X_i, \max_i X_i \right)$$

è una statistica sufficiente minimale per θ.

1. Costruzione della densità congiunta: La densità marginale per la singola osservazione è data da:

$$f(x|\theta) = \begin{cases} 1 & \text{se } \theta < x < \theta + 1 \\ 0 & \text{altrimenti} \end{cases}$$

Di conseguenza, la densità congiunta del campione è:

$$f_n(\underline{x}|\theta) = \begin{cases} 1 & \text{se } \theta < x_i < \theta + 1,\ \forall i \in \{1, \dots, n\} \\ 0 & \text{altrimenti} \end{cases}$$

Analizziamo le condizioni per cui $f_n(\underline{x}|\theta) = 1$:

$$\begin{cases} \forall i,\ \theta < x_i \iff \min_i x_i > \theta \iff x_{(1)} > \theta \\ \forall i,\ x_i < \theta + 1 \iff \max_i x_i < \theta + 1 \iff \theta > x_{(n)} - 1 \end{cases}$$

Possiamo dunque riscrivere la densità congiunta mediante le statistiche d'ordine:

$$f_n(\underline{x}|\theta) = \begin{cases} 1 & \text{se } x_{(n)} - 1 < \theta < x_{(1)} \\ 0 & \text{altrimenti} \end{cases}$$

2. Verifica del rapporto tramite Lehmann-Scheffé: Consideriamo due realizzazioni campionarie $\underline{x}$ e $\underline{y}$. Vogliamo studiare quando il rapporto $\frac{f_n(\underline{x}|\theta)}{f_n(\underline{y}|\theta)}$ risulta indipendente da θ.

- **Implicazione $\Leftarrow$:** Se $T(\underline{x}) = T(\underline{y})$, ovvero $x_{(1)} = y_{(1)}$ e $x_{(n)} = y_{(n)}$, allora le due densità $f_n(\underline{x}|\theta)$ e $f_n(\underline{y}|\theta)$ sono perfettamente identiche per ogni θ. Il loro rapporto è identicamente pari a 1, dunque costante rispetto a θ.
- **Implicazione $\Rightarrow$:** Supponiamo viceversa che le statistiche non coincidano. Senza perdita di generalità, assumiamo $x_{(n)} = y_{(n)}$ e $y_{(1)} < x_{(1)}$. Le due funzioni di densità valgono 1 nei rispettivi intervalli:

  $$f_n(\underline{x}|\theta) = 1 \iff \theta \in (x_{(n)} - 1,\ x_{(1)})$$

  $$f_n(\underline{y}|\theta) = 1 \iff \theta \in (y_{(n)} - 1,\ y_{(1)}) = (x_{(n)} - 1,\ y_{(1)})$$

  Valutiamo il rapporto nei vari sottointervalli di θ:

  - Se $\theta_1 \in (x_{(n)} - 1,\ y_{(1)})$, allora $f_n(\underline{x}|\theta_1) = 1$ e $f_n(\underline{y}|\theta_1) = 1 \implies \frac{f_n(\underline{x}|\theta_1)}{f_n(\underline{y}|\theta_1)} = 1$.
  - Se $\theta_2 \in (y_{(1)},\ x_{(1)})$, allora $f_n(\underline{x}|\theta_2) = 1$ mentre $f_n(\underline{y}|\theta_2) = 0 \implies \frac{f_n(\underline{x}|\theta_2)}{f_n(\underline{y}|\theta_2)} = \infty$.

Il rapporto dipende criticamente dalla scelta di θ ed è costante se e solo se le statistiche d'ordine coincidono, ossia se $T(\underline{x}) = T(\underline{y})$.

Siccome quanto mostrato vale $\forall \underline{x}, \underline{y}$, in virtù del Teorema di Lehmann-Scheffé, la coppia $T(\underline{X}) = (X_{(1)}, X_{(n)})$ è una **statistica sufficiente minimale** per θ.

47.2 Proprietà ed Osservazioni sulle Statistiche Minimali

- **Dimensione del parametro vs Dimensione della statistica:** Nell'esempio uniforme, il parametro incognito θ appartiene a $\mathbb{R}$ (dimensione 1), ma la statistica sufficiente minimale $T(\underline{X}) \in \mathbb{R}^2$ ha dimensione 2. Ciò dimostra che la dimensione della statistica minimale non coincide necessariamente con la dimensione dello spazio dei parametri.
- **Non unicità formale:** La statistica sufficiente minimale non è unica. Ad esempio, definendo il range campionario e il punto medio:

  $$T'(\underline{X}) = \left(X_{(n)} - X_{(1)},\ \frac{X_{(1)} + X_{(n)}}{2} \right)$$

  anche $T'(\underline{X})$ costituisce una statistica sufficiente minimale.
- **Esistenza:** Non è garantito che per qualunque famiglia parametrica esista una statistica sufficiente minimale che riduca significativamente la dimensione dei dati rispetto al campione completo. Ma se esiste soddisfa il teorema di Lehmann-Scheffé.

48 Il Principio di Verosimiglianza

Un pilastro concettuale della statistica inferenziale (in particolare di scuola fisheriana e bayesiana) è rappresentato dalla funzione di verosimiglianza e dal relativo principio.

Definizione 48.1 (Funzione di Verosimiglianza)**.** Sia $f_n(\underline{x}|\theta)$ la densità di probabilità congiunta associata al campione casuale $\underline{X}$. Una volta che il campione è stato osservato ed assume il valore fissato $\underline{x}$, la funzione:

$$L(\theta \,|\, \underline{x}) := f_n(\underline{x}|\theta)$$

considerata come funzione del parametro θ, prende il nome di **funzione di verosimiglianza** (*likelihood function*).

Interpretazione Probabilistica vs Inferenziale: Per comprendere appieno la natura di $L(\theta|\underline{x})$, consideriamo per semplicità il caso discreto, in cui:

$$f_n(\underline{x}|\theta) = \mathbb{P}_\theta(X_1 = x_1, X_2 = x_2, \ldots, X_n = x_n)$$

- **Prima dell'esperimento:** θ è considerato un parametro fisso e i dati $\underline{X}$ sono variabili aleatorie. Calcoliamo la probabilità di osservare diversi eventi futuri.
- **Dopo l'esperimento:** I dati $\underline{x}$ sono stati realizzati e fissati; l'unica incognita rimane il parametro θ.

Se per due valori parametrici $\theta_1 \neq \theta_2$ si osserva che:

$$L(\theta_1 \,|\, \underline{x}) > L(\theta_2 \,|\, \underline{x})$$

diciamo che il valore θ_1 è **più verosimile** di θ_2 alla luce dei dati osservati.

Attenzione! Dire che θ_1 è *"più probabile"* di θ_2 sarebbe formalmente scorretto nell'impostazione classica (frequentista). Una volta osservato il campione $\underline{x}$, non vi è più alcun elemento aleatorio nei dati. Il parametro θ è un valore incognito ma deterministico, non una variabile casuale; pertanto non ha senso associarvi direttamente una distribuzione di probabilità.

Assioma 4 (Principio di Verosimiglianza)**.** Siano $\underline{x}$ e $\underline{y}$ due realizzazioni campionarie (anche ottenute da esperimenti differenti). Se esiste una costante $C(\underline{x}, \underline{y})$, indipendente dal parametro θ, tale per cui:

$$L(\theta \,|\, \underline{x}) = C(\underline{x}, \underline{y}) \cdot L(\theta \,|\, \underline{y}) \quad \forall \theta$$

allora l'insieme delle informazioni inferenziali che si possono estrarre su θ dall'osservazione di $\underline{x}$ è identico a quello estraibile dall'osservazione di $\underline{y}$.

Esempio applicativo del principio: Supponiamo che per due parametri θ_1, θ_2 la verosimiglianza su un campione $\underline{x}$ verifichi:

$$L(\theta_1 \,|\, \underline{x}) = 2 \cdot L(\theta_2 \,|\, \underline{x})$$

Se osserviamo un secondo campione $\underline{y}$ la cui verosimiglianza è proporzionale a quella di $\underline{x}$ per mezzo di una costante C, cioè vale il principio di verosimiglianza, allora anche su $\underline{y}$ avremo:

$$L(\theta_1 \,|\, \underline{y}) = 2 \cdot L(\theta_2 \,|\, \underline{y})$$

Ne consegue che, in entrambi i casi, il valore θ_1 risulta essere esattamente due volte più plausibile del valore θ_2.

49 Introduzione agli Stimatori

Uno dei problemi centrali dell'inferenza statistica è capire come stimare un parametro incognito di una popolazione a partire dai dati a nostra disposizione. In questo contesto, è fondamentale distinguere due concetti spesso confusi:

- **Stimatore**: È una variabile aleatoria, definita come una funzione del campione casuale ($\underline{X}$). Rappresenta la "regola" o la formula che utilizzeremo.
- **Stima**: È il valore numerico effettivo ottenuto applicando lo stimatore a un'osservazione specifica $\underline{x}$ del campione.

50 Stimatori di Massima Verosimiglianza (MLE)

Tra i metodi più utilizzati per trovare buoni stimatori spicca il metodo della Massima Verosimiglianza (in inglese, *Maximum Likelihood Estimators* o MLE). L'idea di base è scegliere come stima il valore del parametro che rende "più probabile" osservare il campione che abbiamo effettivamente estratto.

Per formalizzare questo concetto, ricordiamo la **funzione di verosimiglianza**:

$$L(\theta|\underline{x}) = f_n(\underline{x}|\theta)$$

Questa funzione rappresenta la densità congiunta del campione, valutata nei dati osservati $\underline{x}$, ma vista come funzione del parametro incognito θ.

Definizione 50.1 (Stimatore di Massima Verosimiglianza)**.** Per ogni campione osservato $\underline{x}$, sia $\hat{\theta}(\underline{x})$ un parametro tale che la funzione di verosimiglianza $L(\theta|\underline{x})$ assuma il suo valore massimo in $\hat{\theta}(\underline{x})$. Ricordando che la funzione di verosimiglianza è una funzione di θ, $\hat{\theta}(\underline{x})$ rappresenta il punto di massimo assoluto di questa funzione (ed è a sua volta in funzione dei dati $\underline{x}$). In tal caso, $\hat{\theta}(\underline{X})$ è detto **stimatore di massima verosimiglianza** per θ (l'estimatore è funzione del campione $\underline{X}$).

50.1 Procedura operativa e l'uso del Logaritmo

Per trovare $\hat{\theta}$ si procede tipicamente attraverso i classici strumenti dell'analisi matematica:

1. Si cercano i **punti critici** annullando la derivata prima (o il gradiente) rispetto al parametro.
2. Si dimostra che il punto critico trovato è effettivamente un **massimo** (verificando il segno della derivata seconda o definita negatività dell'Hessiana).
3. *Attenzione ai bordi*: se il parametro è vincolato (es. $\theta \geq 0$), il massimo potrebbe trovarsi sulla frontiera del dominio, dove non è detto che il gradiente si annulli.

Nota fondamentale (Log-Verosimiglianza): Poiché i campioni sono spesso composti da variabili indipendenti e identicamente distribuite (i.i.d.), la funzione di verosimiglianza assume la forma di una produttoria. Per monotonia e continuità, è molto più comodo derivare somme rispetto ai prodotti. Si preferisce quindi lavorare con il logaritmo naturale della funzione di verosimiglianza, $\log(L(\theta|\underline{x}))$. Essendo il logaritmo una funzione strettamente monotona crescente, il valore θ che massimizza $\log(L(\theta|\underline{x}))$ è esattamente lo stesso che massimizza $L(\theta|\underline{x})$.

51 Esempi di Calcolo MLE

Esempio: MLE per la media di una distribuzione Normale

Siano $X_1, \ldots, X_n$ i.i.d. $\sim \mathcal{N}(\theta, 1)$. Vogliamo trovare l'MLE per la media incognita θ.
La funzione di verosimiglianza è:

$$L(\theta|\underline{x}) = f_n(\underline{x}|\theta) = \left(\frac{1}{\sqrt{2\pi}}\right)^n \exp\left\{-\frac{1}{2}\sum_{i=1}^{n}(x_i-\theta)^2\right\}$$

Deriviamo direttamente la funzione rispetto a θ:

$$\frac{d}{d\theta}L(\theta|\underline{x}) = \left(\frac{1}{\sqrt{2\pi}}\right)^n \exp\left\{-\frac{1}{2}\sum_{i=1}^{n}(x_i-\theta)^2\right\} \cdot \left(\sum_{i=1}^{n}(x_i-\theta)\right)$$

Ponendo la derivata uguale a zero, l'esponenziale non si annulla mai, quindi si ha:

$$\sum_{i=1}^{n}(x_i-\theta) = 0 \iff \sum_{i=1}^{n}x_i - n\theta = 0 \iff \hat{\theta} = \frac{1}{n}\sum_{i=1}^{n}x_i = \bar{x}$$

Il risultato è molto intuitivo: l'MLE per la media della popolazione è la media campionaria $\bar{x}$.
Verifichiamo che si tratti di un massimo calcolando la derivata seconda nel punto trovato. Poiché $\theta \in \mathbb{R}$, non abbiamo problemi di frontiera:

$$\left.\frac{d^2L(\theta|\underline{x})}{d\theta^2}\right|_{\theta=\bar{x}} < 0$$

Questo conferma che $\hat{\theta} = \bar{x}$ è effettivamente un punto di massimo. Perciò l'estimatore di massima verosimiglianza è $\hat{\theta}(\underline{X}) = \bar{X}$

Esempio: Normale con parametro vincolato ($\theta \geq 0$)

Consideriamo il caso precedente: $X_1, \ldots, X_n$ i.i.d. $\sim \mathcal{N}(\theta, 1)$, ma questa volta sappiamo a priori che $\theta \geq 0$. Dobbiamo distinguere due casi in base al valore assunto dalla media campionaria $\bar{x}$:

Caso 1: $\bar{x} < 0$

Se la media campionaria è negativa ($\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i < 0$), non può essere una stima ammissibile poiché viola il vincolo $\theta \geq 0$. Analizziamo la derivata:

$$\frac{dL(\theta|\underline{x})}{d\theta} = \underbrace{(\ldots)}_{>0} \cdot \underbrace{\left(\sum_{i=1}^{n} x_i - n\theta\right)}_{<0}$$

Infatti, se $\bar{x} < 0$, allora $\sum x_i < 0$. Poiché anche $-n\theta \leq 0$, l'intera parentesi è negativa. Ne consegue che per ogni $\theta \geq 0$, $\frac{dL(\theta|\underline{x})}{d\theta} < 0$. La funzione è strettamente decrescente nel dominio ammissibile, pertanto assumerà il suo valore massimo sulla frontiera inferiore, ovvero in $\hat{\theta} = 0$.

Caso 2: $\bar{x} \geq 0$

Se la media campionaria rispetta il vincolo, i calcoli precedenti restano validi e il punto di annullamento del gradiente cade dentro il dominio ammissibile. In questo caso $\hat{\theta}(\underline{x}) = \bar{x}$. Quindi in questo caso si ha che l'estimatore di massima verosimiglianza è $\hat{\theta}(\underline{X}) = max(0, \bar{X})$.

52 Proprietà degli Stimatori

Teorema 52.1 (Invarianza per MLE)**.** *Se $\hat{\theta}$ è lo stimatore di massima verosimiglianza per θ, allora per qualsiasi funzione g, si ha che $g(\hat{\theta})$ è lo stimatore di massima verosimiglianza per $g(\theta)$. Questo teorema è valido anche nel caso multidimensionale (per $\underline{\theta} \in \mathbb{R}^k$).*

Ad esempio, se sappiamo che $\hat{\theta} = \bar{X}$ è l'MLE per θ, per il teorema di invarianza lo stimatore MLE per θ^2 sarà semplicemente $\hat{\theta}^2 = (\bar{X})^2$. Allo stesso modo, in una variabile di Bernoulli Bern(p) dove lo stimatore per p è $\hat{p}$, l'MLE per la varianza $\text{Var}(\text{Bern}(p)) = p(1-p)$ sarà $\hat{p}(1-\hat{p})$.

Definizione 52.1 (Stimatore Corretto / Unbiased)**.** Diciamo che uno stimatore $\hat{\theta}$ è corretto (o non distorto) per il parametro θ se il suo valore atteso coincide con il parametro stesso:

$$\mathbb{E}[\hat{\theta}] = \theta$$

Nell'esempio della media campionaria:

$$\mathbb{E}[\bar{X}] = \mathbb{E}\left[\frac{1}{n}\sum_{i=1}^{n} X_i\right] = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}[X_i] = \frac{1}{n}(n\theta) = \theta$$

53 Estensione a Modelli Multiparametrici

Esempio: Normale con media e varianza incognite

Siano $X_1, \dots, X_n$ i.i.d. $\sim \mathcal{N}(\mu, \sigma^2)$, con $\underline{\theta} = (\mu, \sigma^2)$ entrambi incogniti. Troviamo l'MLE per il vettore $\underline{\theta}$.
La funzione di verosimiglianza congiunta è:

$$L(\underline{\theta}|\underline{x}) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left\{-\frac{1}{2\sigma^2}\sum_{i=1}^n (x_i-\mu)^2\right\}$$

Passiamo alla log-verosimiglianza, che ci semplificherà enormemente la vita:

$$\begin{aligned}\log(L(\underline{\theta}|\underline{x})) &= n\log\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \sum_{i=1}^n \frac{(x_i-\mu)^2}{2\sigma^2} \\ &= -\frac{n}{2}\left[\log(2\pi) + \log(\sigma^2)\right] - \frac{1}{2\sigma^2}\sum_{i=1}^n (x_i-\mu)^2\end{aligned}$$

Cerchiamo i punti critici annullando le derivate parziali rispetto a μ e σ^2:

$$\frac{\partial}{\partial\mu}\log(L(\underline{\theta}|\underline{x})) = \frac{1}{\sigma^2}\sum_{i=1}^n (x_i-\mu) = 0 \implies \hat{\mu} = \bar{x}$$

$$\frac{\partial}{\partial\sigma^2}\log(L(\underline{\theta}|\underline{x})) = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2}\sum_{i=1}^n (x_i-\mu)^2 = 0 \implies \sigma^2 = \frac{1}{n}\sum_{i=1}^n (x_i-\mu)^2$$

Tuttavia, uno stimatore non può dipendere da parametri incogniti. Sostituiamo quindi μ con la sua stima appena trovata $\hat{\mu} = \bar{x}$:

$$\hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^n (x_i-\bar{x})^2$$

Per confermare che il punto $(\bar{x}, \frac{1}{n}\sum_{i=1}^n (x_i-\bar{x})^2)$ sia effettivamente un punto di massimo, calcoliamo la matrice Hessiana H:

$$H := \begin{pmatrix} \frac{\partial^2}{\partial\mu^2} & \frac{\partial^2}{\partial\mu\partial\sigma^2} \\ \frac{\partial^2}{\partial\sigma^2\partial\mu} & \frac{\partial^2}{\partial(\sigma^2)^2} \end{pmatrix}$$

Facendo i conti (omessi per brevità), si verifica che $\det(H)\Big|_{ptocritico} > 0$ e che almeno una delle due derivate sulla diagonale principale, calcolata nel punto, è strettamente minore di zero. Il punto trovato è quindi l'MLE per $\underline{\theta} = (\mu, \sigma^2)$.

54 Un Caso con Dominio e Struttura Generica

Concludiamo con un esercizio su una distribuzione non standard che richiede attenzione nello studio della natura del punto critico.

Esempio: MLE per una distribuzione di potenza

Sia $X_1, \ldots, X_n$ un campione di v.a. i.i.d. con densità $f(x) = (\theta+1)x^{-(\theta+2)}$ per $x > 1$ e $\theta > 0$. Vogliamo determinare l'MLE per θ.
La funzione di verosimiglianza è:

$$L(\theta|\underline{x}) = (\theta+1)^n \prod_{i=1}^{n} x_i^{-(\theta+2)}$$

Passiamo subito alla log-verosimiglianza:

$$\begin{aligned}\log(L(\theta|\underline{x})) &= n\log(\theta+1) + \sum_{i=1}^{n} \log\left(x_i^{-(\theta+2)}\right) \\ &= n\log(\theta+1) - (\theta+2)\sum_{i=1}^{n}\log(x_i)\end{aligned}$$

Calcoliamo la derivata prima per trovare i punti critici:

$$\frac{d}{d\theta}\log(L(\theta|\underline{x})) = \frac{n}{\theta+1} - \sum_{i=1}^{n}\log(x_i)$$

Ponendola a zero otteniamo il nostro candidato stimatore:

$$\frac{n}{\theta+1} = \sum_{i=1}^{n}\log(x_i) \implies \theta+1 = \frac{n}{\sum_{i=1}^{n}\log(x_i)} \implies \hat{\theta} = \frac{n}{\sum_{i=1}^{n}\log(x_i)} - 1$$

Verifica del massimo e passaggio al massimo globale:
Calcoliamo ora la derivata seconda rispetto a θ:

$$\frac{d^2}{d\theta^2}\log(L(\theta|\underline{x})) = -\frac{n}{(\theta+1)^2}$$

Valutata nel punto critico $\hat{\theta}$, risulta ovviamente minore di zero, confermandolo come massimo locale:

$$\frac{d^2}{d\theta^2}\log(L(\hat{\theta}|\underline{x})) = -\frac{\left(\sum_{i=1}^{n}\log(x_i)\right)^2}{n} < 0$$

Inoltre, notiamo che l'espressione $-\frac{n}{(\theta+1)^2}$ è **strettamente minore di zero per qualsiasi valore di** $\theta > 0$ nel dominio. Questo ci dà un'informazione preziosissima: l'intera funzione log-verosimiglianza è strettamente concava. Per le proprietà delle funzioni strettamente concave, un punto stazionario (cioè dove la derivata prima si annulla) non è solo un massimo locale, ma è **necessariamente l'unico punto di massimo globale** sull'intero dominio.
Non è quindi strettamente necessario indagare l'andamento ai bordi del dominio per confrontare i valori (sebbene sia istruttivo notare che per $\theta \to +\infty$ la funzione tende a 0, e per $\theta = 0$ assume il valore finito $\prod_{i=1}^{n} x_i^{-2}$), in quanto la concavità globale è sufficiente per garantire che $\hat{\theta}$ sia il massimo assoluto.

55 Esercizi su Minimalità e MLE

55.1 Esercizi Statistiche Sufficienti e Minimali

Esempio: Statistica sufficiente e minimale per una distribuzione logistica modificata

Sia $X_1, \ldots, X_n$ *uncampionecasualei.i.d.* (indipendenti e identicamente distribuite) la cui densità di probabilità è data da:

$$f(x|\vartheta) = \frac{e^{-(x-\vartheta)}}{(1+e^{-(x-\vartheta)})^2}, \quad x \in \mathbb{R},\ \vartheta \in \mathbb{R}$$

Vogliamo verificare se il vettore delle statistiche d'ordine $\underline{T}(\underline{X}) := (X_{(1)}, X_{(2)}, \ldots, X_{(n)})$ costituisca una statistica sufficiente minimale.

55.1.1 Analisi della Sufficienza tramite il Teorema di Fattorizzazione

Per determinare se $\underline{T}(\underline{X})$ è una statistica sufficiente, partiamo dalla densità congiunta del campione $f_n(\underline{x}|\vartheta)$:

$$f_n(\underline{x}|\vartheta) = \prod_{i=1}^{n} \frac{e^{-(x_i-\vartheta)}}{(1+e^{-(x_i-\vartheta)})^2}, \quad x_i \in \mathbb{R} \quad \forall i$$

Sviluppando algebricamente i prodotti e separando la dipendenza dal parametro ϑ:

$$= \frac{e^{n\vartheta}\prod_{i=1}^{n} e^{-x_i}}{\prod_{i=1}^{n}(1+e^{-(x_i-\vartheta)})^2} = \frac{e^{n\vartheta}e^{-\sum_{i=1}^{n} x_i}}{\prod_{i=1}^{n}(1+e^{-(x_i-\vartheta)})^2}$$

Utilizzando il fatto che:

$$\sum_{i=1}^{n} x_i = \sum_{i=1}^{n} x_{(i)} \quad , \quad \prod_{i=1}^{n}(1+e^{-(x_i-\vartheta)})^2 = \prod_{i=1}^{n}(1+e^{-(x_{(i)}-\vartheta)})^2$$

e moltiplicando per una funzione costante pari a 1 indipendente da ϑ (funzione $h(\underline{x})$), possiamo esprimere la congiunta nella forma richiesta dal Teorema di Fattorizzazione di:

$$= \frac{e^{n\vartheta}e^{-\sum_{i=1}^{n} x_{(i)}}}{\prod_{i=1}^{n}(1+e^{-(x_{(i)}-\vartheta)})^2} \cdot \underbrace{1}_{h(\underline{x})}$$

La parte restante della funzione dipende dai dati attraverso le statistiche d'ordine e racchiude la dipendenza da ϑ, fungendo da $g(\underline{T}(\underline{X})|\vartheta)$. Poiché il teorema di fattorizzazione è soddisfatto, concludiamo che $\underline{T}(\underline{X})$ è una statistica sufficiente.

55.1.2 Verifica della Minimalità con il Criterio di Lehmann-Scheffé

Per accertare se la statistica sufficiente è anche minimale, analizziamo il rapporto delle densità congiunte per due campioni generici $\underline{x}$ e $\underline{y}$:

$$\frac{f_n(\underline{x}|\vartheta)}{f_n(\underline{y}|\vartheta)} = \frac{\frac{e^{n\vartheta}e^{-\sum_{i=1}^{n} x_{(i)}}}{\prod_{i=1}^{n}(1+e^{-(x_{(i)}-\vartheta)})^2}}{\frac{e^{n\vartheta}e^{-\sum_{i=1}^{n} y_{(i)}}}{\prod_{i=1}^{n}(1+e^{-(y_{(i)}-\vartheta)})^2}} = \frac{e^{-\sum_{i=1}^{n} x_{(i)}}}{e^{-\sum_{i=1}^{n} y_{(i)}}} \frac{\prod_{i=1}^{n}(1+e^{-(y_{(i)}-\vartheta)})^2}{\prod_{i=1}^{n}(1+e^{-(x_{(i)}-\vartheta)})^2}$$

Affinché questo rapporto risulti perfettamente costante rispetto al parametro ϑ, è necessario che il rapporto tra le produttorie si annulli o si semplifichi, il che si verifica se e solo se le

statistiche d'ordine coincidono, ovvero $T(\underline{X}) = T(\underline{Y})$. Per il criterio di Lehmann-Scheffé, la statistica è pertanto **sufficiente e minimale**.

55.2 Esercizio: Parametro Bidimensionale

Consideriamo ora un modello in cui il supporto della distribuzione dipende direttamente dai parametri incogniti.

Esempio: Distribuzione Esponenziale traslata

Sia $X_1, \dots, X_n$ un campione i.i.d. con densità:

$$f(x|\mu,\sigma) = \frac{1}{\sigma} e^{-\frac{(x-\mu)}{\sigma}} \mathbb{1}_{\{x>\mu\}}$$

Vogliamo trovare una statistica sufficiente per il vettore parametrico $\underline{\vartheta} = (\mu, \sigma)$ e stabilire se sia minimale.

Scriviamo la funzione di densità congiunta:

$$f_n(\underline{x}|\underline{\vartheta}) = \frac{1}{\sigma^n} e^{-\frac{\sum_{i=1}^n (x_i-\mu)}{\sigma}} \cdot \prod_{i=1}^n \mathbb{1}_{\{x_i>\mu\}}$$

Semplificando l'esponenziale e aggregando le funzioni indicatrici (notando che l'intersezione delle condizioni $x_i > \mu$ per ogni i equivale a imporre che il minimo dei dati sia maggiore di μ):

$$f_n(\underline{x}|\underline{\vartheta}) = \frac{1}{\sigma^n} e^{\frac{n\mu}{\sigma}} \cdot e^{-\frac{\sum_{i=1}^n x_i}{\sigma}} \cdot \mathbb{1}_{\{x_{(1)}>\mu\}}$$

Definiamo quindi la statistica bidimensionale:

$$\underline{T}(\underline{X}) := (\underbrace{X_{(1)}}_{T_1}, \underbrace{\sum_{i=1}^n X_i}_{T_2})$$

La densità si fattorizza come:

$$f_n(\underline{x}|\underline{\vartheta}) = \underbrace{\left(\frac{1}{\sigma}\right)^n e^{\frac{n\mu}{\sigma}} e^{-\frac{t_2}{\sigma}} \cdot \mathbb{1}_{\{t_1>\mu\}}}_{g(T(\underline{X})|\underline{\vartheta})} \cdot \underbrace{1}_{h(\underline{X})}$$

Per il teorema di fattorizzazione $T(\underline{X})$ è sufficiente. Analogamente al caso precedente, impostando il rapporto delle congiunte si riconosce che la condizione di costanza rispetto a μ e σ richiede l'uguaglianza delle statistiche d'ordine e delle somme campionarie, confermando la minimalità tramite Lehmann-Scheffé:

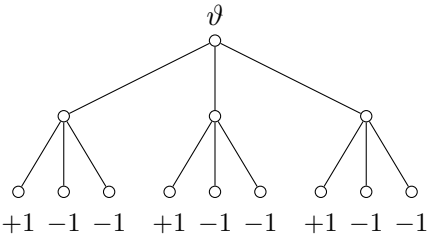
$$\frac{f_n(\underline{x}|\underline{\vartheta})}{f_n(\underline{y}|\underline{\vartheta})} = \frac{e^{-\frac{\sum_{i=1}^n x_i}{\sigma}} \cdot \mathbb{1}_{\{x_{(1)}>\mu\}}}{e^{-\frac{\sum_{i=1}^n y_i}{\sigma}} \cdot \mathbb{1}_{\{y_{(1)}>\mu\}}}$$

55.3 Esercizi sul Principio di Massima Verosimiglianza

Un'interessante applicazione della stima di massima verosimiglianza (MLE) si osserva nei modelli grafici ad albero, dove i dati osservati rappresentano stime affette da errore lungo i rami.

Esempio: Modello ad albero con segnali rumorosi

Sia $\vartheta \in \{-1, +1\}$ il valore alla radice di un albero di decisione. Supponiamo di osservare esclusivamente i valori posti ai nodi foglia (al livello inferiore), mentre la trasmissione lungo ciascun arco preserva il segno con probabilità $1 - \varepsilon$ e lo inverte con probabilità ε, assumendo $0 < \varepsilon < \frac{1}{2}$ fissato.



Il valore del vertice in alto è ϑ. La relazione di transizione lungo un arco generico (v, v') è descritta da:

$$\text{sgn}(v') = \begin{cases} \text{sgn}(v) & \text{con probabilità } 1 - \varepsilon \\ -\text{sgn}(v) & \text{con probabilità } \varepsilon \end{cases}$$

Valutiamo la probabilità dei dati osservati assumendo un'ipotesi sul parametro radice:

$$\mathbb{P}_{(\vartheta=+1)}[\text{dati osservati}] = [(1-\varepsilon)\cdot(1-\varepsilon)\cdot\varepsilon^2 + \varepsilon\cdot\varepsilon\cdot(1-\varepsilon)]^3 = 8\varepsilon^6(1-\varepsilon)^6$$

Infatti se il primo nodo vale 1, i figli possono valere o 1, mantendendo il segno, o -1, invertendo il segno. Nel primo caso quindi è necessario che, per ottenere la sequenza osservata, uno dei tre figli mantenga il segno, mentre gli altri due lo invertano, un ragionamento analogo si fa se il vertice sulla seconda linea ha valore -1. Siccome tutte le diramazioni sono indipendenti, le probabilità si fattorizzano, e siccome si hanno tre gruppi uguali di vertici, si ha l'elevazione al cubo.

Analogamente, calcolando la probabilità sotto l'ipotesi $\vartheta = -1$:

$$\mathbb{P}_{(\vartheta=-1)}[\text{dati osservati}] = [(1-\varepsilon)\varepsilon(1-\varepsilon)^2] + [\varepsilon(1-\varepsilon)\varepsilon^3] = \dots$$

Poiché $0 < \varepsilon < \frac{1}{2}$, si dimostra che $\mathbb{P}_{(\vartheta=-1)}(\text{dati osservati}) > \mathbb{P}_{(\vartheta=+1)}(\text{dati osservati})$, conducendo alla stima di massima verosimiglianza:

$$\hat{\vartheta} = -1$$

55.3.1 Stima di Massima Verosimiglianza e Proprietà di Correttezza

Un aspetto centrale nella valutazione di un estimatore riguarda la sua correttezza (assenza di distorsione, o *unbiasedness*).

Esempio: Stima per una distribuzione troncata

Sia $X_1, \dots, X_n$ un campione i.i.d. con funzione di densità:

$$f(x|\vartheta) = \begin{cases} \frac{\vartheta}{x^2}, & 0 < \vartheta \le x \\ 0, & \text{altrimenti} \end{cases}$$

Vogliamo determinare lo stimatore di massima verosimiglianza per ϑ e verificare se esso sia corretto.

Derivazione dello Stimatore MLE La funzione di verosimiglianza si esprime come:

$$\mathcal{L}(\vartheta|\underline{x}) = f_n(\underline{x}|\vartheta) = \vartheta^n \prod_{i=1}^{n} \frac{1}{x_i^2} \cdot \mathbb{1}_{\{0<\vartheta\leq x_i\}} = \vartheta^n \prod_{i=1}^{n} \frac{1}{x_i^2} \cdot \mathbb{1}_{\{x_{(1)}\geq\vartheta\}}$$

Analizzando l'andamento della funzione rispetto a ϑ:

- Se $\vartheta \leq 0$, la verosimiglianza si annulla identicamente, basti guardare la distribuzione marginale.
- Se $\vartheta > 0$, la funzione è strettamente crescente in ϑ, il che porta a scegliere il valore massimo ammissibile compatibile con i vincoli, ovvero l'estimatore di massima verosimiglianza:

$$\text{MLE}(\vartheta) = \hat{\vartheta}(\underline{X}) = X_{(1)}$$

Verifica della Correttezza dello Stimatore Per verificare se lo stimatore è corretto, dobbiamo calcolarne il valore atteso $\mathbb{E}_\vartheta[\hat{\vartheta}(\underline{X})]$ e controllare se coincide con il parametro ϑ.

Partiamo dalla densità della statistica d'ordine minima $X_{(1)}$:

$$f_{X_{(1)}}(a) = \frac{d}{da}\mathbb{P}_\vartheta(X_{(1)} \leq a) = \frac{d}{da}(1 - \mathbb{P}_\vartheta(X_{(1)} > a)) = \frac{d}{da}\left(1 - [\mathbb{P}_\vartheta(X_1 > a)]^n\right)$$

Per $a < \vartheta$, la probabilità è nulla $f_{X_{(1)}}(a) = 0$. Infatti:

$$\forall a < \vartheta \implies \mathbb{P}_{(\vartheta)}(X_1 \leq a) = 0 \implies \mathbb{P}_{(\vartheta)}(X_1 > a) = 1$$

che sostituita nell'espressione di $f_{X_{(1)}}(a)$ da il risultato esposto. Per $a \geq \vartheta$, calcoliamo la probabilità di sopravvivenza:

$$\mathbb{P}_\vartheta(X_1 > a) = \int_a^{+\infty} \frac{\vartheta}{x^2} dx = \frac{\vartheta}{a}$$

Sostituendo nella derivata otteniamo la densità di $X_{(1)}$ per $a \geq \vartheta$:

$$f_{X_{(1)}}(a) = \frac{d}{da}\left[1 - \frac{\vartheta^n}{a^n}\right] = \frac{n\vartheta^n}{a^{n+1}}$$

Passiamo ora al calcolo del valore atteso:

$$\mathbb{E}_\vartheta(X_{(1)}) = \int_\vartheta^{+\infty} a \cdot f_{X_{(1)}}(a)\, da = \int_\vartheta^{+\infty} a \cdot \frac{n\vartheta^n}{a^{n+1}}\, da = n\vartheta^n \int_\vartheta^{+\infty} a^{-n}\, da$$

Risolvendo l'integrale:

$$= n \cdot \vartheta^n \left[\frac{a^{-n+1}}{-n+1}\right]_\vartheta^{+\infty} = \frac{n}{n-1}\vartheta$$

Poiché il valore atteso differisce da ϑ per il fattore moltiplicativo $\frac{n}{n-1}$, concludiamo che **lo stimatore di massima verosimiglianza non è corretto** (è distorto).

56 Altri Esercizi Stima di Massima Verosimiglianza (MLE)

Esempio: Stimatore di Massima Verosimiglianza per la Laplace

Sia $X_1, \ldots, X_n$ un campione di variabili aleatorie i.i.d. con densità di probabilità di Laplace:

$$f(x|\vartheta) = \frac{1}{2}e^{-|x-\vartheta|}$$

Vogliamo determinare lo stimatore di massima verosimiglianza per il parametro di posizione ϑ.

Svolgimento: Per prima cosa, costruiamo la funzione di verosimiglianza $L(\vartheta|\underline{x})$, definita come il prodotto delle densità marginali congiunte del campione:

$$L(\vartheta|\underline{x}) = f_n(\underline{x}|\vartheta) = \left(\frac{1}{2}\right)^n e^{-\sum_{i=1}^n |x_i - \vartheta|}$$

Per agevolare il calcolo analitico, anziché massimizzare direttamente L, massimizziamo la sua funzione logaritmica (log-verosimiglianza), la quale possiede gli stessi punti di massimo ma trasforma i prodotti in somme più trattabili:

$$\log(L(\vartheta|\underline{x})) = n \log\left(\frac{1}{2}\right) - \sum_{i=1}^n |x_i - \vartheta|$$

Derivando rispetto al parametro ϑ, otteniamo:

$$\frac{d}{d\vartheta}(\log(L(\vartheta|\underline{x}))) = \sum_{i=1}^n \operatorname{sgn}(x_i - \vartheta)$$

Ponendo la derivata prima uguale a zero per trovare i punti stazionari, ci chiediamo quando si annulla:

$$\frac{d}{d\vartheta}(\log(L(\vartheta|\underline{x}))) = 0 \iff \sum_{i=1}^n \operatorname{sgn}(x_i - \vartheta) = 0$$

Ciò si verifica quando abbiamo lo stesso numero di termini positivi e negativi, ovvero quando ϑ divide a metà l'ordinamento del campione. Questo significa che ϑ è la **mediana** del campione.

Formalmente, lo stimatore è dato da:

$$\hat{\vartheta}(\underline{X}) = \text{mediana}(\underline{X})$$

(Nel caso di un numero dispari di osservazioni, il valore centrale esatto ha scarto nullo e si esclude dalla somma). Per confermare che si tratti di un massimo assoluto, osserviamo il segno della derivata:

$$\forall \vartheta < \text{mediana}(\underline{x}) \implies \frac{d}{d\vartheta}(\log(L(\vartheta|\underline{x}))) > 0$$

$$\forall \vartheta > \text{mediana}(\underline{x}) \implies \frac{d}{d\vartheta}(\log(L(\vartheta|\underline{x}))) < 0$$

Pertanto, la funzione log-verosimiglianza è crescente a sinistra della mediana e decrescente a destra, confermando che lo stimatore di massima verosimiglianza cercato è proprio la mediana campionaria.

Esempio: Stima del parametro di scala

Consideriamo ora un secondo esempio in cui la densità di probabilità presenta un parametro di scala $\sigma > 0$:

$$f(x|\sigma) = \frac{1}{2\sigma} e^{-\frac{|x|}{\sigma}} \quad \text{con } \sigma > 0$$

La corrispondente funzione di verosimiglianza per un campione i.i.d. è:

$$L(\sigma|\underline{x}) = f_n(\underline{x}|\sigma) = \left(\frac{1}{2\sigma}\right)^n e^{-\sum_{i=1}^n \frac{|x_i|}{\sigma}}$$

Passando al logaritmo naturale:

$$\log(L(\sigma|\underline{x})) = n \log\left(\frac{1}{2\sigma}\right) - \sum_{i=1}^n \frac{|x_i}{\sigma} = n \log\left(\frac{1}{2}\right) - n\log(\sigma) - \frac{1}{\sigma}\sum_{i=1}^n |x_i|$$

Calcoliamo la derivata prima rispetto a σ:

$$\frac{d}{d\sigma}(\log(L(\sigma|\underline{x}))) = -\frac{n}{\sigma} + \frac{1}{\sigma^2}\sum_{i=1}^n |x_i| = \frac{1}{\sigma^2}\sum_{i=1}^n |x_i| - \frac{n}{\sigma}$$

Imponendo la condizione stazionaria pari a zero:

$$\frac{d}{d\sigma}(\log(L(\sigma|\underline{x}))) = 0 \implies \sigma = \frac{1}{n}\sum_{i=1}^n |x_i|$$

Il candidato stimatore di massima verosimiglianza è dunque:

$$\hat{\sigma}(\underline{x}) = \frac{\sum_{i=1}^n |X_i|}{n}$$

Studio del segno della derivata per verificare la natura del punto stazionario:

$$\frac{d}{d\sigma}(\log(L(\sigma|\underline{x}))) > 0 \iff \sigma < \frac{\sum_{i=1}^n |x_i|}{n}$$

$$\frac{d}{d\sigma}(\log(L(\sigma|\underline{x}))) < 0 \iff \sigma > \frac{\sum_{i=1}^n |x_i|}{n}$$

Anche in questo caso, la funzione ammette un massimo globale in corrispondenza del valore stimato $\hat{\sigma}$.

57 Gli Stimatori Bayesiani

Mentre negli approcci precedenti il parametro ϑ delle distribuzioni è stato considerato una costante fissa ma ignota, nell'inferenza Bayesiana ϑ viene trattato a tutti gli effetti come una variabile aleatoria, descritta da una distribuzione di probabilità iniziale nota come **distribuzione a priori** (*prior distribution*), indicata solitamente con $\pi(\vartheta)$.

Una volta osservato il campione dei dati, aggiorniamo la nostra credenza sul parametro combinando la verosimiglianza dei dati con la distribuzione a priori, ottenendo così la **distribuzione a posteriori** (*posterior distribution*). Questo processo di apprendimento e aggiornamento è regolato dal teorema di Bayes:

Proposizione 57.1 (Regola di Bayes per densità)**.** *Data la prior $\pi(\vartheta)$ e la congiunta del campione $f_n(\underline{x}|\vartheta)$, la distribuzione a posteriori si esprime come:*

$$\pi(\vartheta|\underline{x}) = \frac{f_n(\underline{x}|\vartheta) \cdot \pi(\vartheta)}{f_n(\underline{x})}$$

dove al denominatore compare la distribuzione marginale dei dati (o evidenza), ottenuta marginalizzando rispetto al parametro:

$$f_n(\underline{x}) = \int f_n(\underline{x}, \vartheta) d\vartheta = \int f_n(\underline{x}|\vartheta)\pi(\vartheta) d\vartheta$$

È importante sottolineare che la distribuzione a posteriori dipende esplicitamente dal campione osservato $\underline{x}$: se avessimo estratto un campione differente, la nostra conoscenza aggiornata sul parametro sarebbe inevitabilmente diversa.

57.1 Derivazione dello Stimatore Bayesiano

Per estrarre una stima puntuale dal quadro bayesiano, si procede generalmente secondo due strade principali:

1. **Tramite una funzione costo (Loss Function) $G(a, \vartheta)$:** in cui a rappresenta la stima scelta e ϑ il valore reale del parametro. Lo stimatore Bayesiano ottimale è definito come quel valore che minimizza il valore atteso della funzione costo, calcolato rispetto alla distribuzione a posteriori $\pi(\vartheta|\underline{x})$:

   $$\hat{\vartheta}_{\text{Bayes}} = \arg\min_a \mathbb{E}_{\pi(\vartheta|\underline{x})}(G(a, \vartheta)) = \arg\min_a \int G(a, \vartheta)\pi(\vartheta|\underline{x}) d\vartheta$$

   Una delle scelte più comuni in letteratura è la funzione costo a errore quadratico: $G(a, \vartheta) = (a - \vartheta)^2$.

2. **Senza una funzione costo esplicita:** se non viene specificata una funzione di perdita e assumiamo che il parametro ϑ segua la distribuzione a posteriori, lo stimatore Bayesiano coincide con la media della posterior stessa:

   $$\hat{\vartheta}_{\text{Bayes}} = \mathbb{E}[V_\vartheta] \quad \text{con } V_\vartheta \sim \pi(\vartheta|\underline{x})$$

57.2 Famiglie Coniugate

Un concetto fondamentale nell'inferenza Bayesiana è la coniugazione a priori.

Definizione 57.1 (Famiglia Coniugata)**.** Sia $\mathcal{F} = \{f_n(\underline{x}|\vartheta)\}_{\vartheta \in \Theta}$ una classe di distribuzioni congiunte indicizzata da ϑ. Si dice che la classe $\mathcal{G}$ delle distribuzioni a priori è una **famiglia coniugata** per $\mathcal{F}$ se la distribuzione a posteriori risultante appartiene ancora alla stessa classe $\mathcal{G}$, per ogni $f_n(\underline{x}|\vartheta) \in \mathcal{F}$ e per ogni scelta della prior $\pi \in \mathcal{G}$.

Nota: In parole povere, la prior e la posteriore appartengono alla stessa identica famiglia matematica. Questo significa che l'osservazione dei dati non stravolge la forma funzionale della distribuzione, ma si traduce semplicemente in un aggiornamento algebrico dei suoi parametri.

Esempio: Coniugazione Beta-Binomiale

Consideriamo un campione di variabili aleatorie bernoulliane $X_1, \dots, X_n \sim \text{Bern}(p)$, dove il parametro di successo p è incognito. Definiamo la statistica sufficiente $Y = \sum_{i=1}^{n} X_i$, la quale segue una distribuzione binomiale $Y \sim \text{Bin}(n, p)$.
Assumiamo a priori che il parametro p sia distribuito secondo una legge Beta: $p \sim \text{Beta}(\alpha, \beta)$.
Vogliamo trovare lo stimatore Bayesiano per p. La distribuzione congiunta tra la statistica Y e il parametro p è data dal prodotto tra la verosimiglianza binomiale e la densità della prior Beta:

$$f(y,p) = f(y|p) \cdot \pi(p) = \left[\binom{n}{y} p^y (1-p)^{n-y}\right] \left[\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1}(1-p)^{\beta-1}\right]$$

La distribuzione marginale di Y si ottiene integrando rispetto a p su tutto il supporto $[0,1]$:

$$f_Y(y) = \int_0^1 f(y,p)dp = \binom{n}{y} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(y+\alpha)\Gamma(n-y+\beta)}{\Gamma(n+\alpha+\beta)}$$

Costruiamo quindi la distribuzione a posteriori applicando la regola di Bayes:

$$\pi(p|y) = \frac{f(y,p)}{f_Y(y)} = \frac{\binom{n}{y} p^y (1-p)^{n-y} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1}(1-p)^{\beta-1}}{\binom{n}{y} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \frac{\Gamma(y+\alpha)\Gamma(n-y+\beta)}{\Gamma(n+\alpha+\beta)}}$$

semplificando i termini costanti, otteniamo:

$$\pi(p|y) = \frac{\Gamma(n+\alpha+\beta)}{\Gamma(y+\alpha)\Gamma(n-y+\beta)} p^{y+\alpha-1}(1-p)^{n-y+\beta-1}$$

Riconosciamo immediatamente che la distribuzione a posteriori è ancora una volta una legge Beta, nello specifico $\text{Beta}(y+\alpha, n-y+\beta)$.
In assenza di una funzione costo esplicita, la stima Bayesiana per p è data dal valore atteso della distribuzione a posteriori:

$$\hat{p}_{\text{Bayes}} = \mathbb{E}[\pi(p|y)]$$

Sapendo che la media di una variabile aleatoria distribuita come $\text{Beta}(\alpha', \beta')$ è data da $\frac{\alpha'}{\alpha'+\beta'}$, otteniamo la stima finale:

$$\hat{p}_B = \frac{y+\alpha}{\alpha+\beta+n}$$

che rappresenta la media della distribuzione a posteriori $\text{Beta}(y+\alpha, n-y+\beta)$.

58 Esercizi sugli Stimatori Bayesiani

Esempio:

Supponiamo di disporre di un campione di variabili aleatorie indipendenti e identically distributed (i.i.d.) $X_1, \ldots, X_n$, caratterizzate da una densità marginale condizionata data da:

$$f(x|\theta) = \begin{cases} \theta x^{\theta-1}, & 0 < x < 1 \\ 0, & \text{altimenti} \end{cases}$$

dove $\theta > 0$ è il parametro di interesse. Assumiamo inoltre una distribuzione a priori coniugata di tipo Gamma, $\pi(\theta) \sim \Gamma(\alpha, \beta)$, con iperparametri $\alpha, \beta > 0$, la cui densità è definita come:

$$\pi(\theta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta}$$

Il nostro obiettivo è determinare la distribuzione a posteriori $\pi(\theta|\underline{x})$ e ricavare il conseguente stimatore Bayesiano per il parametro θ.

Derivazione della Distribuzione a Posteriori La funzione di verosimiglianza congiunta del campione, assumendo per semplicità che ogni osservazione appartenga all'intervallo $(0, 1)$, si esprime come il prodotto delle singole densità:

$$f_n(\underline{x}|\theta) = \prod_{i=1}^{n} \theta x_i^{\theta-1} = \theta^n \prod_{i=1}^{n} x_i^{\theta-1} = \theta^n e^{(\theta-1)\sum_{i=1}^{n} \log(x_i)}$$

Attraverso il teorema di Bayes, la distribuzione a posteriori è proporzionale al prodotto tra la verosimiglianza e la distribuzione a priori:

$$\pi(\theta|\underline{x}) = \frac{f_n(\underline{x}|\theta)\pi(\theta)}{f_n(\underline{x})} \propto f_n(\underline{x}|\theta) \cdot \pi(\theta)$$

Notiamo che il denominatore $f_n(\underline{x}) = \int_0^\infty f_n(\underline{x}, \theta)\, d\theta$ agisce puramente come una costante di normalizzazione rispetto a θ. Sostituendo le espressioni otteniamo:

$$\pi(\theta|\underline{x}) \propto \theta^n e^{(\theta-1)\sum_{i=1}^{n} \log(x_i)} \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta}$$

Raggruppando i termini in base alle potenze di θ e agli esponenti esponenziali, ricaviamo:

$$\pi(\theta|\underline{x}) \propto \theta^{n+\alpha-1} e^{-\theta\left(\beta - \sum_{i=1}^{n} \log(x_i)\right)}$$

Riconosciamo immediatamente in questa struttura il nucleo di una distribuzione Gamma. Posto $\gamma = \beta - \sum_{i=1}^{n} \log(x_i)$, la distribuzione a posteriori risulta essere:

$$\pi(\theta|\underline{x}) \sim \Gamma\left(n + \alpha,\, \beta - \sum_{i=1}^{n} \log(x_i)\right)$$

In assenza di una specifica funzione di perdita (costo), lo stimatore Bayesiano classico sotto perdita quadratica coincide con la media della distribuzione a posteriori:

$$\hat{\theta}_{\text{Bayes}} = \mathbb{E}[V_{\underline{x}}] \quad \text{dove } V_{\underline{x}} \sim \pi(\theta|\underline{x})$$

Sfruttando le proprietà note della media di una variabile aleatoria Gamma, otteniamo esplicitamente lo stimatore:

$$\hat{\theta}_{\text{Bayes}} = \frac{n + \alpha}{\beta - \sum_{i=1}^{n} \log(x_i)}$$

Teorema 58.1 (Densità della Gamma Inversa)**.** *Sia $X \sim \Gamma(m, \beta)$, ovvero con densità $f(x) = \frac{\beta^m}{\Gamma(m)} x^{m-1} e^{-\beta x} \mathbb{1}_{\{x \geq 0\}}$. Definiamo la variabile trasformata $Y = \frac{1}{X}$. La densità di Y segue una distribuzione Γ-inversa con parametri m e β.*

Dimostrazione. Ponendo $g(x) = \frac{1}{x}$ per $x > 0$, la funzione inversa è $x = \frac{1}{y}$ con derivata in modulo pari a $\left|\frac{dx}{dy}\right| = \frac{1}{y^2}$. Applicando il lemma di trasformazione per le densità:

$$f_Y(y) = f_X(x(y)) \left|\frac{dx}{dy}\right| = \frac{\beta^m}{\Gamma(m)} \left(\frac{1}{y}\right)^{m-1} e^{-\beta/y} \cdot \frac{1}{y^2} = \frac{\beta^m}{\Gamma(m)} \frac{1}{y^{m+1}} e^{-\beta/y}$$

□

58.1 Inferenza sulla Varianza di un Modello Gaussiano

Consideriamo un campione $X_1, \ldots, X_n$ i.i.d. tali che $X_i \sim \mathcal{N}(0, \sigma^2)$ con σ^2 sconosciuto. Supponiamo che la distribuzione a priori sul parametro di varianza sia una Γ-inversa con parametri m e β:

$$\pi(\sigma^2) = \frac{\beta^m}{\Gamma(m)} \frac{1}{(\sigma^2)^{m+1}} e^{-\frac{\beta}{\sigma^2}}$$

La verosimiglianza del campione condizionata a σ^2 è data da:

$$f_n(\underline{x}|\sigma^2) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n e^{-\sum_{i=1}^n \frac{x_i^2}{2\sigma^2}}$$

Combinando verosimiglianza e priori, ricaviamo la posterior per la varianza:

$$\pi(\sigma^2|\underline{x}) \propto \left(\frac{1}{\sigma^2}\right)^{\frac{n}{2}+m+1} e^{-\frac{1}{\sigma^2}\left(\beta + \sum_{i=1}^n \frac{x_i^2}{2}\right)}$$

Ciò dimostra la coniugazione del modello: la distribuzione a posteriori della varianza è ancora una Γ-inversa con parametri aggiornati:

$$m^* = m + \frac{n}{2}, \quad \beta^* = \beta + \sum_{i=1}^n \frac{x_i^2}{2}$$

58.2 Esercizio con Funzione di Costo

Esempio:

Consideriamo la seguente funzione di costo:

$$G(a, \theta) = e^{c(a-\theta)} - c(a - \theta) - 1$$

dove θ è il parametro vero, a è la nostra stima (azione) e $c > 0$ è una costante di penalizzazione. Vogliamo verificare che lo stimatore Bayesiano associato a questa funzione di perdita sia dato da:

$$\hat{a}_{\text{Bayes}} = -\frac{1}{c} \log\left(\mathbb{E}_{\pi(\theta|\underline{x})}(e^{-c\theta})\right)$$

Minimizzazione del Rischio Atteso Il rischio atteso a posteriori associato alla funzione di costo è:

$$\mathbb{E}_{\pi(\theta|\underline{x})}(G(a,\theta)) = \int_{\mathbb{R}} \left(e^{c(a-\theta)} - c(a-\theta) - 1\right) \pi(\theta|\underline{x})\, d\theta$$

Sviluppando l'integrale e sfruttando la linearità del valore atteso, otteniamo:

$$\mathbb{E}_{\pi(\theta|\underline{x})}(G(a,\theta)) = e^{ca}\mathbb{E}_{\pi(\theta|\underline{x})}[e^{-c\theta}] - ca + c\mathbb{E}_{\pi(\theta|\underline{x})}(\theta) - 1$$

Derivando rispetto alla variabile di decisione a e ponendo la derivata uguale a zero per trovare i punti stazionari:

$$\frac{d}{da}\mathbb{E}[\dots] = ce^{ca}\mathbb{E}_{\pi(\theta|\underline{x})}[e^{-c\theta}] - c = 0$$

Dividendo per c e riordinando i termini:

$$e^{ca}\mathbb{E}_{\pi(\theta|\underline{x})}[e^{-c\theta}] = 1 \implies e^{ca} = \frac{1}{\mathbb{E}_{\pi(\theta|\underline{x})}[e^{-c\theta}]}$$

Applicando il logaritmo naturale ad ambo i membri ricaviamo lo stimatore ottimale:

$$ca = -\log\left(\mathbb{E}_{\pi(\theta|\underline{x})}[e^{-c\theta}]\right) \implies \hat{a} = -\frac{1}{c}\log\left(\mathbb{E}_{\pi(\theta|\underline{x})}[e^{-c\theta}]\right)$$

Per assicurarci che il punto critico trovato corrisponda a un minimo globale, calcoliamo la derivata seconda del rischio atteso rispetto ad a:

$$\frac{d^2}{da^2}\mathbb{E}[\dots] = c^2e^{ca}\mathbb{E}_{\pi(\theta|\underline{x})}(e^{-c\theta}) > 0 \quad \forall a$$

Essendo la derivata seconda strettamente positiva per ogni valore di a, la funzione di rischio atteso risulta convessa. Di conseguenza, l'unico punto critico individuato rappresenta un minimo assoluto per il nostro problema decisionale.